

Prácticas preprofesionales – Departamento de Ciencias de la Computación
Universidad de las Fuerzas Armadas ESPE

Autor/a: Ariel Llumiquinga

Tutora: Ing. Doris Chicaiza

Proyecto: Smart Agriculture

Actividad del itinerario: 1. Inducción al proyecto de investigación

Versión: 3

Fecha: 1 de octubre de 2026.

Estado: Borrador para revisión de la tutora.

Título provisional

Enfermedades del tallo del aguacate (*Persea americana*) y sistemas basados en inteligencia artificial para su diagnóstico en el marco de la agricultura inteligente (*Smart Agriculture*): protocolo de revisión sistemática.

1. Antecedentes/justificación

La agricultura de precisión es un enfoque que aprovecha tecnologías avanzadas —como la teledetección, los sistemas de información geográfica y el aprendizaje automático— para adaptar las intervenciones a las condiciones específicas de cada campo, mejorar la eficiencia en el uso de los recursos y aumentar los rendimientos (Majdalawieh et al., 2025). La detección de enfermedades es una de sus aplicaciones principales, ya que tradicionalmente los agricultores vigilan las plantas de forma manual y a simple vista, una práctica que consume tiempo y recursos (Sajitha et al., 2024).

El aprendizaje profundo ha transformado la identificación de enfermedades de plantas. Las redes neuronales convolucionales (CNN) son el enfoque más utilizado y con mejor relación entre costo y desempeño, mientras que los Vision Transformers alcanzan mayor exactitud a cambio de mayores recursos de cómputo; en general, los modelos de aprendizaje profundo superan a los de aprendizaje automático clásico (Majdalawieh et al., 2025). El uso de modelos preentrenados y del aprendizaje por transferencia permite una detección precisa con conjuntos de datos más pequeños (Sajitha et al., 2024). Sin embargo, los modelos entrenados con conjuntos de laboratorio, como PlantVillage, pueden sobreajustarse a condiciones controladas (Majdalawieh et al., 2025), y las condiciones de campo —clima variable, iluminación inconsistente o diferentes etapas de crecimiento— reducen su robustez (Lin et al., 2026).

Llevar estos modelos al lugar donde se observan los síntomas exige soluciones ligeras. El despliegue en el borde (*edge*), con modelos compactos ejecutados en teléfonos inteligentes, evita la dependencia continua de Internet y permite la inferencia en tiempo real (Saini et al., 2026), y técnicas como la destilación de conocimiento transfieren lo aprendido por modelos complejos a modelos ligeros como MobileNet (Lin et al., 2026). A la vez, el valor práctico de una aplicación depende de la experiencia de sus usuarios: el diseño centrado en el usuario integra en el desarrollo actividades como la investigación con usuarios, el prototipado y las pruebas de usabilidad (Martinelli et al., 2024).

En el aguacate, las enfermedades del tallo, las ramas y el tronco —como la muerte descendente y los canchros asociados a Botryosphaeriaceae— comprometen la estructura del árbol

y se han reportado en distintas regiones productoras (Arjona-Girona et al., 2019; Crespo et al., 2026; Möller et al., 2025). Otros patógenos, como *Colletotrichum* spp., también causan lesiones en el tallo (Vecchio et al., 2026). Su diagnóstico depende hoy de análisis de laboratorio, aunque su manifestación visible en el tallo hace factible, en principio, su identificación por imagen. Los sistemas de IA aplicados al aguacate, en cambio, se han centrado en el fruto (Moreano et al., 2026).

Las revisiones disponibles abordan estas cuestiones por separado. Las revisiones tecnológicas analizan las técnicas de aprendizaje automático y profundo para detectar enfermedades en cultivos en general (Majdalawieh et al., 2025; Munjal et al., 2023; Odounfa et al., 2024; Saini et al., 2026; Sajitha et al., 2024), mientras que las fitopatológicas describen las enfermedades del aguacate sin abordar su diagnóstico automatizado (Möller et al., 2025). Para desarrollar una aplicación móvil de diagnóstico en tallos de aguacate se necesitan ambos conocimientos: qué enfermedades afectan al tallo y cómo se manifiestan, y qué técnicas y diseños de aplicación han funcionado en el diagnóstico de enfermedades.

Por ello, se justifica una revisión sistemática que integre, en un único proceso y un único diagrama de flujo, dos categorías de estudios primarios: estudios fitopatológicos sobre las enfermedades y alteraciones del tallo del aguacate, y estudios tecnológicos sobre sistemas basados en IA para el diagnóstico de enfermedades en cultivos. Cada categoría se evalúa con sus propios criterios de elegibilidad y de calidad. La revisión sigue las directrices de Kitchenham y Charters para revisiones sistemáticas (como se citó en Martinelli et al., 2024) y se reporta conforme a la declaración PRISMA, aplicada también en revisiones recientes del área (Lin et al., 2026; Majdalawieh et al., 2025; Odounfa et al., 2024; Sajitha et al., 2024). Sus resultados orientarán el diseño del dataset de imágenes de tallos, la selección de modelos y el diseño de la aplicación móvil del proyecto.

2. Objetivo del estudio

Analizar y sintetizar la literatura científica sobre las enfermedades y alteraciones del tallo del aguacate —sus agentes causales, síntomas visibles y métodos de detección— y sobre los sistemas basados en inteligencia artificial y visión por computador para el diagnóstico de enfermedades en cultivos —sus técnicas, datos, métricas, implementación e interacción persona-ordenador—, con el fin de identificar buenas prácticas y brechas que fundamenten el desarrollo de una aplicación móvil para el diagnóstico de enfermedades en tallos de aguacate.

3. Pregunta principal de investigación

¿Qué evidencia científica existe sobre las enfermedades y alteraciones del tallo del aguacate y sobre los sistemas basados en inteligencia artificial para el diagnóstico de enfermedades en cultivos, que permita fundamentar el desarrollo de una aplicación móvil para el diagnóstico en tallos de aguacate?

4. Preguntas de investigación secundarias

RQ1. ¿Qué agentes causales y enfermedades afectan al tallo, las ramas y el tronco del aguacate, y en qué regiones se han reportado?

RQ2. ¿Qué síntomas visibles producen estas enfermedades y qué métodos se utilizan para su detección y diagnóstico?

RQ3. ¿Qué técnicas de inteligencia artificial y visión por computador, conjuntos de datos y métricas se emplean en los sistemas de diagnóstico de enfermedades en cultivos?

RQ4. ¿Qué características de implementación (plataforma, inferencia, funcionamiento sin conexión) y de interacción persona-ordenador presentan estos sistemas?

RQ5. ¿Qué brechas y oportunidades se identifican para desarrollar una aplicación móvil de diagnóstico de enfermedades en tallos de aguacate?

5. Marco PICOS

Para estructurar la pregunta de investigación y definir los criterios de elegibilidad, este protocolo adopta el marco PICOS (*Population, Intervention, Comparison, Outcomes y Study design*), que facilita la delimitación del alcance, la construcción de estrategias de búsqueda reproducibles y la definición transparente de los criterios de inclusión y exclusión. Se seleccionó PICOS frente a otros marcos (PICO, PECO o SPIDER) porque incorpora explícitamente el tipo de estudio, aspecto relevante en una revisión que integra dos categorías de estudios primarios.

Los componentes se definieron de la siguiente manera:

Elemento	Estudios fitopatológicos	Estudios tecnológicos
P (Population)	Aguacate (<i>Persea americana</i>), con énfasis en tallo, ramas y tronco.	Cultivos agrícolas afectados por enfermedades (cualquier órgano).
I (Intervention)	Identificación, caracterización o patogenicidad de agentes causales; descripción de síntomas; métodos de detección y diagnóstico.	Sistemas de IA, machine learning, deep learning o visión por computador para detectar, clasificar o diagnosticar enfermedades, relacionados con una app móvil, un dispositivo o un sistema de apoyo.
C (Comparison)	No se exige comparador.	Comparación entre modelos o arquitecturas, cuando exista; no se exige.
O (Outcomes)	Agentes causales, regiones, síntomas visibles en tallo y métodos de detección.	Técnicas, conjuntos de datos, métricas, plataforma, tipo de inferencia y aspectos de IPO.
S (Study type)	Estudios primarios empíricos revisados por pares.	Estudios primarios empíricos revisados por pares (revistas o congresos).

6. Criterios de elegibilidad (inclusión y exclusión)

Los criterios se definen por separado para cada categoría de estudio:

Categoría	Criterios de inclusión	Criterios de exclusión
Fitopatológica	– CI-F1. Trata sobre aguacate (<i>Persea americana</i>). – CI-F2. Menciona uno de los grupos de patógenos considerados: <i>Phytophthora</i>, <i>Lasiodiplodia</i>, Botryosphaeriaceae, <i>Colletotrichum</i>, <i>Fusarium</i> o <i>Nectria/Rugonectria</i>. – CI-F3. Aporta información sobre el tallo, las ramas o el tronco (síntomas, cancro, muerte descendente, pudrición, marchitez o detección). – CI-F4. Es un estudio primario en español o inglés, publicado entre 2003 y 2026.	– CE-F1. Se enfoca únicamente en raíz, hoja o fruto, sin relación con el tallo. Incluye la pudrición peduncular (<i>stem-end rot</i>), que es una enfermedad del fruto. – CE-F2. Es una revisión, survey, mapping o metaanálisis. – CE-F3. No especifica la especie del patógeno ni el órgano afectado. – CE-F4. Es un registro duplicado. – CE-F5. Está fuera del periodo o del idioma definidos.
Tecnológica	– CI-T1. Aborda la detección, clasificación o diagnóstico de enfermedades de plantas o cultivos. – CI-T2. Usa IA, machine learning, deep learning o visión por computador. – CI-T3. Se relaciona con una aplicación móvil, un dispositivo o un sistema de apoyo, o analiza su viabilidad. – CI-T4. Es un estudio primario en español o inglés, publicado entre 2015 y 2026.	– CE-T1. No usa IA ni métodos de aprendizaje automático. – CE-T2. No aborda enfermedades de plantas (p. ej., madurez, calidad del fruto o estrés hídrico). – CE-T3. Es una revisión o estudio secundario. – CE-T4. Es un duplicado o está fuera del periodo o del idioma definidos.

Nota. Las revisiones identificadas no forman parte de la síntesis, pero pueden citarse en los antecedentes y en la discusión.

7. Fuentes de información

La búsqueda se realizó en Scopus, ScienceDirect y Springer Link, bases a las que se dispone de acceso institucional. El itinerario del proyecto contemplaba además IEEE Xplore y Web of Science, que no pudieron consultarse por falta de acceso; esta limitación se reconocerá en el informe final.

Las cadenas exactas, las fechas de ejecución, los filtros y el número de registros exportados se documentan en la hoja *Cadenas_de_búsqueda* de la matriz de la revisión (*SLR_tallos_aguacate_PLANTILLA_v5.xlsx*), que funciona como bitácora de búsqueda. Todo el material recopilado se conserva en la carpeta *Grupos v2* y se registra en el *Inventario de fuentes*; ninguna otra fuente se utiliza en la revisión.

8. Estrategia de búsqueda

Se utilizaron tres grupos de cadenas, aplicadas sobre título, resumen y palabras clave (Tabla 1):

- **Cadenas fitopatológicas (17 y 18 de septiembre de 2026):** combinan el cultivo (“*Persea americana*” OR avocado) con los grupos de patógenos y con términos relacionados con el

tallo (stem, trunk, canker, dieback, wilt). Incluyen una cadena general por base y una cadena por grupo de patógeno en Scopus (periodo 2003–2026).

- **Cadenas tecnológicas (25 de septiembre de 2026):** combinan el cultivo o las enfermedades de plantas con términos de IA (deep learning, machine learning, computer vision, CNN) y, en su caso, de IPO (usability, user experience, human-computer interaction) (periodo 2015–2026).
- **Cadenas complementarias (1 de octubre de 2026):** se ejecutaron en ScienceDirect para recuperar revisiones sobre agricultura inteligente, detección de enfermedades con aprendizaje profundo y experiencia de usuario. Al ser estudios secundarios, no forman parte del corpus de la síntesis, pero se documentan en el diagrama de flujo y se utilizan como fuentes de los antecedentes y del estado del arte. Son cadenas más cortas porque ScienceDirect limita a ocho el número de operadores booleanos por campo (Yuan et al., 2026).

Tabla 1. Cadenas de búsqueda ejecutadas

N.º	Grupo	Base	Cadena exacta	Fecha	Reg. export.
1	TODOS	Scopus	("Persea americana" OR avocado) AND ("Phytophthora cinnamomi" OR "Lasiodiplodia theobromae" OR "Neofusicoccum parvum" OR Botryosphaeriaceae OR Colletotrichum OR Fusarium OR Nectria OR Rugonectria) AND (stem OR trunk OR canker OR dieback OR "stem-end rot" OR wilt OR disease OR symptom)	2026-09-17	19
2	TODOS	Science Direct	("Persea americana" OR avocado) AND ("Phytophthora" OR Botryosphaeriaceae OR Colletotrichum OR Fusarium OR Nectria OR Rugonectria)	2026-09-18	7
3	TODOS	Springer Link	("Persea americana" OR avocado) AND ("Phytophthora cinnamomi" OR "Lasiodiplodia theobromae" OR "Neofusicoccum parvum" OR Botryosphaeriaceae OR Colletotrichum OR Fusarium OR Nectria OR Rugonectria) AND (stem OR trunk OR canker OR dieback OR "stem-end rot" OR wilt OR disease OR symptom)	2026-09-17	3
4	1. Phytophthora	Scopus	("Persea americana" OR avocado) AND "Phytophthora cinnamomi" AND (root OR stem OR trunk OR wilt OR dieback)	2026-09-18	7
5	2. Lasiodiplodia	Scopus	("Persea americana" OR avocado) AND "Lasiodiplodia theobromae" AND (stem OR trunk OR canker OR "stem-end rot")	2026-09-18	4
6	3. Botryosphaeriaceae	Scopus	("Persea americana" OR avocado) AND ("Neofusicoccum parvum" OR Botryosphaeriaceae) AND (stem OR trunk OR canker OR dieback)	2026-09-18	6
7	4. Colletotrichum	Scopus	("Persea americana" OR avocado) AND ("Colletotrichum acutatum" OR "Colletotrichum gloeosporioides") AND (anthracnose OR stem OR canker)	2026-09-17 / 2026-09-18	4
8	5. Fusarium	Scopus	("Persea americana" OR avocado) AND ("Fusarium solani" OR "Fusarium oxysporum" OR "Fusarium equiseti") AND (wilt OR stem OR trunk OR rot)	2026-09-18	2
9	6. Nectria	Scopus	("Persea americana" OR avocado) AND (Nectria OR "Rugonectria rugulosa") AND (canker OR trunk OR stem)	2026-09-18	4
12	Tecnológica: Aguacate+IA (stem)	Scopus	("Persea americana" OR avocado) AND ("deep learning" OR "machine learning" OR "computer vision" OR CNN OR "image classification") AND (stem OR detection OR classification)	2026-09-25	13
13	Tecnológica: Enfermedad+IA+HCI	Scopus	("plant disease" OR "crop disease" OR "leaf disease") AND ("deep learning" OR "machine learning" OR "computer vision" OR "artificial intelligence") AND (usability OR "user experience" OR UX OR "human-computer interaction" OR HCI OR "user interface" OR "user-centered design")	2026-09-25	incl. en N.º 12

N.º	Grupo	Base	Cadena exacta	Fecha	Reg. export.
14	Tecnológica: Aguacate+IA (disease/pest)	Scopus	(avocado OR "Persea americana") AND ("deep learning" OR "machine learning" OR "computer vision" OR CNN OR "image classification" OR "artificial intelligence") AND (disease OR detection OR classification OR pest)	2026-09-25	incl. en N.º 12
15	Tecnológica: Aguacate+IA+HCI	Springer	("persea americana" OR avocado) AND ("deep learning" OR "machine learning" OR "computer vision") AND (usability OR "user experience" OR "human-computer interaction" OR "user interface")	2026-09-25	1
16	Complementaria: estado del arte	Science Direct	("smart agriculture" OR "smart farming" OR "precision agriculture") AND ("deep learning" OR "computer vision") AND review	2026-10-01	4
17	Complementaria: estado del arte	Science Direct	("plant disease" OR "crop disease") AND ("deep learning" OR CNN) AND (detection OR classification)	2026-10-01	3
18	Complementaria: estado del arte	Science Direct	("mobile application" OR smartphone) AND (agriculture OR farmer*) AND (usability OR "user-centered design" OR "user experience")	2026-10-01	1

Nota. En las cadenas tecnológicas de Scopus, los registros se exportaron de forma conjunta (13 en total). Los totales de resultados (*hits*) de cada base no se registraron en el momento de la búsqueda; por ello, la fase de identificación del diagrama de flujo se basa en los registros exportados, lo que se reconocerá como limitación.

9. Gestión de referencias y deduplicación

Los registros exportados se consolidan en la hoja *Base consolidada* de la matriz, con un identificador único por registro: A0001–A0048 para los fitopatológicos y T0001 en adelante para los tecnológicos, incluidos los registros de las cadenas complementarias. Los PDF se nombran con el mismo identificador y se relacionan en el Inventario de fuentes.

La deduplicación se realiza en dos niveles: al consolidar las exportaciones de una misma base (registros recuperados por más de una cadena) y entre bases, por DOI y título (hoja *Duplicados_y_exclusion*). En esta misma etapa se identifican, por el tipo de documento, los estudios secundarios (revisiones), que se retiran antes del cribado como “registros eliminados por otros motivos”. Todas las cifras se reportan en el diagrama de flujo PRISMA.

10. Selección de estudios

La selección se realiza en dos fases: cribado por título, resumen y palabras clave (hoja *Tamizaje_Tit_Abs_Keys*) y evaluación a texto completo (hoja *Texto_completo*). Cada registro se clasifica como “incluir”, “excluir” o “dudoso”; los dudosos pasan a texto completo para evitar exclusiones prematuras. En cada exclusión se registra el código del criterio aplicado (CE-F o CE-T) y, en la fase de texto completo, el motivo principal de exclusión.

Dado que la revisión es desarrollada por un único revisor principal, la tutora verificará todos los registros clasificados como dudosos y una muestra aleatoria del 10 % de los excluidos en cada fase; las discrepancias se resolverán por consenso.

11. Evaluación de calidad y suficiencia metodológica previa a la extracción (QA)

Los estudios que superan la evaluación a texto completo se evalúan con diez criterios de calidad (Q1–Q10), específicos para cada categoría (Tablas 2 y 3). Cada criterio se puntúa con 0 (no cumple),

1 (cumple parcialmente) o 2 (cumple bien), para un total de 0 a 20 puntos: calidad alta (16–20), media (11–15) o baja (≤ 10).

Tabla 2. Criterios de calidad para estudios fitopatológicos

Código	Criterio
Q1	El objetivo o la pregunta del estudio están claramente definidos.
Q2	Identifica el patógeno a nivel de especie (o al menos de género) de forma clara.
Q3	Describe con claridad la enfermedad y los síntomas en el tallo o tronco.
Q4	Se realiza sobre aguacate o es claramente extrapolable a él.
Q5	La metodología (muestreo, aislamiento, identificación o diagnóstico) está descrita y es replicable.
Q6	Aporta evidencia que respalda las conclusiones (imágenes, mediciones, laboratorio, secuencias).
Q7	Menciona métodos de detección o diagnóstico (visual, molecular, por imagen o IA) útiles para la aplicación.
Q8	Indica el contexto geográfico y las condiciones del estudio.
Q9	Los resultados y conclusiones son claros y coherentes con los datos.
Q10	La fuente es confiable y actual (revisada por pares y dentro del periodo).

Tabla 3. Criterios de calidad para estudios tecnológicos

Código	Criterio
Q1	El objetivo o la pregunta del estudio están claramente definidos.
Q2	Describe con claridad el problema de detección o clasificación.
Q3	Especifica el conjunto de datos (tamaño, número de clases y origen de las imágenes).
Q4	Describe el modelo o la técnica de IA (arquitectura, entrenamiento) de forma replicable.
Q5	Reporta métricas (exactitud, F1, precisión, exhaustividad) con una validación adecuada.
Q6	Compara con modelos base u otros métodos.
Q7	Aborda la implementación en una aplicación móvil o dispositivo, o analiza su viabilidad.
Q8	Considera la IPO, la experiencia de usuario o la usabilidad.
Q9	Los resultados y conclusiones son coherentes y reproducibles.
Q10	La fuente es confiable y actual (revisada por pares y dentro del periodo).

Además de la calidad, se valora la alineación del estudio con el objetivo de la revisión (alta, media o baja). La decisión final aplica la siguiente regla: el estudio se **incluye** en la síntesis si su calidad es alta o media y su alineación es alta o media; en caso contrario, queda en **reserva**, es decir, se cita como antecedente pero no se utiliza en la síntesis. La tutora revisará las valoraciones de los estudios en el límite entre categorías.

12. Extracción de datos

La extracción se realiza en la hoja *Articulos_finales* de la matriz, con un formulario común y campos específicos para cada categoría. La hoja *Articulos_finales_ok* resume los datos en tablas de síntesis. La información ausente se registra como “no reportada”.

- **Campos comunes:** identificador, base de datos, título, año, autores, DOI, tipo de estudio, país, aporte principal, relación con el objetivo, alineación, nivel de calidad y decisión final.
- **Estudios fitopatológicos (RQ1 y RQ2):** grupo de patógeno, especies confirmadas, órgano afectado, enfermedad y síntomas en el tallo, y método de detección o diagnóstico.
- **Estudios tecnológicos (RQ3 y RQ4):** modelo o técnica de IA, conjunto de datos, métricas y resultados, tipo de aplicación o plataforma, tipo de inferencia, funcionamiento sin conexión y principios o evaluación de IPO.

13. Evaluación de calidad metodológica y riesgo de sesgo

La valoración Q1–Q10 se utiliza también para interpretar la solidez de la evidencia. Se prestará especial atención a los siguientes riesgos: en los estudios fitopatológicos, el tamaño de la muestra y la confirmación de la patogenicidad (postulados de Koch); en los tecnológicos, el uso de conjuntos de datos de laboratorio, la ausencia de validación en campo, el riesgo de fuga de información entre los conjuntos de entrenamiento y prueba, y la falta de evaluación con usuarios. En la síntesis se contrastarán los hallazgos de los estudios de calidad alta con los de calidad media.

Se reconocen como limitaciones del proceso: la ejecución por un único revisor principal, la falta de acceso a IEEE Xplore y Web of Science, y la ausencia del registro de los totales de resultados por base.

14. Síntesis de datos

La síntesis será narrativa y estructurada por pregunta de investigación, apoyada en tablas comparativas. Para RQ1 y RQ2 se elaborará una tabla de agentes causales, regiones, síntomas en el tallo y métodos de detección; para RQ3 y RQ4, una tabla de sistemas con su modelo, datos, métricas, plataforma, inferencia e IPO. Se incluirá una descripción de los estudios por año, país, base de datos y categoría.

La RQ5 se responderá integrando ambas categorías: los síntomas visibles del tallo se traducirán en clases candidatas para el diagnóstico por imagen, y las prácticas de los sistemas tecnológicos se traducirán en decisiones de diseño de la aplicación. No se prevé un metaanálisis, dada la heterogeneidad de los estudios.

15. Relación con el caso práctico del proyecto

Los resultados de la revisión alimentarán directamente las siguientes fases del itinerario: el protocolo de construcción del dataset de imágenes de tallos (clases diagnósticas y condiciones de captura), la selección de arquitecturas de IA adecuadas para dispositivos móviles, el análisis de IPO y el diseño de la interfaz, y la implementación del funcionamiento sin conexión.

16. Restricciones de idioma y tipo de publicación

Se incluyen publicaciones en inglés y español, con periodos de 2003–2026 (estudios fitopatológicos) y 2015–2026 (estudios tecnológicos). Solo se incluyen estudios primarios revisados por pares; se excluyen revisiones, tesis, capítulos de libro, preprints y publicaciones no arbitradas. La restricción de idioma se reconocerá como limitación.

17. Consideraciones éticas

La revisión utiliza exclusivamente literatura publicada y no implica participantes ni datos personales, por lo que no requiere aprobación ética. Las fases posteriores del proyecto (captura de imágenes en fincas o viveros y pruebas con usuarios) requerirán la autorización de los propietarios de los predios y el consentimiento informado de los participantes.

18. Enmiendas al protocolo

Toda modificación del protocolo se documentará en el registro de correcciones con número de versión, fecha, descripción, justificación e impacto metodológico. La versión 2 ajustó las fuentes de información a las bases efectivamente consultadas, documentó las cadenas ejecutadas entre el 17 y el 25 de septiembre de 2026 e integró en una única revisión las categorías fitopatológica y tecnológica. La versión 3 introduce tres cambios: (a) incorpora las cadenas complementarias del 1 de octubre de 2026; (b) limita todas las referencias a las fuentes recopiladas en la carpeta Grupos v2, de modo que las guías metodológicas se mencionan mediante cita secundaria; y (c) actualiza la organización de los archivos según las actividades del itinerario.

19. Registro, versiones y trazabilidad

El protocolo cuenta con control de versiones; la versión aprobada por la tutora será la versión congelada. Los materiales se organizan según las actividades del itinerario:

- **Grupos v2/Todos:** exportaciones de cada base y textos completos (material del autor; única fuente permitida).
- **SLR_SmartAgriculture/00_Planificacion:** planificación del itinerario, Inventario de fuentes y registro de correcciones.
- **01_Induccion (Act. 1):** protocolo y fundamentos. **02_Estado_del_arte (Act. 2).** **03_Matriz_SLR (Act. 3 a 6):** matriz SLR_tallos_aguacate_PLANTILLA_v5.xlsx, que se completa paso a paso.
- **04_PRISMA (Act. 7), 05_Redaccion_SLR (Act. 8), 06_Revision (Act. 9) y _historial** (versiones anteriores).

20. Plan de difusión

Los resultados se integrarán en el borrador de la revisión sistemática, que será revisado por la tutora, y en el informe técnico final de las prácticas. Si la tutora lo considera pertinente, servirán de base para un artículo científico.

21. Equipo revisor y responsabilidades

La revisión es desarrollada por un revisor principal, Ariel Llumiquinga, responsable de la búsqueda, el cribado, la evaluación de calidad, la extracción y la síntesis. La tutora, Ing. Doris Chicaiza, actúa como segunda instancia metodológica: valida el protocolo, verifica los registros dudosos y una muestra de los excluidos, y revisa las valoraciones de calidad en el límite entre categorías. La realización por un único revisor se reconocerá como limitación.

22. Herramientas y soporte operativo

Se utilizan Scopus, ScienceDirect y Springer Link para la búsqueda; Microsoft Excel para la matriz de la revisión; un gestor bibliográfico (Zotero o Mendeley) para las referencias en formato APA 7.^a edición; y el diagrama de flujo de la declaración PRISMA para reportar la selección de estudios.

Referencias

Todas las referencias corresponden a fuentes recopiladas por el autor en la carpeta Grupos v2.

- Arjona-Girona, I., Ruano-Rosa, D., & López-Herrera, C. J. (2019). Identification, pathogenicity and distribution of the causal agents of dieback in avocado orchards in Spain. *Spanish Journal of Agricultural Research*, 17(1), e1003. <https://doi.org/10.5424/sjar/2019171-13561>
- Crespo, M., Guirado-Manzano, L., Sarmiento, D., Guirado, E., de Vicente, A., Fernández-Ortuño, D., Cazorla, F. M., & Arrebola, E. (2026). Fungal species of Botryosphaeriaceae associated with avocado dieback in southern Spain. *Plant Pathology*. <https://doi.org/10.1111/ppa.70079>
- Lin, X., Chen, S., Yan, N., Pi, J., Zhu, T., & Xu, L. (2026). Knowledge distillation for smart agriculture: Methods, applications, and future directions. *Smart Agricultural Technology*, 14, 102019. <https://doi.org/10.1016/j.atech.2026.102019>
- Majdalawieh, M., Martins, C., Radi, M., Alaraj, M., & Khan, S. (2025). Precision agriculture in the age of AI: A systematic review of machine learning methods for crop disease detection. *Smart Agricultural Technology*, 12, 101491. <https://doi.org/10.1016/j.atech.2025.101491>
- Martinelli, S., Lopes, L., & Zaina, L. (2024). UX research practices related to long-term UX: A systematic literature review. *Information and Software Technology*, 170, 107431. <https://doi.org/10.1016/j.infsof.2024.107431>
- Möller, H., Slippers, B., & van den Berg, N. (2025). Branch canker battles: Understanding and managing the Botryosphaeriaceae in avocado. *Phytoparasitica*. <https://doi.org/10.1007/s12600-024-01227-6>
- Moreano, M., Sosa, A., Mauricio, D., Rivera, L., & Santisteban, J. (2026). ApaltAI: A web-based diagnostic system with a sequential voting architecture for detecting anthracnose and scab in avocado fruit. *Frontiers in Plant Science*, 17, 1736123. <https://doi.org/10.3389/fpls.2026.1736123>
- Munjal, D., Singh, L., Pandey, M., & Lakra, S. (2023). A systematic review on the detection and classification of plant diseases using machine learning. *International Journal of Software Innovation*. <https://doi.org/10.4018/ijsi.315657>
- Odounfa, M. G. F., Gbemavo, C. D. S. J., Tahi, S. P. G., & Glèlè Kakaï, R. L. (2024). Deep learning methods for enhanced stress and pest management in market garden crops: A comprehensive analysis. *Smart Agricultural Technology*, 9, 100521. <https://doi.org/10.1016/j.atech.2024.100521>
- Saini, Y., Somani, V., & Khatri, N. (2026). Critical analysis of advanced machine learning and deep learning models for crop disease detection: Challenges, innovations, and future directions. *Franklin Open*, 15, 100584. <https://doi.org/10.1016/j.fraope.2026.100584>
- Sajitha, P., Andrushia, A. D., Anand, N., & Naser, M. Z. (2024). A review on machine learning and deep learning image-based plant disease classification for industrial farming systems. *Journal of Industrial Information Integration*, 38, 100572. <https://doi.org/10.1016/j.jii.2024.100572>

- Vecchio, L., Martino, I., Guarnaccia, V., Polizzi, G., & Aiello, D. (2026). Colletotrichum perseae and Colletotrichum gloeosporioides sensu stricto causing stem lesion and dieback in avocado in Italy. *Horticulturae*, 12(1), 111. <https://doi.org/10.3390/horticulturae12010111>
- Yuan, L., Li, W., Yue, J., Li, Z., Zhao, Y., Li, Q., Feng, W., & Kou, G. (2026). A review of cattle behavior recognition methods based on computer vision and deep learning. *Smart Agricultural Technology*, 14, 101867. <https://doi.org/10.1016/j.atech.2026.101867>