

Prácticas preprofesionales – Departamento de Ciencias de la Computación
Universidad de las Fuerzas Armadas ESPE

Autor/a: Ariel Llumiquinga

Tutora: Ing. Doris Chicaiza

Proyecto: Smart Agriculture

Actividad del itinerario: 2. Desarrollo del estado del arte (tareas T03–T06)

Versión: 2

Fecha: 1 de octubre de 2026.

Estado: Borrador para revisión de la tutora.

Estado del arte: inteligencia artificial, interacción persona-ordenador y enfermedades del tallo del aguacate (*Persea americana*) como base para una aplicación móvil de diagnóstico

Nota. Este documento utiliza exclusivamente fuentes recopiladas por el autor en la carpeta Grupos v2 (revisiones y estudios primarios de Scopus, ScienceDirect y Springer Link). Los estudios primarios citados aquí se evaluarán formalmente en las Actividades 3 a 6 de la revisión sistemática; en este documento se usan solo para describir el estado del conocimiento. La correspondencia entre cada referencia y su identificador en la matriz se presenta en el Anexo A.

1. Introducción

Las plagas y enfermedades causan, en conjunto, cerca del 30 % de las pérdidas mundiales de cultivos, y su identificación tradicional depende de la experiencia humana, lo que la vuelve lenta, costosa y a menudo imprecisa (Majdalawieh et al., 2025). En la práctica, los agricultores vigilan las plantas enfermas de forma manual y a simple vista (Sajitha et al., 2024), y la inspección visual de hojas, tallos y frutos depende de la pericia de cada persona, por lo que está expuesta a errores y juicios subjetivos (Odounfa et al., 2024). La agricultura de precisión y la inteligencia artificial (IA) ofrecen una alternativa: la visión por computador y el aprendizaje profundo permiten reconocer síntomas en imágenes, y los teléfonos inteligentes acercan ese diagnóstico al lugar donde se cultiva (Saini et al., 2026).

El aguacate es un cultivo de gran importancia económica; México, Colombia, Perú y la República Dominicana reunieron cerca del 58 % de la producción mundial en la temporada 2022 (Möller et al., 2025). Las mismas condiciones cálidas que favorecen al cultivo favorecen también a los hongos patógenos, en especial a los de la familia Botryosphaeriaceae, que causan canchros en ramas, muerte descendente y pudriciones del fruto (Möller et al., 2025). El diagnóstico de estas enfermedades se basa tradicionalmente en los síntomas observados en campo (Silva et al., 2025) y su confirmación requiere aislamiento en laboratorio e identificación molecular, un proceso que puede tardar semanas (Möller et al., 2025).

El proyecto Smart Agriculture busca desarrollar una aplicación móvil con IA para diagnosticar enfermedades y alteraciones visibles en el **tallo** del aguacate; el fruto y las hojas corresponden a proyectos de otros grupos. Este documento desarrolla la Actividad 2 del itinerario (tareas T03 a T06) y organiza el estado del arte en ocho apartados: la IA en aplicaciones móviles (2.1), la interacción persona-ordenador (IPO) (2.2), su integración (2.3), las aplicaciones inteligentes en agricultura (2.4), la IA para identificar enfermedades vegetales (2.5), las enfermedades del aguacate con énfasis en el

tallo (2.6), las revisiones previas (2.7) y una síntesis de brechas (2.8) vinculada con las preguntas de investigación (RQ1–RQ5) del protocolo v3.

Las fuentes provienen de la carpeta Grupos v2: ocho revisiones (seis de las recuperadas con las cadenas complementarias de ScienceDirect C16 a C18 el 01/10/2026, más las de Munjal et al., 2023, y Möller et al., 2025) y los estudios primarios fitopatológicos y tecnológicos recopilados para la revisión sistemática. Las tablas son de elaboración propia y comparan las fuentes entre sí; cada una indica su origen en una nota.

2. Estado del arte / Trabajos relacionados

Este apartado avanza de lo general a lo específico: primero describe cómo se llevan los modelos de IA al teléfono y cómo se diseñan pensando en sus usuarios; luego, qué se ha logrado en la agricultura y en el diagnóstico de enfermedades vegetales; y finalmente, qué se sabe de las enfermedades del tallo del aguacate y qué implica esto para un diagnóstico basado en fotografías.

2.1 Inteligencia artificial en aplicaciones móviles inteligentes

Una aplicación móvil inteligente ejecuta, o consulta, un modelo de IA para interpretar los datos que captura el teléfono; en el diagnóstico de enfermedades, ese dato es una fotografía. El obstáculo principal es que los modelos de aprendizaje profundo son pesados, mientras que los dispositivos usados en el campo —teléfonos, drones o sistemas embebidos— tienen recursos de cómputo limitados (Lin et al., 2026). Para reducir el tamaño de los modelos se emplean la poda, la cuantización, la factorización de bajo rango, el uso compartido de pesos, las arquitecturas compactas, la búsqueda de arquitecturas neuronales y la destilación de conocimiento (Lin et al., 2026). Entre las arquitecturas compactas destaca MobileNet, diseñada para dispositivos móviles mediante convoluciones separables en profundidad (Saini et al., 2026).

El modelo puede ejecutarse en el propio teléfono (en el borde), en la nube o de forma híbrida. Según Saini et al. (2026), la ejecución en el borde evita depender de Internet y permite la inferencia en tiempo real: variantes de MobileNet-V3 y EfficientNet-Lite mantienen tiempos de 90 a 150 ms por imagen en procesadores móviles de gama media, con 88–93 % de exactitud en las clases de enfermedad más frecuentes. El esquema híbrido reduce el uso de ancho de banda en cerca de un 70 % y suele apoyarse en TensorFlow Lite y ONNX Runtime (Saini et al., 2026). Estas configuraciones se describieron en el documento de Fundamentos de la Actividad 1; aquí interesa su relación con las condiciones reales de uso, que se comparan en la Tabla 1.

Tabla 1. Barreras para usar modelos de IA en el teléfono en condiciones de campo y estrategias reportadas

Barrera	Efecto reportado	Estrategia reportada	Fuentes
Conectividad a Internet inestable	Interrumpe el monitoreo; las apps que dependen del servidor no funcionan en zonas sin cobertura.	Inferencia en el borde, capaz de operar sin conexión.	Kochhar et al. (2026); Saini et al. (2026)
Recursos de cómputo limitados	Latencia y dificultad para ejecutar modelos grandes en el dispositivo.	Compresión (poda, cuantización, destilación) y arquitecturas ligeras como MobileNet.	Lin et al. (2026); Saini et al. (2026)

Barrera	Efecto reportado	Estrategia reportada	Fuentes
Costo del equipo y poca formación técnica	Limita el acceso y puede llevar a un uso inadecuado.	Modelos de bajo costo con imágenes RGB; interfaces sencillas.	Majdalawieh et al. (2025); Saini et al. (2026); Kochhar et al. (2026)
Condiciones adversas de campo	Cambios de clima e iluminación reducen la exactitud y la calidad de la imagen.	Ajuste fino con imágenes locales, aumento de datos y adaptación de dominio.	Saini et al. (2026)
Degradación del modelo con el tiempo	Pérdida de 5–12 % de exactitud en 6–9 meses sin reentrenamiento.	Reentrenamiento periódico; guardar las predicciones con probabilidad menor a 0,55 para revisión experta.	Saini et al. (2026)

Nota. Elaboración propia a partir de Kochhar et al. (2026), Lin et al. (2026), Majdalawieh et al. (2025) y Saini et al. (2026).

A pesar de estos avances, varias revisiones coinciden en que existen pocas aplicaciones web o móviles de diagnóstico disponibles y en que los modelos precisos de la literatura todavía deben probarse en aplicaciones móviles en tiempo real y en campo abierto (Munjal et al., 2023; Sajitha et al., 2024). Para el proyecto, esto significa que la inferencia en el teléfono, sin conexión, es un requisito y no un detalle técnico (Actividades 19 y 20 del itinerario).

2.2 Interacción persona-ordenador (IPO) en aplicaciones inteligentes

La IPO se ocupa de que un sistema sea útil y comprensible para quienes lo usan. La experiencia de usuario (UX) abarca todos los aspectos de la interacción de una persona con un producto, y sus prácticas exigen un diseño centrado en el usuario, que integra en el desarrollo la investigación con usuarios, el prototipado y las pruebas de usabilidad (Martinelli et al., 2024). En una revisión sistemática de 45 artículos, Martinelli et al. (2024) identificaron 38 prácticas de investigación de UX y 52 métodos, técnicas y herramientas; los más usados en la industria son las personas (perfiles de usuario), las entrevistas, las encuestas y las pruebas de usabilidad, mientras que los métodos de campo —indagación contextual, estudios de campo y etnografía— se usan menos, aunque son los que permiten conocer los hábitos, necesidades y motivaciones de los usuarios.

La misma revisión destaca que la experiencia cambia con el tiempo y distingue cuatro momentos de la UX a largo plazo (Martinelli et al., 2024), que se comparan en la Tabla 2 junto con su posible uso en este proyecto.

Tabla 2. *Métodos de investigación de UX según el momento de la experiencia y su posible uso en el proyecto*

Momento de la UX	Qué se busca conocer	Métodos reportados	Posible uso en el proyecto
Anticipada	Expectativas del usuario antes del primer uso.	Entrevistas, grupos focales y analítica de comportamiento.	Entrevistas a agricultores y técnicos antes de prototipar (Act. 16).
Momentánea	Percepciones durante la interacción, en el momento en que ocurren.	Evaluación heurística, pensamiento en voz alta, indagación contextual, pruebas A/B y estudios de campo.	Pruebas del prototipo de captura y resultado en el huerto (Act. 17 y 21).
Episódica	Valoración de un episodio de uso concreto.	Analítica de comportamiento, AttrakDiff, iScale y análisis de métricas.	Evaluación al terminar sesiones de diagnóstico (Act. 21).

Momento de la UX	Qué se busca conocer	Métodos reportados	Posible uso en el proyecto
Acumulada	Experiencia después de un tiempo de uso.	Pruebas de usabilidad, análisis de publicaciones de usuarios y de métricas.	Seguimiento del uso durante la temporada (después de la Act. 22).

Nota. Elaboración propia a partir de Martinelli et al. (2024). La última columna es una propuesta del autor para el itinerario.

En el ámbito agrícola, las fuentes recopiladas subrayan rasgos propios de los usuarios. Christakakis et al. (2024) incorporaron a agricultores como usuarios finales para que la aplicación fuera accesible a personas sin habilidades avanzadas en tecnologías de la información; Kochhar et al. (2026) organizaron el desarrollo en análisis de las necesidades de los agricultores, diseño de una interfaz sencilla con cámara integrada y pruebas continuas; y Odounfa et al. (2024) señalan como prioridad crear aplicaciones fáciles de usar y en idiomas locales para agricultores rurales con poca experiencia tecnológica. Las fuentes de IPO del material recopilado son escasas, una limitación que ya se advirtió en la Actividad 1.

2.3 Integración IA–IPO

Integrar IA e IPO significa diseñar no solo un modelo exacto, sino una interacción en la que el usuario capture bien la imagen, entienda el resultado y sepa cuándo confiar en él. Lin et al. (2026) advierten que la mayoría de los modelos obtenidos por destilación son opacos y que esta brecha de interpretabilidad limita la confianza de agricultores y agrónomos que deben decidir a partir de sus resultados; por ello proponen explicaciones en lenguaje natural ligadas a rasgos observables de la planta. Saini et al. (2026) describen otra forma de integración: guardar para revisión experta las predicciones con baja confianza, lo que mantiene a una persona en el ciclo de decisión y permite actualizar el modelo.

La calidad de la fotografía es también un problema de interacción. Las imágenes tomadas en campo cambian con la humedad, el ambiente y la intensidad de la luz, por lo que conviene capturar la misma muestra en distintos momentos, ángulos y condiciones (Sajitha et al., 2024); Majdalawieh et al. (2025) recomiendan además imágenes de alta resolución (≥ 12 MP), con iluminación controlada o carpas de luz portátiles, desde varios ángulos y con metadatos de contexto. Una pantalla de captura guiada puede trasladar estas recomendaciones al usuario. La Tabla 3 compara cómo los sistemas con aplicación recopilados resolvieron la relación entre el modelo y el usuario.

Tabla 3. Elementos de integración IA–IPO en los sistemas de diagnóstico con aplicación recopilados

Sistema	Resultado que ve el usuario	Explicación o confianza	Participación de usuarios	Limitación o dependencia
Ramana Reddy et al. (2025)	Enfermedad, puntaje de confianza, porcentaje de severidad y breve descripción.	Mapa Grad-CAM y puntaje de confianza.	Pruebas informales: interfaz intuitiva; la severidad ayuda a priorizar.	Inferencia en servidor (Wi-Fi); la inferencia sin conexión queda como trabajo futuro.
Christakakis et al. (2024)	Zonas afectadas marcadas con cajas y nivel de confianza.	Confianza por detección.	50 usuarios (20 agrónomos y 30 agricultores) en campo y cuestionario de experiencia; alta satisfacción.	Modelos en un sistema de apoyo a la decisión en el servidor.

Sistema	Resultado que ve el usuario	Explicación o confianza	Participación de usuarios	Limitación o dependencia
Kochhar et al. (2026)	Enfermedad según el cultivo que elige el usuario.	Grad-CAM para verificar que el modelo mira la lesión.	Diseño centrado en el usuario (análisis de necesidades, interfaz sencilla y pruebas).	Depende de Internet estable y de cobertura celular.
Moreano et al. (2026)	Diagnóstico y módulos de gestión del cultivo y análisis fitosanitario (web).	No se reporta.	Interfaz para usuarios no técnicos; pruebas de aceptación con agricultores pendientes.	Dataset pequeño (674 imágenes) sin coinfecciones ni síntomas muy tempranos.

Nota. Elaboración propia a partir de Christakakis et al. (2024), Kochhar et al. (2026), Moreano et al. (2026) y Ramana Reddy et al. (2025).

La comparación muestra que solo un sistema evaluó formalmente la experiencia de usuarios reales y que ninguno reporta inferencia sin conexión ya implementada. La explicación visual (Grad-CAM) y el puntaje de confianza aparecen como recursos para hacer comprensible el diagnóstico.

2.4 Aplicaciones inteligentes en agricultura

La agricultura de precisión adapta las intervenciones a las condiciones de cada campo o sección de campo mediante teledetección, sistemas de información geográfica y aprendizaje automático (Majdalawieh et al., 2025). Sus herramientas incluyen sensores multiespectrales e hiperespectrales, cámaras RGB-D, vehículos aéreos no tripulados (UAV), robots e Internet de las cosas (Odounfa et al., 2024), integrados con IA para la detección de malezas, plagas y enfermedades (Sajitha et al., 2024). Saini et al. (2026) reportan que, en fincas de 50 a 500 hectáreas, la analítica en la nube unida a telemetría y alertas mejoró entre un 18 y un 25 % la programación de aplicaciones dirigidas de plaguicidas.

Respecto al tipo de imagen, Majdalawieh et al. (2025) encontraron que los modelos con imágenes RGB alcanzaron una exactitud media de 96,94 %, frente a 95,81 % con imágenes hiperespectrales o multiespectrales, que además son más costosas y exigen más cómputo; por ello, las imágenes RGB —como las de la cámara de un teléfono— son la opción preferida para aplicaciones a gran escala.

En el aguacate, la IA recopilada se ha aplicado sobre todo al fruto y a las hojas (Tabla 4). Destaca el caso de Guelac-Santillan et al. (2026), en Amazonas (Perú): los índices de vegetación obtenidos con un UAV describieron la variabilidad del dosel, pero ninguno se correlacionó significativamente con la incidencia de antracnosis foliar, por lo que los autores concluyen que, por sí solos, tienen una capacidad limitada para detectar la enfermedad.

Tabla 4. Trabajos de IA y teledetección aplicados al aguacate en el material recopilado

Estudio	Órgano	Tarea	Datos y técnica	Resultado reportado
Moreano et al. (2026)	Fruto	Diagnóstico de antracnosis y roña	674 imágenes; ensamble de cinco modelos de aprendizaje profundo en votación secuencial; aplicación web	Exactitud 99,03 %
Estrada et al. (2026)	Hoja	Estado de deshidratación (estrés hídrico)	Imágenes multiespectrales; ResNet18, MobileNetV3 y ConvNeXt-Tiny	Exactitud 0,99 (ResNet18)

Estudio	Órgano	Tarea	Datos y técnica	Resultado reportado
Xavier et al. (2024)	Fruto	Etapas de maduración y vida útil	Fotografías diarias de 478 frutos; AlexNet y ResNet-18 con transferencia	Exactitud 88,8 %
Ovalle et al. (2026)	Fruto	Madurez	Espectroscopía NIR; ensambles de aprendizaje automático	AUC 0,931
Ahmed et al. (2026)	Fruto	Maduración con etiquetas ruidosas	Imágenes de microondas y fotográficas; función de pérdida híbrida	Mejora significativa frente a funciones de referencia
Vera et al. (2024)	Fruto	Clasificación agroindustrial	346 imágenes de entrenamiento y 146 de prueba; DenseNet, ResNet50 y EfficientNet B4	F1 99,27 % (DenseNet)
Guelac-Santillan et al. (2026)	Hoja (dosel)	Severidad de antracnosis	Índices de vegetación desde UAV, sin modelo de IA	Sin correlación significativa ($p > 0,05$)

Nota. Elaboración propia a partir de los estudios citados. Ninguno de los trabajos recopilados aborda el tallo, las ramas o el tronco.

2.5 Inteligencia artificial para la identificación de enfermedades vegetales

2.5.1 Fundamentos: redes neuronales convolucionales y aprendizaje por transferencia

Las redes neuronales convolucionales (CNN) son el método de aprendizaje profundo más adoptado para detectar enfermedades de cultivos; procesan la imagen mediante capas convolucionales, de agrupamiento y totalmente conectadas, y entre las arquitecturas preentrenadas más usadas están VGG-Net, ResNet, MobileNet, Inception y DenseNet (Saini et al., 2026). En 150 estudios, Majdalawieh et al. (2025) contaron 49 que usaron CNN, 19 con aprendizaje automático clásico (SVM, KNN), 9 con Vision Transformers y 2 con modelos híbridos; los modelos profundos superaron a los clásicos porque estos dependen de descriptores diseñados a mano, y las CNN con aprendizaje por transferencia ofrecieron el mejor equilibrio entre desempeño y costo.

El aprendizaje por transferencia reutiliza modelos preentrenados para lograr una detección precisa con menos imágenes (Sajitha et al., 2024). El aumento de datos es casi una práctica estándar: 42 de los 72 estudios analizados por Odounfa et al. (2024) aplicaron transformaciones geométricas, de color o filtros. Los mismos autores observaron que no todos los modelos más usados son los de mejor desempeño, lo que aconseja comparar varias arquitecturas antes de elegir una.

La tarea también importa. La clasificación asigna una etiqueta a toda la imagen; la detección localiza los síntomas con cajas; y la segmentación delimita la lesión píxel a píxel. Odounfa et al. (2024) explican que, si una lesión está orientada en diagonal, la caja incluye áreas sanas, mientras que la segmentación se ajusta a su forma, aunque su anotación es más lenta y costosa. Esta observación es relevante para el tallo, donde las lesiones suelen ser alargadas.

2.5.2 Conjuntos de datos y brecha entre laboratorio y campo

Los conjuntos de datos determinan el desempeño de los modelos. La Tabla 5 compara los conjuntos públicos más citados en las fuentes recopiladas.

Tabla 5. Conjuntos de datos de enfermedades vegetales citados en las revisiones recopiladas

Conjunto	Imágenes	Clases	Condiciones de captura	Observaciones
PlantVillage	54 309	38	Laboratorio, fondos uniformes	El más usado (36 de 150 estudios); riesgo de sobreajuste a condiciones controladas.
PlantDoc	2 598	17 (13 especies)	Entornos reales (imágenes reunidas de Internet)	Más diverso, pero con algunas enfermedades mal clasificadas.
PDD271	220 592	271	Campo (frutales, hortalizas y cultivos extensivos)	Desbalance: las 20 clases principales reúnen más del 50 % de las imágenes.
CCMT	102 976	22	Marañón, yuca, maíz y tomate	Orientado a aplicaciones de reconocimiento y detección.
Plant Pathology 2021-FGVC8	18 632	5 tipos de enfermedad	No se detalla	Listado entre los conjuntos públicos de la revisión sobre destilación.
Conjuntos propios de campo	Variable	Variable	Campo, protocolos propios	Predominan en los estudios recientes, pero su alcance limitado dificulta la reproducibilidad y la comparación.

Nota. Elaboración propia a partir de Lin et al. (2026), Majdalawieh et al. (2025), Odounfa et al. (2024), Saini et al. (2026) y Sajitha et al. (2024). Ninguno de los conjuntos incluye imágenes de tallos de aguacate.

El problema central es la brecha entre laboratorio y campo. Las CNN entrenadas con PlantVillage suelen superar el 98 % de exactitud en validación, pero bajan a 70–80 % con imágenes de campo por el fondo, los cambios de iluminación, la oclusión y el clima (Saini et al., 2026). En la destilación de conocimiento ocurre lo mismo: la clasificación en laboratorio está cerca de la saturación, pero la retención de desempeño cae, a menudo por debajo del 85 %, al pasar a datos de campo (Lin et al., 2026). Majdalawieh et al. (2025) añaden que el tamaño del conjunto no se correlaciona significativamente con la exactitud, porque la calidad, la anotación y la diversidad pesan tanto como la cantidad.

Las fuentes recopiladas describen además otros sesgos y problemas de los datos:

- **Sesgo geográfico y de cultivos.** India (30 estudios) y China (15) concentran el origen de los datos, y el tomate (31 estudios) y el arroz (18) dominan la investigación (Majdalawieh et al., 2025); en hortalizas, India y China suman el 27,27 % y el 19,70 % de los estudios (Odounfa et al., 2024).
- **Calidad de las etiquetas.** Un 5 % de imágenes mal etiquetadas puede reducir la exactitud entre 3 y 6 % y aumentar la confusión entre enfermedades parecidas (Saini et al., 2026).
- **Desbalance de clases.** Los modelos entrenados con clases desbalanceadas muestran diferencias de 8 a 15 puntos porcentuales de F1 entre las clases mayoritarias y las minoritarias (Saini et al., 2026).
- **Falta de metadatos.** Muchos conjuntos solo traen la etiqueta, sin variedad, etapa de la enfermedad, georreferencia ni condiciones ambientales (Saini et al., 2026).

Como respuesta, se recomienda combinar conjuntos públicos con imágenes propias de campo (Lin et al., 2026), ajustar el modelo con imágenes locales (Saini et al., 2026) y seguir

protocolos de etiquetado claros, con consenso de varios expertos y un acuerdo entre anotadores medido con kappa de Cohen $\geq 0,80$ (Majdalawieh et al., 2025).

2.5.3 Evaluación de los modelos y métricas

La elección de la métrica depende de la tarea. La Tabla 6 resume las métricas descritas en las fuentes recopiladas. Entre 72 estudios, las más usadas fueron la exactitud (47 veces), la precisión (37), la exhaustividad (30) y F1 (26) (Odounfa et al., 2024).

Tabla 6. Métricas de evaluación de modelos de diagnóstico según la tarea

Métrica	Qué mide	Tarea en que se usa	Valores de referencia reportados
Exactitud (accuracy)	Proporción de predicciones correctas sobre el total.	Clasificación	CNN: 85–99 % en conjuntos limpios y bien etiquetados (Saini et al., 2026).
Precisión y exhaustividad (recall)	Precisión: aciertos entre los casos predichos como positivos. Exhaustividad: positivos reales que el modelo encuentra.	Clasificación y detección	Detección con YOLO o R-CNN: precisión y exhaustividad > 0,80 (Odounfa et al., 2024).
F1	Media armónica de precisión y exhaustividad; útil cuando importan los falsos positivos y los falsos negativos.	Clasificación	CNN en hortalizas: 0,85–0,92 (Odounfa et al., 2024).
AUC-ROC	Área bajo la curva de tasa de verdaderos frente a falsos positivos.	Clasificación	Reportada en algunos estudios (Saini et al., 2026).
mAP	Precisión media de la detección con cajas.	Detección	mAP50 70,2 % en una app de campo (Christakakis et al., 2024).
IoU / mIoU	Superposición entre la región predicha y la real.	Segmentación y severidad	IoU 0,75–0,85 (Odounfa et al., 2024).

Nota. Elaboración propia a partir de Christakakis et al. (2024), Odounfa et al. (2024) y Saini et al. (2026).

Tres hallazgos matizan los valores altos de exactitud. Primero, en 150 estudios la exactitud media para enfermedades fúngicas (88,85 %, DE 22,92) fue menor que para las bacterianas (91,39 %) y las virales (94,16 %) (Majdalawieh et al., 2025), y las enfermedades del tallo del aguacate son causadas sobre todo por hongos y oomicetos. Segundo, la confianza media del modelo ante síntomas tempranos (0,52–0,68) es menor que ante síntomas maduros ($\geq 0,85$) (Saini et al., 2026). Tercero, la exactitud obtenida sobre un conjunto curado es una prueba de concepto y debe validarse con imágenes de campo recogidas de forma prospectiva (Moreano et al., 2026). Por ello, la evaluación del modelo del proyecto deberá reportar varias métricas por clase y probarse con imágenes de campo nuevas (Actividades 15 y 22).

2.5.4 Sistemas móviles de diagnóstico

La Tabla 7 compara los sistemas de diagnóstico con aplicación, o que proponen una, recopilados para la revisión.

Tabla 7. *Sistemas de diagnóstico de enfermedades con aplicación en el material recopilado*

Sistema	Cultivo y órgano	Datos y modelo	Plataforma e inferencia	Resultado reportado
Moreano et al. (2026)	Aguacate; fruto (antracnosis y roña)	674 imágenes; ensamble de cinco modelos en dos etapas	Web para móvil y escritorio; servidor	Exactitud 99,03 %
Ramana Reddy et al. (2025)	Varios cultivos; hoja	PlantVillage; CNN propia y severidad con OpenCV	React Native; servidor Flask; ~2 s por imagen	Exactitud 92,06 %
Christakakis et al. (2024)	Tomate; hoja (plaga <i>Tuta absoluta</i>)	Imágenes de enfermedades e insectos; YOLOv8	iOS y Android; sistema de apoyo en servidor	mAP50 70,2 %
Kochhar et al. (2026)	Trigo, arroz, forraje, maíz y caña; hoja (19 enfermedades)	Imágenes de campo y públicas; CNN y VGG-16	Android de tres capas; servidor	Exactitud de 44,15 % (arroz) a 95,23 % (maíz)
Iqbal et al. (2026)	Trigo y guisante; hoja	Conjunto propio de campos de Pakistán; VGG16, DETR, CNN, YOLO y RF	Propone una app móvil; YOLO y DETR para tiempo real	Exactitud 98 % (VGG16) frente a 80–96 % de los demás

Nota. Elaboración propia a partir de los estudios citados. El primer autor de Iqbal et al. (2026) es Iqbal, aunque Scopus lo registra como Ahmed.

Los sistemas recopilados comparten tres rasgos: trabajan con hojas o frutos, los que tienen aplicación procesan la imagen en un servidor y se evaluaron sobre todo con métricas del modelo. La amplitud de resultados de Kochhar et al. (2026), de 44 a 95 % según el cultivo, muestra que el mismo enfoque puede rendir muy distinto en otro conjunto de datos, algo que debe considerarse al trasladarlo a un órgano nuevo como el tallo.

2.6 Enfermedades y alteraciones en el aguacate

2.6.1 Hojas, frutos y raíz (contexto)

Estos órganos se describen solo para delimitar el alcance, ya que corresponden a otros proyectos. En el **fruto**, la antracnosis causada por especies de *Colletotrichum* es una de las principales enfermedades de poscosecha: en México se obtuvieron 232 aislamientos en seis regiones productoras y *C. siamense* fue la especie más frecuente (Fuentes-Aragón et al., 2020); en el sureste de Brasil, *C. siamense* es también el agente principal (Soares et al., 2021), y en Chile se registró por primera vez *C. anthrisci* (Bustamante et al., 2022). La pudrición peduncular (*stem-end rot*) es una enfermedad del **fruto** que comienza en la inserción del pedúnculo (Möller et al., 2025); en huertos de Chile, los picos de esporas se asociaron a las lluvias y la alta humedad, y la pudrición peduncular alcanzó una incidencia del 44 % en el huerto más afectado (Tapia et al., 2025). Además, en cultivares de piel oscura como Hass es difícil detectar los síntomas del fruto (Vecchio, Martino, et al., 2026).

En las **hojas** se describen necrosis pardas que avanzan desde el margen del ápice y manchas de antracnosis (Linaldeddu et al., 2026), así como defoliación por *Neofusicoccum parvum*, *C. gloeosporioides* y *Neopestalotiopsis rosae* en inoculaciones (Çalış et al., 2024). En la **raíz**, la pudrición por *Phytophthora cinnamomi* ataca las raíces absorbentes y conduce a la muerte descendente y a la muerte del árbol, y el encharcamiento la agrava (Reeksting et al., 2014); la raíz afectada muestra una necrosis oscura en forma de "cola de rata", y la copa, síntomas inespecíficos como clorosis, enanismo o muerte súbita (Linaldeddu et al., 2026).

2.6.2 Tallos, ramas y tronco (núcleo del proyecto)

Las enfermedades de la madera del aguacate forman un complejo con varios agentes. El grupo más estudiado es la familia Botryosphaeriaceae, con más de 220 especies en 24 géneros, de los cuales *Neofusicoccum* es el más frecuente y diverso en el aguacate (Möller et al., 2025). Estos hongos pueden vivir como endófitos sin causar síntomas y volverse patógenos cuando el árbol sufre estrés por sequía, deficiencia de nutrientes o heridas (Möller et al., 2025), y es común aislar varias especies a la vez del mismo tejido (Linaldeddu et al., 2026; Möller et al., 2025).

Los reportes regionales muestran la magnitud del problema:

- **España.** En Málaga, en 2014, *N. parvum* representó el 50 % de 68 aislamientos de ramas con muerte descendente, seguido de *C. gloeosporioides* (17,6 %) (Arjona-Girona et al., 2019). Entre 2019 y 2022 se obtuvieron 252 aislamientos en Andalucía, con predominio de *Neofusicoccum* (110), y el aumento de la enfermedad se relacionó con la escasez de agua de riego (Crespo et al., 2026). En condiciones mediterráneas, el estrés hídrico produjo la mayor severidad y los árboles de 1 a 2 años fueron los más susceptibles (Guirado-Manzano et al., 2026).
- **Islas Canarias.** En Tenerife, la necrosis de ramas (sobre todo muerte descendente) apareció en el 90 % de 40 huertos, y los canchros en ramas y tronco, en el 7,5 % (Hernández et al., 2023).
- **Italia.** En Cerdeña y Sicilia, a partir de 430 muestras de 115 plantas se identificaron 22 especies, y los canchros en brotes, ramas y tallo se observaron en el 86 % de los árboles monitoreados (Linaldeddu et al., 2026). En un vivero de Sicilia, *C. perseae* y *C. gloeosporioides* causaron lesiones en el tallo y muerte descendente, a menudo desde el injerto, con una incidencia superior al 45 % en unas 20 000 plantas (Vecchio, Martino, et al., 2026).
- **Turquía.** En 2 537 árboles de 11 regiones de Antalya, la incidencia de enfermedades fue de 33,89 %, y en inoculaciones *P. cinnamomi*, *Fusarium solani* y *F. oxysporum* causaron canchros severos en ramas (Çalış et al., 2024).
- **Sudamérica.** En Brasil se reportaron por primera vez cuatro hongos causantes de muerte descendente (Silva et al., 2025); en Perú, en *Lasiodiplodia theobromae* la necrosis interna avanzó antes que la externa (Rodríguez-Gálvez et al., 2025); en Chile, la incidencia de cancro y muerte descendente fue de 31 a 100 % en 9 de 16 huertos y se asoció a la edad, el volumen de copa y el diámetro del tronco, con heladas y exceso de riego como factores secundarios (Valencia et al., 2022); y en Colombia se secuenció el genoma de *Rugonectria rugulosa*, aislado de canchros del tronco (Rincón López et al., 2026).

La Tabla 8 relaciona cada grupo de agentes con sus síntomas, separando lo que se ve desde fuera de lo que solo aparece al cortar el tejido.

Tabla 8. Agentes causales y síntomas en el tallo, las ramas y el tronco del aguacate

Agente causal	Enfermedad o alteración	Síntomas externos (visibles en el árbol)	Síntomas internos (requieren corte)	Países y fuentes
Botryosphaeriaceae (<i>Neofusicoccum</i> , <i>Lasioidiplodia</i> , <i>Diplodia</i> , <i>Dothiorella</i>)	Cancro de rama y tronco; muerte descendente	– Cancros hundidos en ramillas, ramas y tronco. – Exudado rojizo que seca en polvo blanco o blanco-amarillento. – Corteza oscura, agrietada y quebradiza; protuberancias rugosas. – Ramas secas con hojas pardas adheridas y frutos negros momificados.	– Necrosis en forma de cuña o V hacia el xilema. – Madera parda o rojiza; haces vasculares rojizos.	España, Canarias, Italia, Chile, Turquía y Perú (Arjona-Girona et al., 2019; Çaliş et al., 2024; Crespo et al., 2026; Hernández et al., 2023; Linaldeddu et al., 2026; Möller et al., 2025; Rodríguez-Gálvez et al., 2025; Valencia et al., 2022)
<i>Colletotrichum perseae</i> y <i>C. gloeosporioides</i>	Lesión del tallo y muerte descendente (vivero, tras el injerto)	– Lesiones necróticas oscuras en brotes y tallos. – Muerte descendente que suele iniciar en el punto de injerto.	– Decoloración de la madera y estrías pardo-rojizas que se extienden más allá de la lesión externa.	Italia y España (Arjona-Girona et al., 2019; Vecchio, Arrebola, et al., 2026; Vecchio, Martino, et al., 2026)
<i>Phytophthora</i> (<i>P. citrophthora</i> , <i>P. palmivora</i> , <i>P. cinnamomi</i>)	Necrosis de corteza (cancro sangrante); pudrición del cuello y la raíz	– Necrosis oscura de la corteza con exudados negruzcos, sin aspecto hundido. – Agrietamiento de la corteza en la base del tallo. – Síntomas de copa inespecíficos.	– Necrosis limitada a la corteza interna.	Italia y Turquía (Çaliş et al., 2024; Linaldeddu et al., 2026)
<i>Fusarium solani</i> y <i>F. oxysporum</i>	Cancro de rama (inoculación)	– Lesiones de gran área en ramas inoculadas.	– No se describen.	Turquía (Çaliş et al., 2024)
Nectriaceae y otros (<i>Nectria pseudotrichia</i> , <i>Neocosmospora bostrycoides</i> , <i>Cytospora viridistroma</i> , <i>Neopestalotiopsis areacearum</i> , <i>Rugonectria rugulosa</i> , <i>Diaporthe foeniculina</i>)	Muerte descendente; cancro del tronco	– Marchitez, caída intensa de hojas y muerte descendente. – Cancro activo en el tronco.	– Tejidos internos necróticos y oscurecimiento vascular.	Brasil, Colombia y España (Crespo et al., 2026; Rincón López et al., 2026; Silva et al., 2025)

Nota. Elaboración propia a partir de los estudios citados. Los síntomas no son exclusivos de cada agente: varios patógenos producen cuadros parecidos y pueden aparecer juntos.

En cuanto a la severidad, Guirado-Manzano et al. (2026) evaluaron la muerte descendente con una escala visual de cuatro categorías (0: sin síntomas; 1: ≤ 15 % de la planta afectada; 2: 15–50 %; 3: > 50 %), y en el manejo, los bioformulados redujeron entre 37 y 91 % las lesiones por *C. perseae*

en ramillas (Vecchio, Arrebola, et al., 2026). Que la severidad se estime a simple vista indica que existe una base visual sobre la cual se podría construir un etiquetado de imágenes.

2.6.3 Implicaciones para el diagnóstico por imagen

La evidencia anterior permite distinguir qué puede captar una fotografía del tallo y qué no (Tabla 9). El hallazgo más importante es que los síntomas no identifican a la especie: cada patógeno de Botryosphaeriaceae puede causar varios síntomas y estos se superponen (Möller et al., 2025); especies de *Colletotrichum* y *Alternaria* causan síntomas similares que pueden atribuirse por error a Botryosphaeriaceae (Hernández et al., 2023); y, vistos desde fuera, los síntomas de *Phytophthora* en el tronco pueden parecer idénticos a los de Botryosphaeriaceae, lo que para Linaldeddu et al. (2026) plantea un límite al diagnóstico automático de enfermedades a partir de imágenes con IA.

Tabla 9. Qué puede y qué no puede captar una fotografía del tallo del aguacate

Aspecto	¿Visible en una foto externa?	Evidencia	Implicación para la aplicación
Cancro, exudado, corteza oscura o agrietada	Sí	Hernández et al. (2023); Linaldeddu et al. (2026); Möller et al. (2025)	Base de las clases de síntoma; guiar la captura de cerca.
Muerte descendente de ramillas	Sí, a distancia	Crespo et al. (2026); Valencia et al. (2022)	Requiere una toma de la rama o la copa, además del primer plano.
Aspecto hundido frente a no hundido	Parcialmente; menos claro en el tronco principal	Linaldeddu et al. (2026)	Ayuda a diferenciar síntomas, pero no confirma el agente.
Necrosis interna en cuña y haces vasculares rojizos	No; solo con un corte	Crespo et al. (2026); Hernández et al. (2023); Möller et al. (2025)	Posible clase opcional con foto de un corte de poda (validar con la tutora).
Avance interno de la infección	No; la necrosis interna precede a la externa	Rodríguez-Gálvez et al. (2025); Vecchio, Martino, et al. (2026)	La foto subestima el daño; advertirlo en el resultado.
Infección latente (endófito)	No	Möller et al. (2025); Valencia et al. (2022)	La app no puede descartar la infección en un tallo sano.
Especie del patógeno	No; los síntomas se superponen	Hernández et al. (2023); Linaldeddu et al. (2026); Silva et al. (2025)	Diagnóstico por tipo de síntoma; confirmar la especie en laboratorio.

Nota. Elaboración propia a partir de los estudios citados.

De ello se desprende que la aplicación debería clasificar **tipos de síntoma** y no especies, y recomendar la confirmación en laboratorio, que combina el aislamiento con marcadores moleculares como ITS, EF1- α y β -tubulina (Möller et al., 2025). Con esa lógica, la Tabla 10 propone clases candidatas **preliminares**, que deberán validarse con la tutora y, de ser posible, con un fitopatólogo en la Actividad 10 (tarea T30), y ajustarse con los resultados de la revisión sistemática.

Tabla 10. Clases candidatas preliminares para el dataset de tallos de aguacate

Clase candidata	Descripción visual	Agentes asociados (no exclusivos)	Observación
C0. Tallo o rama sanos	Corteza sin lesiones, exudados ni grietas.	—	Clase de referencia necesaria para el modelo.

Clase candidata	Descripción visual	Agentes asociados (no exclusivos)	Observación
C1. Cancro con exudado blanquecino	Lesión, a veces hundida, con exudado rojizo que seca en polvo blanco.	Botryosphaeriaceae	El árbol puede exudar por otras causas (Hernández et al., 2023).
C2. Necrosis oscura con exudado negruzco	Corteza oscura con exudado negro, sin hundimiento.	<i>Phytophthora</i>	Puede confundirse con C1 y C3 (Linaldeddu et al., 2026).
C3. Cancro hundido o corteza agrietada sin exudado	Corteza oscura, hundida o quebradiza.	Botryosphaeriaceae y otros	Revisar si se fusiona con C1 según el número de imágenes.
C4. Muerte descendente	Ramillas secas desde el ápice, hojas pardas adheridas, frutos negros momificados.	Botryosphaeriaceae, <i>Colletotrichum</i> , Nectriaceae	Requiere una toma de la rama completa.
C5. Lesión en tallo joven o injerto	Lesión necrótica oscura en planta de vivero, a menudo desde el injerto.	<i>Colletotrichum</i> , Botryosphaeriaceae	Depende de tener acceso a viveros.
C6. Decoloración interna (opcional)	Sector en cuña o V y haces vasculares rojizos en un corte.	Botryosphaeriaceae	Requiere cortar; decidir con la tutora si se incluye.

Nota. Propuesta del autor, elaborada a partir de Crespo et al. (2026), Hernández et al. (2023), Linaldeddu et al. (2026), Möller et al. (2025), Valencia et al. (2022) y Vecchio, Martino, et al. (2026). Para la severidad podría adaptarse la escala de cuatro categorías de Guirado-Manzano et al. (2026).

2.7 Revisiones previas y posicionamiento del estudio

Las revisiones recopiladas abordan por separado los componentes que necesita el proyecto. Cuatro de ellas aplicaron la declaración PRISMA (Lin et al., 2026; Majdalawieh et al., 2025; Odounfa et al., 2024; Sajitha et al., 2024), y Martinelli et al. (2024) siguieron las guías de Kitchenham y Charters. La Tabla 11 las compara con la revisión sistemática planteada en el protocolo v3.

Tabla 11. Comparación de las revisiones previas con la revisión sistemática del proyecto

Revisión	Método y alcance	IA / visión por computador	App móvil o despliegue	IPO	Aguacate / tallo
Majdalawieh et al. (2025)	RS (PRISMA); 150 estudios, 2016–2024	Sí	Escalabilidad y costo; sin app	No	No
Saini et al. (2026)	Revisión sistemática de 80 trabajos, 2021–2025	Sí	Borde, híbrido y nube	No	No
Sajitha et al. (2024)	Revisión (PRISMA); 135 artículos, 2017–2023	Sí	Señala pocas apps	No	Señala que los tallos no se han estudiado
Odounfa et al. (2024)	Revisión (PRISMA); 72 de 1 422 publicaciones, 2017–2023; hortalizas	Sí, incluida la severidad	Recomienda apps en idiomas locales	Breve	Propone extender el estudio a tallos y ramas
Lin et al. (2026)	Revisión (PRISMA); 92 estudios; destilación	Sí, modelos ligeros	Dispositivos de borde	Interpretabilidad y confianza	No
Munjal et al. (2023)	Revisión de unos 100 trabajos; hojas	Sí	Señala pocas apps	No	No (la hoja como índice)
Martinelli et al. (2024)	RSL (Kitchenham y Charters); 45 artículos	No	No	Sí, UX a largo plazo	No

Revisión	Método y alcance	IA / visión por computador	App móvil o despliegue	IPO	Aguacate / tallo
Möller et al. (2025)	Revisión de literatura sobre Botryosphaeriaceae	No	No	No	Sí: cancro y muerte descendente; detección en laboratorio
Este estudio (protocolo v3)	RS con dos categorías (fitopatológica y tecnológica)	Sí	Sí	Sí	Sí, tallo como núcleo

Nota. Elaboración propia a partir de las revisiones citadas. RS: revisión sistemática; RSL: revisión sistemática de la literatura.

Ninguna revisión reúne en un solo análisis las enfermedades del tallo del aguacate, las técnicas de IA para diagnosticarlas, su despliegue en el teléfono y el diseño centrado en el usuario. Ese es el espacio que ocupa la revisión sistemática del proyecto.

2.8 Síntesis de brechas de investigación

La Tabla 12 resume las brechas identificadas, la evidencia que las respalda y la pregunta de investigación del protocolo v3 que las abordará.

Tabla 12. Brechas identificadas en el estado del arte y preguntas de investigación relacionadas

N.º	Brecha	Evidencia	RQ
B1	El diagnóstico por IA se ha centrado en hojas y frutos; los tallos casi no se han estudiado.	Munjal et al. (2023); Odounfa et al. (2024); Sajitha et al. (2024); Tabla 4	RQ3, RQ5
B2	No existen conjuntos de imágenes de tallos de aguacate; los públicos son de laboratorio y con sesgo geográfico. Ninguna fuente recopilada es un estudio realizado en Ecuador.	Lin et al. (2026); Majdalawieh et al. (2025); Saini et al. (2026); Tabla 5	RQ3, RQ5
B3	Los síntomas del tallo se superponen entre patógenos y hay coinfecciones, lo que limita el diagnóstico por imagen.	Hernández et al. (2023); Linaldeddu et al. (2026); Möller et al. (2025); Silva et al. (2025)	RQ1, RQ2, RQ5
B4	Lo visible subestima el daño: la necrosis interna precede a la externa y existen infecciones latentes.	Möller et al. (2025); Rodríguez-Gálvez et al. (2025); Valencia et al. (2022); Vecchio, Martino, et al. (2026)	RQ2, RQ5
B5	El diagnóstico depende del laboratorio y tarda semanas; no hay herramientas de campo basadas en imágenes del tallo.	Möller et al. (2025); Silva et al. (2025)	RQ2, RQ5
B6	Los sistemas móviles procesan en el servidor y dependen de Internet; la inferencia sin conexión es poco común.	Kochhar et al. (2026); Ramana Reddy et al. (2025); Saini et al. (2026)	RQ4
B7	La evaluación con usuarios es escasa e informal, y la UX a largo plazo casi no se aplica.	Christakakis et al. (2024); Martinelli et al. (2024); Ramana Reddy et al. (2025)	RQ4
B8	La exactitud alta en laboratorio no se mantiene en campo y es menor en enfermedades fúngicas.	Lin et al. (2026); Majdalawieh et al. (2025); Moreano et al. (2026); Saini et al. (2026)	RQ3
B9	La falta de interpretabilidad limita la confianza del usuario en el diagnóstico.	Lin et al. (2026); Ramana Reddy et al. (2025)	RQ4

Nota. Elaboración propia. RQ1–RQ5 corresponden a las preguntas de investigación del protocolo v3.

En conjunto, el estado del arte muestra que existen las piezas tecnológicas —modelos ligeros, despliegue en el borde y métodos de diseño centrado en el usuario—, pero no se han aplicado a las enfermedades del tallo del aguacate, cuyos síntomas son visibles pero poco específicos. Esto justifica la revisión sistemática de las Actividades 3 a 9 y orienta las fases siguientes: construir un conjunto propio de imágenes de campo con clases por tipo de síntoma (Actividades 10 a 12), entrenar modelos ligeros y evaluarlos con métricas por clase (Actividades 13 a 15), diseñar la captura guiada y la presentación comprensible del resultado (Actividades 16 y 17) y ejecutar el modelo en el teléfono sin conexión (Actividades 18 a 20).

Referencias

Todas las referencias corresponden a fuentes recopiladas por el autor en la carpeta Grupos v2.

- Ahmed, M., Babaei, M., Jeong, N., Kong, L., & Gan, Y. (2026). Hybrid loss for robust ripeness classification under noisy labels. *Future Foods*, 14, 101116. <https://doi.org/10.1016/j.fufo.2026.101116>
- Arjona-Girona, I., Ruano-Rosa, D., & López-Herrera, C. J. (2019). Identification, pathogenicity and distribution of the causal agents of dieback in avocado orchards in Spain. *Spanish Journal of Agricultural Research*, 17(1), e1003. <https://doi.org/10.5424/sjar/2019171-13561>
- Bustamante, M. I., Osorio-Navarro, C., Fernández, Y., Bourret, T. B., Zamorano, A., & Henríquez-Sáez, J. L. (2022). First record of *Colletotrichum anthrisci* causing anthracnose on avocado fruits in Chile. *Pathogens*, 11(10), 1204. <https://doi.org/10.3390/pathogens11101204>
- Çalış, Ö., Çelik, S., Fidan, H., Tek, M. I., Shah, M., Tozlu, I., & Wani, S. H. (2024). Emerging pathogens and disease dynamics threatening avocado production in southern Türkiye. *Journal of Plant Diseases and Protection*, 131, 1653–1663. <https://doi.org/10.1007/s41348-024-00954-6>
- Christakakis, P., Papadopoulou, G., Mikos, G., Kalogiannidis, N., Ioannidis, D., Tzovaras, D., & Pechlivani, E. M. (2024). Smartphone-based citizen science tool for plant disease and insect pest detection using artificial intelligence. *Technologies*, 12(7), 101. <https://doi.org/10.3390/technologies12070101>
- Crespo, M., Guirado-Manzano, L., Sarmiento, D., Guirado, E., de Vicente, A., Fernández-Ortuño, D., Cazorla, F. M., & Arrebola, E. (2026). Fungal species of Botryosphaeriaceae associated with avocado dieback in southern Spain. *Plant Pathology*, 75, e70079. <https://doi.org/10.1111/ppa.70079>
- Estrada, J. S., Cetin, N., Sacilik, K., Ulu, B., Ulu, B., & Auat Cheein, F. (2026). Assessment of avocado water stress using multispectral imaging and deep learning: Toward scalable, cost-effective irrigation monitoring. *Expert Systems with Applications*, 326, 132688. <https://doi.org/10.1016/j.eswa.2026.132688>
- Fuentes-Aragón, D., Silva-Rojas, H. V., Guarnaccia, V., Mora-Aguilera, J. A., Aranda-Ocampo, S., Bautista-Martínez, N., & Téliz-Ortíz, D. (2020). *Colletotrichum* species causing anthracnose on avocado fruit in Mexico: Current status. *Plant Pathology*, 69, 1513–1528. <https://doi.org/10.1111/ppa.13234>
- Guelac-Santillan, M., Puscan-Rojas, J., Sánchez-Vega, J. A., Huaman-Pilco, A. F., Medina-Medina, A. J., Tuesta-Trauco, K. M., Canta-Ventura, J. M., Barboza, E., & Zabaleta-Santisteban, J. A. (2026). Spatial mapping of avocado anthracnose severity using UAV-derived vegetation indices in Amazonas, Peru. *AgriEngineering*, 8(8), 340. <https://doi.org/10.3390/agriengineering8080340>
- Guirado-Manzano, L., Santamaría-Ortega, J. F., Sarmiento, D., Guirado, E., Pulido-Ruiz, M., de Vicente, A., Fernández-Ortuño, D., Cazorla, F. M., & Arrebola, E. (2026). Integrated strategies to reduce Botryosphaeriaceae-associated dieback in avocado under

Mediterranean climatic stress. *Horticulturae*, 12(6), 673.
<https://doi.org/10.3390/horticulturae12060673>

- Hernández, D., García-Pérez, O., Perera, S., González-Carracedo, M. A., Rodríguez-Pérez, A., & Siverio, F. (2023). Fungal pathogens associated with aerial symptoms of avocado (*Persea americana* Mill.) in Tenerife (Canary Islands, Spain) focused on species of the family Botryosphaeriaceae. *Microorganisms*, 11(3), 585.
<https://doi.org/10.3390/microorganisms11030585>
- Iqbal, A., Ahmed, I., Rehman, S., & Alzahrani, A. S. (2026). Plants disease detection and identification system using AI and computer vision techniques. *PeerJ Computer Science*, 12, e3509. <https://doi.org/10.7717/peerj-cs.3509>
- Kochhar, A., Narang, G., Patel, S., Kaur, H., Singla, C., Pateriya, B., & Galdelli, A. (2026). A three-tier deep learning framework with mobile application integration for multi-crop disease diagnosis. *Discover Artificial Intelligence*, 6, 358. <https://doi.org/10.1007/s44163-026-01062-0>
- Lin, X., Chen, S., Yan, N., Pi, J., Zhu, T., & Xu, L. (2026). Knowledge distillation for smart agriculture: Methods, applications, and future directions. *Smart Agricultural Technology*, 14, 102019. <https://doi.org/10.1016/j.atech.2026.102019>
- Linaldeddu, B. T., Bregant, C., Muscas, J., Maddau, L., Vecchio, L., Polizzi, G., & Aiello, D. (2026). Identification and pathogenicity of Botryosphaeriaceae, *Colletotrichum*, and *Phytophthora* species associated with avocado diseases in Italy. *Agriculture*, 16(10), 1035. <https://doi.org/10.3390/agriculture16101035>
- Majdalawieh, M., Martins, C., Radi, M., Alaraj, M., & Khan, S. (2025). Precision agriculture in the age of AI: A systematic review of machine learning methods for crop disease detection. *Smart Agricultural Technology*, 12, 101491. <https://doi.org/10.1016/j.atech.2025.101491>
- Martinelli, S., Lopes, L., & Zaina, L. (2024). UX research practices related to long-term UX: A systematic literature review. *Information and Software Technology*, 170, 107431. <https://doi.org/10.1016/j.infsof.2024.107431>
- Möller, H., Slippers, B., & van den Berg, N. (2025). Branch canker battles: Understanding and managing the Botryosphaeriaceae in avocado. *Phytoparasitica*, 53, 17. <https://doi.org/10.1007/s12600-024-01227-6>
- Moreano, M., Sosa, A., Mauricio, D., Rivera, L., & Santisteban, J. (2026). ApaltAI: A web-based diagnostic system with a sequential voting architecture for detecting anthracnose and scab in avocado fruit. *Frontiers in Plant Science*, 17, 1736123. <https://doi.org/10.3389/fpls.2026.1736123>
- Munjal, D., Singh, L., Pandey, M., & Lakra, S. (2023). A systematic review on the detection and classification of plant diseases using machine learning. *International Journal of Software Innovation*, 11(1), 1–25. <https://doi.org/10.4018/IJSI.315657>
- Odounfa, M. G. F., Gbemavo, C. D. S. J., Tahi, S. P. G., & Glèlè Kakaï, R. L. (2024). Deep learning methods for enhanced stress and pest management in market garden crops: A

- comprehensive analysis. *Smart Agricultural Technology*, 9, 100521. <https://doi.org/10.1016/j.atech.2024.100521>
- Ovalle, C., Jimenez, J. G., & Zuñiga, J. B. (2026). Comparing global and variety-specific ensemble models for avocado maturity prediction with near-infrared. *IAES International Journal of Artificial Intelligence*, 15(3), 2300–2313. <https://doi.org/10.11591/ijai.v15.i3.pp2300-2313>
- Ramana Reddy, B., Kalnoor, G., Devashish, M., & Sai Karthik Reddy, P. (2025). Deep learning based mobile application for automated plant disease detection. *IEEE Access*, 13, 107917–107925. <https://doi.org/10.1109/ACCESS.2025.3581099>
- Reeksting, B. J., Taylor, N. J., & van den Berg, N. (2014). Flooding and *Phytophthora cinnamomi*: Effects on photosynthesis and chlorophyll fluorescence in shoots of non-grafted *Persea americana* (Mill.) rootstocks differing in tolerance to *Phytophthora* root rot. *South African Journal of Botany*, 95, 40–53. <https://doi.org/10.1016/j.sajb.2014.08.004>
- Rincón López, J. D., Chacón-Vargas, K., Clavijo-Buriticá, D. C., & García-Merchán, V. H. (2026). Genome assembly and annotation of *Rugonectria rugulosa*, a fungus associated with avocado (*Persea americana* cv. Hass) trunk canker in Colombia. *Microbiology Resource Announcements*, 15(7). <https://doi.org/10.1128/mra.00512-26>
- Rodríguez-Gálvez, E., Haro-Díaz, C., Maza-Aguirre, S., Canahuire-Castillo, F., Sullón-Saucedo, J., & Deising, H. B. (2025). *Lasiodiplodia theobromae* disease symptom development in young avocado (*Persea americana* L.) plants depends on the inoculation method. *Tropical Plant Pathology*, 50, 18. <https://doi.org/10.1007/s40858-025-00700-9>
- Saini, Y., Somani, V., & Khatri, N. (2026). Critical analysis of advanced machine learning and deep learning models for crop disease detection: Challenges, innovations, and future directions. *Franklin Open*, 15, 100584. <https://doi.org/10.1016/j.fraope.2026.100584>
- Sajitha, P., Andrushia, A. D., Anand, N., & Naser, M. Z. (2024). A review on machine learning and deep learning image-based plant disease classification for industrial farming systems. *Journal of Industrial Information Integration*, 38, 100572. <https://doi.org/10.1016/j.jii.2024.100572>
- Silva, T. F., Pimentel Duarte, J. L., Vélez-Olmedo, J. B., Vieira, W. A. S., Blum, L. E. B., & Pinho, D. B. (2025). Four new fungal pathogens causing avocado dieback in Brazil. *Crop Protection*, 192, 107168. <https://doi.org/10.1016/j.cropro.2025.107168>
- Soares, M. G. O., Alves, E., Silveira, A. L., Pereira, F. D., & Guimarães, S. S. C. (2021). *Colletotrichum siamense* is the main aetiological agent of anthracnose of avocado in south-eastern Brazil. *Plant Pathology*, 70, 154–166. <https://doi.org/10.1111/ppa.13262>
- Tapia, L., Castillo-Novales, D., Riquelme, N., Valencia, A. L., Larach, A., Cautín, R., & Besoain, X. (2025). Rainfall and high humidity influence the seasonal dynamics of spores of Glomerellaceae and Botryosphaeriaceae genera in avocado orchards and their fruit rot association. *Agronomy*, 15(6), 1453. <https://doi.org/10.3390/agronomy15061453>
- Valencia, A. L., Saavedra-Torrico, J., Rosales, I. M., Mártiz, J., Retamales, A., Link, A., & Gil, P. M. (2022). Unveiling the predisposing factors for the development of branch canker and

dieback in avocado: A case of study in Chilean orchards. *Horticulturae*, 8(12), 1121.
<https://doi.org/10.3390/horticulturae8121121>

Vecchio, L., Arrebola, E., Polizzi, G., & Vitale, A. (2026). Ecofriendly management of anthracnose on avocado caused by *Colletotrichum perseae* in the Mediterranean basin. *JSFA Reports*.
Publicación anticipada en línea. <https://doi.org/10.1002/jsf2.70088>

Vecchio, L., Martino, I., Guarnaccia, V., Polizzi, G., & Aiello, D. (2026). *Colletotrichum perseae* and *Colletotrichum gloeosporioides* sensu strictu causing stem lesion and dieback in avocado in Italy. *Horticulturae*, 12(1), 111. <https://doi.org/10.3390/horticulturae12010111>

Vera, O., Cruz, J., Huaquipaco, S., Mamani, W., Yana-Mamani, V., & Huaquipaco, S. (2024). Automated and enhanced classification of *Persea americana* using optimized deep convolutional neural networks with improved training strategies for agro-industrial settings. *IEEE Access*, 12, 194240–194255. <https://doi.org/10.1109/ACCESS.2024.3496728>

Xavier, P., Rodrigues, P. M., & Silva, C. L. M. (2024). Shelf-life management and ripening assessment of 'Hass' avocado (*Persea americana*) using deep learning approaches. *Foods*, 13(8), 1150. <https://doi.org/10.3390/foods13081150>

Anexo A. Correspondencia entre referencias e identificadores de la matriz

Identificadores asignados en el Inventario de fuentes y en la matriz SLR v5. Las revisiones (T0004, T0014 a T0020 y A0046) se retirarán antes del cribado como estudios secundarios; los estudios primarios se evaluarán en las Actividades 4 a 6.

Referencia	ID en la matriz	Categoría	Tipo de estudio
Ahmed et al. (2026)	T0007	Tecnológico	Primario
Arjona-Girona et al. (2019)	A0022	Fitopatológico	Primario
Bustamante et al. (2022)	A0011	Fitopatológico	Primario
Çalış et al. (2024)	A0009 (= A0047)	Fitopatológico	Primario
Christakakis et al. (2024)	T0011	Tecnológico	Primario
Crespo et al. (2026)	A0016	Fitopatológico	Primario
Estrada et al. (2026)	T0001	Tecnológico	Primario
Fuentes-Aragón et al. (2020)	A0005	Fitopatológico	Primario
Guelac-Santillan et al. (2026)	T0008	Tecnológico	Primario
Guirado-Manzano et al. (2026)	A0024	Fitopatológico	Primario
Hernández et al. (2023)	A0015	Fitopatológico	Primario
Iqbal et al. (2026)	T0009	Tecnológico	Primario
Kochhar et al. (2026)	T0013	Tecnológico	Primario
Lin et al. (2026)	T0016	Tecnológico	Revisión
Linaldeddu et al. (2026)	A0018	Fitopatológico	Primario
Majdalawieh et al. (2025)	T0017	Tecnológico	Revisión
Martinelli et al. (2024)	T0020	Tecnológico	Revisión
Möller et al. (2025)	A0046	Fitopatológico	Revisión
Moreano et al. (2026)	T0002	Tecnológico	Primario
Munjal et al. (2023)	T0004	Tecnológico	Revisión
Odounfa et al. (2024)	T0014	Tecnológico	Revisión
Ovalle et al. (2026)	T0006	Tecnológico	Primario
Ramana Reddy et al. (2025)	T0010	Tecnológico	Primario
Reeksting et al. (2014)	A0043	Fitopatológico	Primario
Rincón López et al. (2026)	A0017	Fitopatológico	Primario
Rodríguez-Gálvez et al. (2025)	A0025 (= A0048)	Fitopatológico	Primario
Saini et al. (2026)	T0018	Tecnológico	Revisión
Sajitha et al. (2024)	T0019	Tecnológico	Revisión
Silva et al. (2025)	A0014	Fitopatológico	Primario
Soares et al. (2021)	A0004	Fitopatológico	Primario
Tapia et al. (2025)	A0034	Fitopatológico	Primario
Valencia et al. (2022)	A0038	Fitopatológico	Primario
Vecchio, Arrebola, et al. (2026)	A0006	Fitopatológico	Primario

Referencia	ID en la matriz	Categoría	Tipo de estudio
Vecchio, Martino, et al. (2026)	A0003	Fitopatológico	Primario
Vera et al. (2024)	T0012	Tecnológico	Primario
Xavier et al. (2024)	T0003	Tecnológico	Primario

Nota. El signo "=" indica el duplicado entre bases ya marcado en la matriz v3. Las revisiones T0014 a T0020 recibieron su identificador el 01/10/2026.