EVIDENCIAS DE LA PRÁCTICA PRE PROFESIONAL DEL ESTUDIANTE

☐	**Pasantía**	☐	**Ayudante de Cátedra**
☒	**Práctica pre profesional no remunerada**	☐	**Ayudante de Investigación**
☐	**Servicio a la comunidad**		

CARRERA: Software

PERIODO ACADÉMICO: 202651 – PREGRADO S-II SEP 26 – FEB 27

Contenido

1. **21 de septiembre de 2026** 2
2. **22 de septiembre de 2026** 3
3. **23 de septiembre de 2026** 5
4. **24 de septiembre de 2026** 7
5. **25 de septiembre de 2026** 8
6. **28 de septiembre de 2026** 10
7. **29 de septiembre de 2026** 10
8. **30 de septiembre de 2026** 11
9. **01 de octubre de 2026** 12
10. **02 de octubre de 2026** 14
11. **05 de octubre de 2026** 14
12. **06 de octubre de 2026** 15
13. **07 de octubre de 2026** 16
1. **08 de octubre de 2026** 16
2. **12 de octubre de 2026** 18
3. **13 de octubre de 2026** 18
4. **14 de octubre de 2026** 19
5. **15 de octubre de 2026** 19
6. **16 de octubre de 2026** 20
7. **19 de octubre de 2026** 21
8. **20 de octubre de 2026** 22
9. **21 de octubre de 2026** 23
10. **22 de octubre de 2026** 24
11. **23 de octubre de 2026** 25

12. 26 de octubre de 2026 28
13. 27 de octubre de 2026 29
14. 28 de octubre de 2026 30
15. 29 de octubre de 2026 31
16. 30 de octubre de 2026 31
17. 4 de noviembre de 2026 31
18. 5 de noviembre de 2026 31
19. 6 de noviembre de 2026 31
20. 9 de noviembre de 2026 31
21. 10 de noviembre de 2026 31
22. 11 de noviembre de 2026 31

ACTIVIDADES

1. 21 de septiembre de 2026

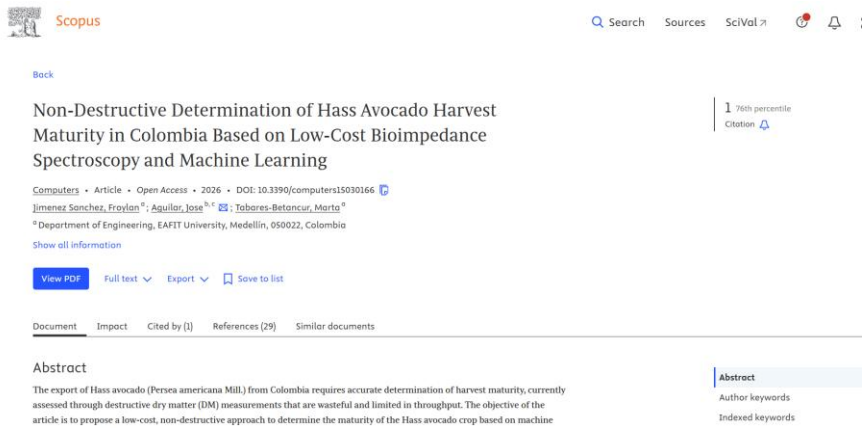


Ilustración 1 Revisión en Scopus de un artículo sobre aguacate y aprendizaje automático



Ilustración 2 Consulta de una revisión sistemática de referencia en Springer Nature Link

2. 22 de septiembre de 2026

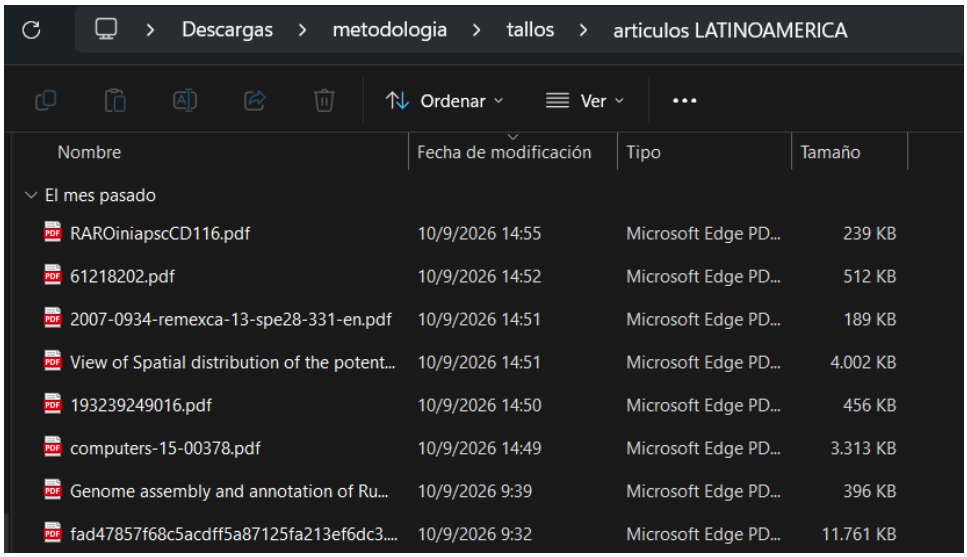


Ilustración 3 Artículos descargados en la carpeta «articulos LATINOAMERICA»

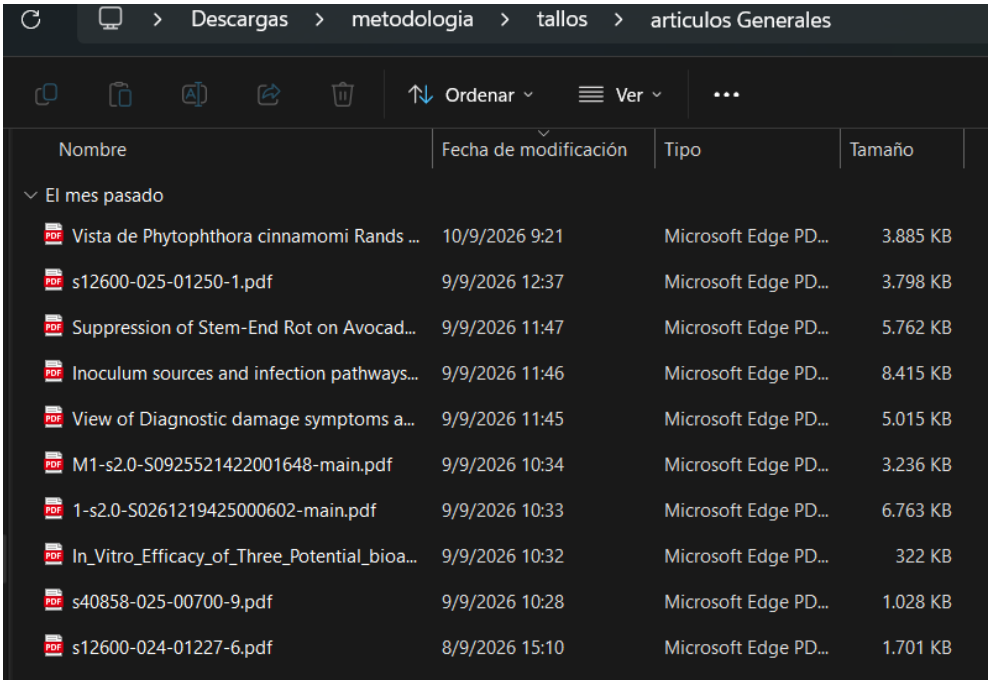


Ilustración 4 Artículos descargados en la carpeta «articulos Generales»

Prácticas preprofesionales – Departamento de Ciencias de la Computación
Universidad de las Fuerzas Armadas ESPE
Autor/a: Ariel Llumiquinga
Tutora: Ing. Doris Chicaiza
Proyecto: Smart Agriculture
Actividad del itinerario: 2. Desarrollo del estado del arte (tareas T03–T06)
Versión: 2
Fecha: 1 de octubre de 2026.
Estado: Borrador para revisión de la tutora.

Estado del arte: inteligencia artificial, interacción persona-ordenador y enfermedades del tallo del aguacate (*Persea americana*) como base para una aplicación móvil de diagnóstico

Nota. Este documento utiliza exclusivamente fuentes recopiladas por el autor en la carpeta Grupos v2 (revisiones y estudios primarios de Scopus, ScienceDirect y Springer Link). Los estudios primarios citados aquí se evaluarán formalmente en las Actividades 3 a 6 de la revisión sistemática; en este documento se usan solo para describir el estado del conocimiento. La correspondencia entre cada referencia y su identificador en la matriz se presenta en el Anexo A.

1. Introducción

Las plagas y enfermedades causan, en conjunto, cerca del 30 % de las pérdidas mundiales de cultivos, y su identificación tradicional depende de la experiencia humana, lo que la vuelve lenta, costosa y a menudo imprecisa (Majdalawieh et al., 2025). En la práctica, los agricultores vigilan las plantas enfermas de forma manual y a simple vista (Sajitha et al., 2024), y la inspección visual de hojas, tallos y frutos depende de la pericia de cada persona, por lo que está expuesta a errores y juicios subjetivos (Odounfa et al., 2024). La agricultura de precisión y la inteligencia artificial (IA) ofrecen una alternativa: la visión por computador y el aprendizaje profundo permiten reconocer síntomas en imágenes, y los teléfonos inteligentes acercan ese diagnóstico al lugar donde se cultiva (Saini et al., 2026).

El aguacate es un cultivo de gran importancia económica; México, Colombia, Perú y la República Dominicana reunieron cerca del 58 % de la producción mundial en la temporada 2022 (Möller et al., 2025). Las mismas condiciones cálidas que favorecen al cultivo favorecen también a los hongos patógenos, en especial a los de la familia Botryosphaeriaceae, que causan cancros en ramas, muerte descendente y pudriciones del fruto (Möller et al., 2025). El diagnóstico de estas enfermedades se basa tradicionalmente en los síntomas observados en campo (Silva et al., 2025) y

Ilustración 5 Redacción del estado del arte

3. 23 de septiembre de 2026

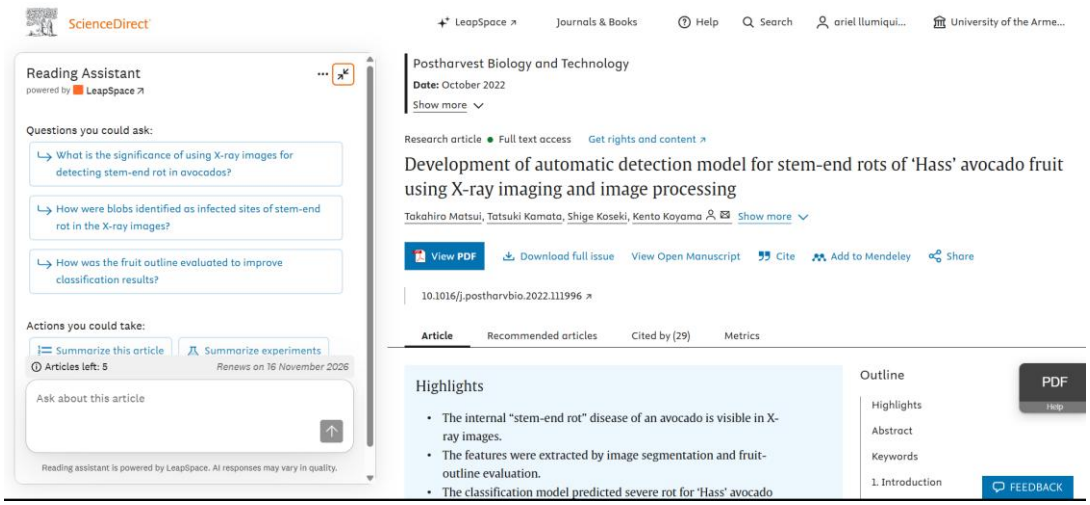


Ilustración 6 Revisión en ScienceDirect de un artículo sobre la pudrición peduncular del aguacate

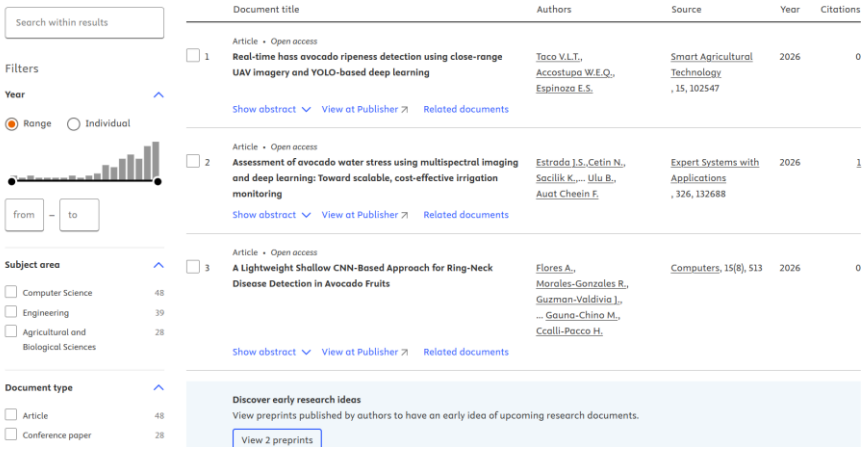


Ilustración 7 Resultados de búsqueda en Scopus sobre aguacate e inteligencia artificial

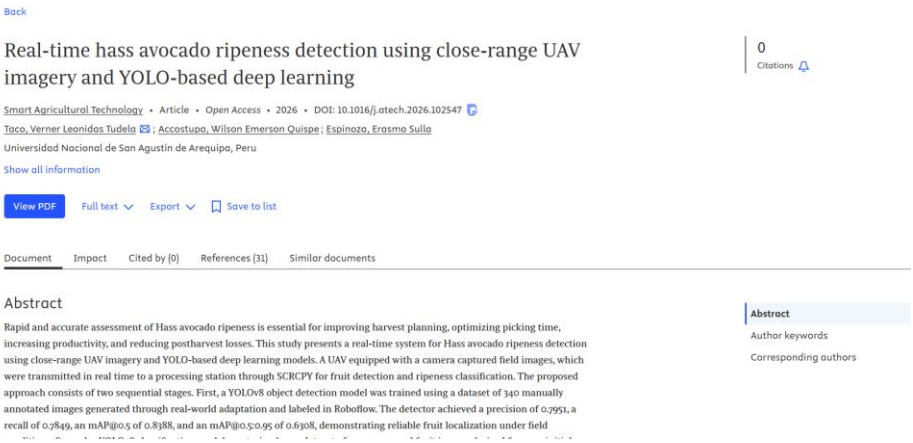


Ilustración 8 Revisión en Scopus de un artículo sobre detección de madurez del aguacate con YOLO

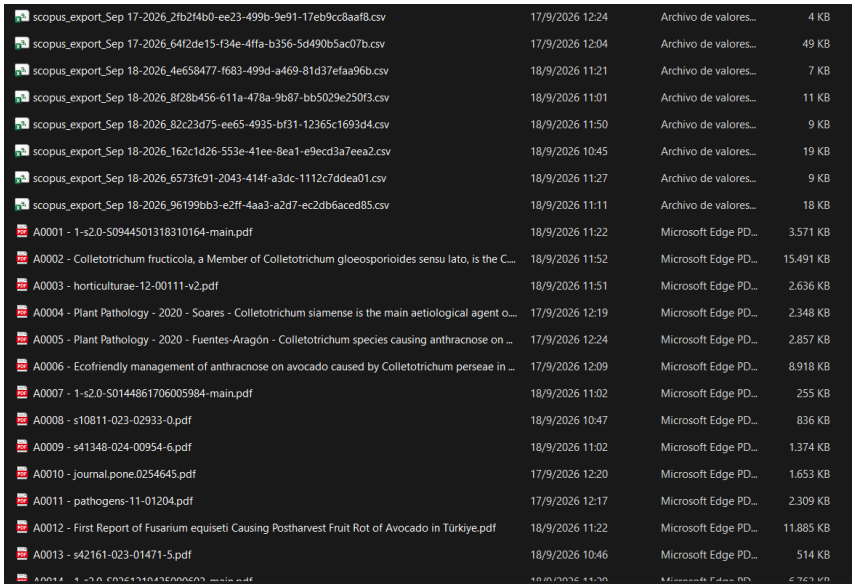


Ilustración 9 Exportaciones de Scopus y artículos renombrados con su identificador

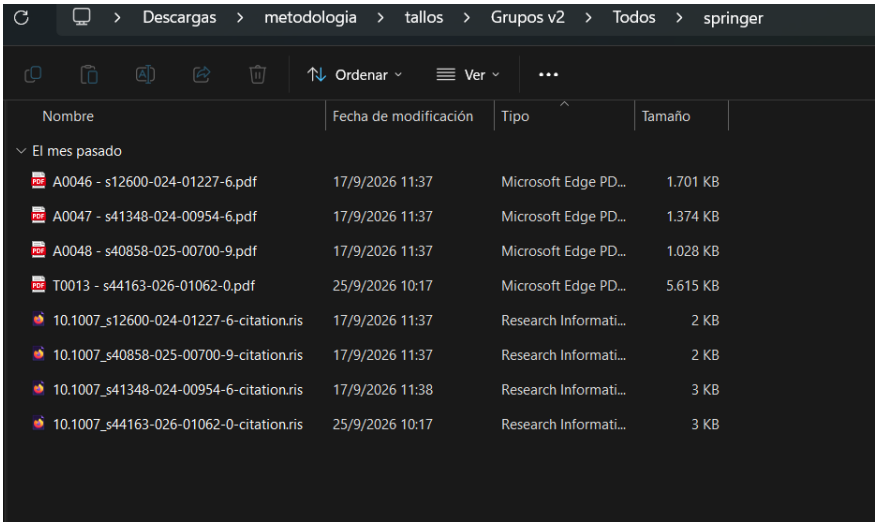


Ilustración 10 Artículos de Springer Link organizados en la carpeta Grupos v2

4. 24 de septiembre de 2026

Base_consolidada

Actividad 3 del itinerario. Registros únicos por base (78 exportados − 10 duplicados dentro de la misma base = 68), con su ID y categoría. Aún no se filtra nada: los duplicados entre bases y las

ID	Base de datos	Título completo	Autores	Año	DOI
A0001	Scopus	Avocado rhizobacteria emit volatile organic compounds with antifungal activity against Fusarium solani, Fusarium sp. associated with Kuroshio shot hole	Guevara-Avendaño E.; Bejarano-Bolívar A.A.; Kiel-	2019	10.1016/j.micres.2018.11.009
A0002	Scopus	Colletotrichum fructicola, a Member of Colletotrichum gloeosporioides sensu lato, is the causal agent of anthracnose and soft rot in avocado fruits cv.	Fuentes-Aragón D.; Juárez-Vázquez S.B.; Vargas-	2018	10.1080/12298093.2018.1454010
A0003	Scopus	Colletotrichum perseae and Colletotrichum gloeosporioides sensu strictu Causing Stem Lesion and Dieback in Avocado in Italy	Vecchio L.; Martino I.; Guarnaccia V.; Polizzi G.; Aiello	2026	10.3390/horticulturae12010111
A0004	Scopus	Colletotrichum siamense is the main aetiological agent of anthracnose of avocado in south-eastern Brazil	Soares M.G.O.; Alves E.; Silveira A.L.; Pereira F.D.;	2021	10.1111/ppa.13262
A0005	Scopus	Colletotrichum species causing anthracnose on avocado fruit in Mexico: Current status	Fuentes-Aragón D.; Silva-Rojas H.V.; Guarnaccia V.; Mora-	2020	10.1111/ppa.13234
A0006	Scopus	Ecofriendly management of anthracnose on avocado caused by Colletotrichum perseae in the Mediterranean basin	Vecchio L.; Arrebola E.; Polizzi G.; Vitale A.	2026	10.1002/jsf2.70088
A0007	Scopus	Effect of pectin-based edible emulsion coating on changes in quality of avocado exposed to Lasiodiplodia theobromae infection	Maftoonazad N.; Ramaswamy H.S.; Moalemiyan M.;	2007	10.1016/j.carbpol.2006.11.020
A0008	Scopus	Effect of seaweed extract on avocado root growth, yield and post-harvest quality in far north Queensland, Australia	Arioli T.; Villalta O.N.; Hepworth G.; Farnsworth B.;	2024	10.1007/s10811-023-02933-0
A0009	Scopus	Emerging pathogens and disease dynamics threatening avocado production in	Çalış Ö.; Çelik S.; Fidan H.; Tek	2024	10.1007/s41348-024-00954-6

Ilustración 11 Base consolidada de registros en la matriz de la SLR

Duplicados_y_exclusion

Se completa en la Actividad 4 del itinerario. Primer filtro: marca y descarta duplicados (mismo DOI/título) y exclusiones (revisiones/duros/ejos). Conserva un único registro por estudio. Cada descarte lleva su motivo.

ID origin	Base de dato	Título completo	DOI	Tipo de exclusión	Motivo de exclusión
A0001	Scopus	Avocado rhizobacteria emit volatile organic compounds with antifungal activity against Fusarium solani, Fusarium sp. associated with Kuroshio shot hole borer, and Colletotrichum gloeosporioides	10.1016/j.micres.2018.11.009	No aplica	Registro único y estudio primario; continúa al cribado.
A0002	Scopus	Colletotrichum fructicola, a Member of Colletotrichum gloeosporioides sensu lato, is the causal agent of anthracnose and soft rot in avocado fruits cv. "Hass"	10.1080/12298093.2018.1454010	No aplica	Registro único y estudio primario; continúa al cribado.
A0003	Scopus	Colletotrichum perseae and Colletotrichum gloeosporioides sensu strictu Causing Stem Lesion and Dieback in Avocado in Italy	10.3390/horticulturae12010111	No aplica	Registro único y estudio primario; continúa al cribado.
A0004	Scopus	Colletotrichum siamense is the main aetiological agent of anthracnose of avocado in south-eastern Brazil	10.1111/ppa.13262	No aplica	Registro único y estudio primario; continúa al cribado.
A0005	Scopus	Colletotrichum species causing anthracnose on avocado fruit in Mexico: Current status	10.1111/ppa.13234	No aplica	Registro único y estudio primario; continúa al cribado.
A0006	Scopus	Ecofriendly management of anthracnose on avocado caused by Colletotrichum perseae in the Mediterranean basin	10.1002/jsf2.70088	No aplica	Registro único y estudio primario; continúa al cribado.
A0007	Scopus	Effect of pectin-based edible emulsion coating on changes in quality of avocado exposed to Lasiodiplodia theobromae infection	10.1016/j.carbpol.2006.11.020	No aplica	Registro único y estudio primario; continúa al cribado.
A0008	Scopus	Effect of seaweed extract on avocado root growth, yield and post-harvest quality in far north Queensland, Australia	10.1007/s10811-023-02933-0	No aplica	Registro único y estudio primario; continúa al cribado.
A0009	Scopus	Emerging pathogens and disease dynamics threatening avocado production in southern Türkiye	10.1007/s41348-024-00954-6	No aplica	Registro único y estudio primario; continúa al cribado.
A0010	Scopus	Expression of several Phytophthora cinnamomi putative RxLRs	10.1371/journal.pone.02546	No aplica	Registro único y estudio primario; continúa al cribado.

Ilustración 12 Registro de duplicados y exclusiones en la matriz de la SLR

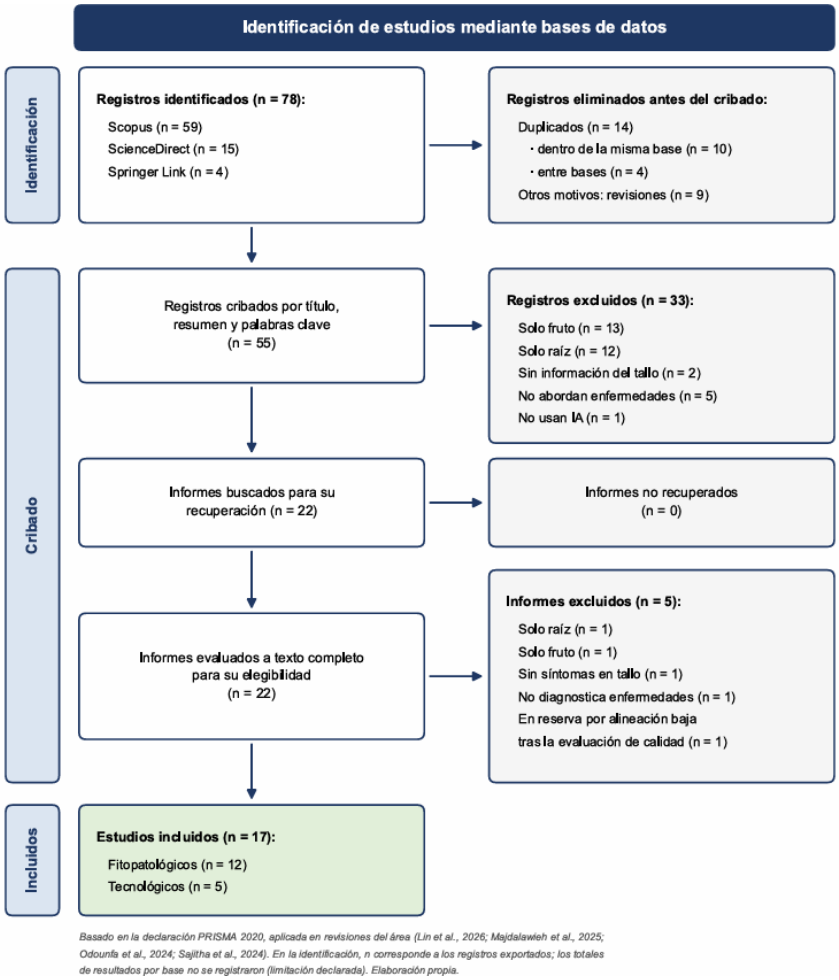


Ilustración 13 Diagrama de flujo PRISMA 2020 de la selección de estudios

5. 25 de septiembre de 2026

Calidad_articulos

Se completa en la Actividad 5 del itinerario. Calidad Q1–Q10 de los estudios elegibles tras el texto completo (0 = no cumple, 1 = parcial, 2 = cumple). Los criterios Q1–Q10 difieren según la categoría (ver hoja Protocolo). Total y nivel se calcul

ID	Base de datos	Titulo completo	Q1	Q2	Q3	Q4	Q5	Q6	Q7	Q8	Q9	Q10	Puntaje
A0003	Scopus	Colletotrichum perseae and Colletotrichum gloeosporioides sensu strictu Causing Stem Lesion and Dieback in Avocado in Italy	2	2	2	2	2	2	2	2	2	2	20
A0006	Scopus	Ecofriendly management of anthracnose on avocado caused by Colletotrichum perseae in the Mediterranean basin	2	2	1	2	2	2	0	2	2	2	17
A0009	Scopus	Emerging pathogens and disease dynamics threatening avocado production in southern Türkiye	2	1	1	2	2	2	2	2	1	2	17
A0014	Scopus	Four new fungal pathogens causing avocado dieback in Brazil	2	2	1	2	2	2	1	2	2	2	18

Ilustración 14 Evaluación de la calidad de los estudios con los criterios Q1–Q10

Articulos_finales

Se completa en la Actividad 6 del itinerario. Selección final razonada. Regla: Incluir si la calidad es Alta o Media y la alineación es Alta o Media; en otro caso, Reserva (se cita, pero no se usa en la síntesis). Columnas T–X solo para estudios tecnológicos.

ID	Base de datos	Título completo	Año	Autores	DOI	Tipo de estudio	Aporte principal
A0003	Scopus	Colletotrichum perseae and Colletotrichum gloeosporioides sensu strictu Causing Stem Lesion and Dieback in Avocado in Italy	2026	Vecchio L.; Martino I.; Guarnaccia V.; Polizzi G.; Aiello D.	10.3390/horticulturae12010111	Primario: observación en vivero, identificación y patogenicidad	Primer reporte de lesiones en el tallo y muerte descendente aguacate y primera detección de C. perseae en Europa.
A0006	Scopus	Ecofriendly management of anthracnose on avocado caused by Colletotrichum perseae in the Mediterranean basin	2026	Vecchio L.; Arrebola E.; Polizzi G.; Vitale A.	10.1002/jsfa.70088	Primario: experimental de manejo (biocontrol)	Los bioformulados redujeron entre 37 y 91 % las lesiones p ramillas; Trichoderma asperellum T34 redujo un 76,78 % la plantas.
A0009	Scopus	Emerging pathogens and disease dynamics threatening avocado production in southern Türkiye	2024	Çalış Ö.; Çelik S.; Fidan H.; Tek M.I.; Shah M.; Tozlu I.; Wani S.H.	10.1007/s41348-024-00954-6	Primario: encuesta de campo, identificación y patogenicidad	Incidencia de 33,89 % en 2537 árboles de 11 regiones; P. F. oxysporum causaron los cancros de rama más severos

Ilustración 15 Selección final de los artículos en la matriz de la SLR

Tabla A. Síntesis fitopatológica de los estudios incluidos (RQ1 y RQ2): agentes, síntomas en el tallo y detección

Autor [ref]	Estudio	Patógeno (género / especie)	Enfermedad	Síntomas en tallo	
Vecchio, Martino, et al. (2026) [A0003]	Colletotrichum perseae and Colletotrichum gloeosporioides sensu strictu Causing Stem Lesion and Dieback in Avocado in Italy	C. perseae; C. gloeosporioides s.s.	Lesión del tallo y muerte descendente (vivero)	Lesiones necróticas en brotes y tallos, decoloración de la madera, estrías pardo-rojizas y muerte descendente desde el injerto (incidencia > 45 %). La lesión externa media 2,5–3,2 cm y la decoloración interna 12,0–12,6 cm.	Insp PDA tub2 reai
Vecchio, Arrebola, et al. (2026) [A0006]	Ecofriendly management of anthracnose on avocado caused by Colletotrichum perseae in the Mediterranean basin	C. perseae (aislamiento APIN16)	Antracnosis de ramillas y tallo	Lesiones necróticas oscuras y alargadas en ramillas y tallos (Fig. 2); lesión interna media de 5,47 cm en el testigo.	Mec ANO
Çalış et al. (2024) [A0009]	Emerging pathogens and disease dynamics threatening avocado production in southern Türkiye	C. gloeosporioides; F. solani; F. oxysporum; N. parvum; L. theobromae; N. rosae; P. cinnamomi y M. phaseolina (tentativas, por morfología)	Muerte descendente y cancro de rama	Muerte descendente de 1 a 5 ramillas en la copa con lesiones > 10 cm en el 60–65 % de los árboles jóvenes; cancro de rama.	Regi PDA esp de l
Silva et al. (2025) [A0014]	Four new fungal pathogens causing avocado dieback in Brazil	Neopestalotiopsis arecacearum; Neocosmospora bostrycoides; Nectria pseudotrichia; Cytospora viridistroma	Muerte descendente	Marchitez, caída intensa de hojas, muerte descendente y necrosis interna; en plántulas, oscurecimiento del sistema vascular.	Aisl mor β-tu plár

Ilustración 16 Síntesis fitopatológica de los estudios incluidos

6. 28 de septiembre de 2026

2.3 Integración IA–IPO

Integrar IA e IPO significa diseñar no solo un modelo exacto, sino una interacción en la que el usuario capture bien la imagen, entienda el resultado y sepa cuándo confiar en él. Lin et al. (2026) advierten que la mayoría de los modelos obtenidos por destilación son opacos y que esta brecha de interpretabilidad limita la confianza de agricultores y agrónomos que deben decidir a partir de sus resultados; por ello proponen explicaciones en lenguaje natural ligadas a rasgos observables de la planta. Saini et al. (2026) describen otra forma de integración: guardar para revisión experta las predicciones con baja confianza, lo que mantiene a una persona en el ciclo de decisión y permite actualizar el modelo.

La calidad de la fotografía es también un problema de interacción. Las imágenes tomadas en campo cambian con la humedad, el ambiente y la intensidad de la luz, por lo que conviene capturar la misma muestra en distintos momentos, ángulos y condiciones (Sajitha et al., 2024); Majdalawieh et al. (2025) recomiendan además imágenes de alta resolución (≥ 12 MP), con iluminación controlada o carpas de luz portátiles, desde varios ángulos y con metadatos de contexto. Una pantalla de captura guiada puede trasladar estas recomendaciones al usuario. La Tabla 3 compara cómo los sistemas con aplicación recopilados resolvieron la relación entre el modelo y el usuario.

Tabla 3. *Elementos de integración IA–IPO en los sistemas de diagnóstico con aplicación recopilados*

Sistema	Resultado que ve el usuario	Explicación o confianza	Participación de usuarios	Limitación o dependencia
Ramana Reddy et al. (2025)	Enfermedad, puntaje de confianza, porcentaje de severidad y breve descripción.	Mapa Grad-CAM y puntaje de confianza.	Pruebas informales: interfaz intuitiva; la severidad ayuda a priorizar.	Inferencia en servidor (Wi-Fi); la inferencia sin conexión queda como trabajo futuro.
Christakakis et al. (2024)	Zonas afectadas marcadas con cajas y nivel de confianza.	Confianza por detección.	50 usuarios (20 agrónomos y 30 agricultores) en campo y cuestionario de experiencia; alta satisfacción.	Modelos en un sistema de apoyo a la decisión en el servidor.

Ilustración 17 Redacción de la integración IA–IPO en el estado del arte

2.4 Aplicaciones inteligentes en agricultura

La agricultura de precisión adapta las intervenciones a las condiciones de cada campo o sección de campo mediante teledetección, sistemas de información geográfica y aprendizaje automático (Majdalawieh et al., 2025). Sus herramientas incluyen sensores multiespectrales e hiperespectrales, cámaras RGB-D, vehículos aéreos no tripulados (UAV), robots e Internet de las cosas (Odounfa et al., 2024), integrados con IA para la detección de malezas, plagas y enfermedades (Sajitha et al., 2024). Saini et al. (2026) reportan que, en fincas de 50 a 500 hectáreas, la analítica en la nube unida a telemetría y alertas mejoró entre un 18 y un 25 % la programación de aplicaciones dirigidas de plaguicidas.

Respecto al tipo de imagen, Majdalawieh et al. (2025) encontraron que los modelos con imágenes RGB alcanzaron una exactitud media de 96,94 %, frente a 95,81 % con imágenes hiperespectrales o multiespectrales, que además son más costosas y exigen más cómputo; por ello, las imágenes RGB —como las de la cámara de un teléfono— son la opción preferida para aplicaciones a gran escala.

En el aguacate, la IA recopilada se ha aplicado sobre todo al fruto y a las hojas (Tabla 4). Destaca el caso de Guelac-Santillan et al. (2026), en Amazonas (Perú): los índices de vegetación obtenidos con un UAV describieron la variabilidad del dosel, pero ninguno se correlacionó significativamente con la incidencia de antracnosis foliar, por lo que los autores concluyen que, por sí solos, tienen una capacidad limitada para detectar la enfermedad.

Tabla 4. *Trabajos de IA y teledetección aplicados al aguacate en el material recopilado*

Estudio	Órgano	Tarea	Datos y técnica	Resultado reportado
Moreano et al. (2026)	Fruto	Diagnóstico de antracnosis y roña	674 imágenes; ensamble de cinco modelos de aprendizaje profundo en votación secuencial; aplicación web	Exactitud 99,03 %
Estrada et al. (2026)	Hoja	Estado de deshidratación (estrés hídrico)	Imágenes multiespectrales; ResNet18, MobileNetV3 y ConvNeXt-Tiny	Exactitud 0,99 (ResNet18)

Ilustración 18 Redacción de las aplicaciones inteligentes en agricultura

7. 29 de septiembre de 2026

2.5.2 Conjuntos de datos y brecha entre laboratorio y campo

Los conjuntos de datos determinan el desempeño de los modelos. La Tabla 5 compara los conjuntos públicos más citados en las fuentes recopiladas.

Tabla 5. *Conjuntos de datos de enfermedades vegetales citados en las revisiones recopiladas*

Conjunto	Imágenes	Clases	Condiciones de captura	Observaciones
PlantVillage	54 309	38	Laboratorio, fondos uniformes	El más usado (36 de 150 estudios); riesgo de sobreajuste a condiciones controladas.
PlantDoc	2 598	17 (13 especies)	Entornos reales (imágenes reunidas de Internet)	Más diverso, pero con algunas enfermedades mal clasificadas.
PDD271	220 592	271	Campo (frutales, hortalizas y cultivos extensivos)	Desbalance: las 20 clases principales reúnen más del 50 % de las imágenes.
CCMT	102 976	22	Marañón, yuca, maíz y tomate	Orientado a aplicaciones de reconocimiento y detección.
Plant Pathology 2021-FGVC8	18 632	5 tipos de enfermedad	No se detalla	Listado entre los conjuntos públicos de la revisión sobre destilación.
Conjuntos propios de campo	Variable	Variable	Campo, protocolos propios	Predominan en los estudios recientes, pero su alcance limitado dificulta la reproducibilidad y la comparación.

Nota. Elaboración propia a partir de Lin et al. (2026), Majdalawieh et al. (2025), Odounfa et al. (2024), Saini et al. (2026) y Sajitha et al. (2024). Ninguno de los conjuntos incluye imágenes de tallos de aguacate.

Ilustración 19 Conjuntos de datos de enfermedades vegetales en el estado del arte

8. 30 de septiembre de 2026

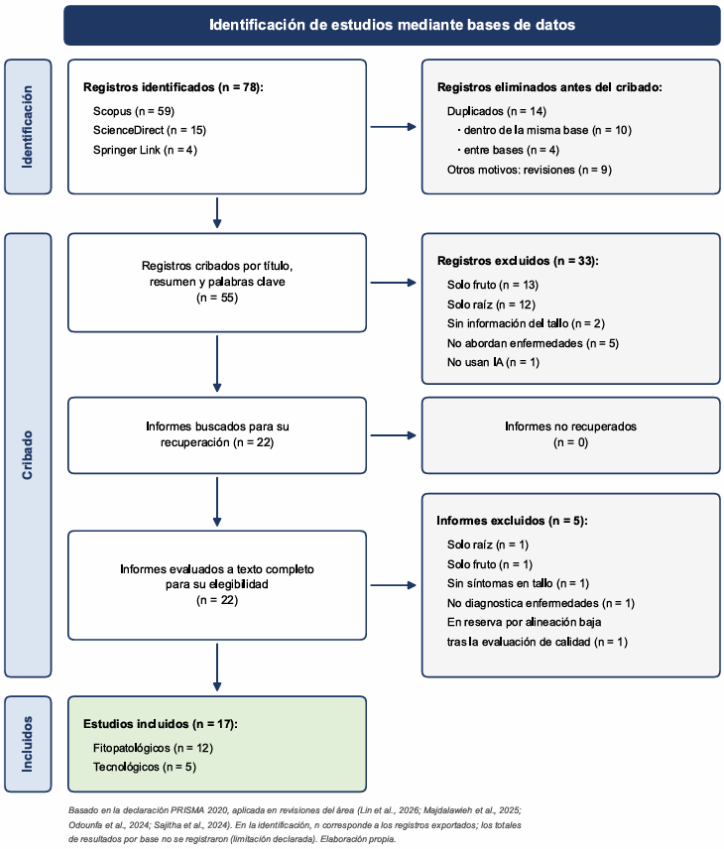


Ilustración 20 Verificación del diagrama de flujo PRISMA 2020

9. 01 de octubre de 2026

Prácticas preprofesionales – Departamento de Ciencias de la Computación
Universidad de las Fuerzas Armadas ESPE
Autor/a: Ariel Llumiquinga
Tutora: Ing. Doris Chicaiza
Proyecto: Smart Agriculture
Actividad del itinerario: 8. Redacción del borrador de la SLR (tareas T23–T26)
Versión: 1 (borrador)
Fecha: 2 de octubre de 2026.
Estado: Borrador para revisión de la tutora.

Enfermedades del tallo del aguacate (*Persea americana*) y sistemas basados en inteligencia artificial para su diagnóstico en el marco de la agricultura inteligente: revisión sistemática de la literatura

Resumen

Las enfermedades del tallo, las ramas y el tronco comprometen la estructura y la productividad del aguacate, y su diagnóstico depende hoy del laboratorio. Esta revisión sistemática analizó la evidencia sobre esas enfermedades y sobre los sistemas basados en inteligencia artificial (IA) para diagnosticar enfermedades en cultivos, con el fin de fundamentar una aplicación móvil de diagnóstico en tallos de aguacate. Se siguieron las directrices de Kitchenham y Charters (como se citó en Martinelli et al., 2024) y el reporte se ajustó a la declaración PRISMA 2020. Dieciséis cadenas ejecutadas en Scopus, ScienceDirect y Springer Link exportaron 78 registros; tras retirar 14 duplicados y 9 revisiones, se cribaron 55, se evaluaron 22 a texto completo y se incluyeron 17 estudios (12 fitopatológicos y 5 tecnológicos); 1 quedó en reserva. Todos los estudios incluidos obtuvieron calidad alta. Botryosphaeriaceae fue el grupo de patógenos dominante, con *Neofusicoccum parvum* como la especie más reportada, seguido de *Colletotrichum*, *Phytophthora* y *Fusarium*; los estudios proceden de la cuenca mediterránea, Sudamérica y México, y ninguno de Ecuador. Los síntomas externos —cancros con exudado blanquecino, corteza oscura y agrietada, muerte descendente desde el ápice y lesiones desde el injerto— pueden fotografiarse, pero se superponen entre patógenos, y la necrosis interna avanza antes que la externa. Ningún estudio aplicó IA al tallo: los sistemas tecnológicos trabajan con hojas o frutos, procesan la imagen en un servidor, no funcionan sin conexión y solo uno evaluó formalmente a sus usuarios. Se recomienda una aplicación que clasifique tipos de síntoma del tallo, entrenada con imágenes propias de campo, con modelos ligeros ejecutados en el teléfono y evaluada con agricultores y técnicos.

Palabras clave: aguacate; enfermedades del tallo; Botryosphaeriaceae; aprendizaje profundo;

Ilustración 21 Borrador de la SLR: portada y resumen

3.5 Técnicas de IA, conjuntos de datos y métricas (RQ3)

Los cinco estudios tecnológicos usan aprendizaje profundo y trabajan con hojas o frutos; ninguno aborda el tallo (Tabla 7). Predominan las CNN preentrenadas (VGG16, ResNet50, DenseNet121) y los detectores YOLO: Iqbal et al. (2026) obtuvieron 98 % de exactitud con VGG16 frente a 80–96 % de los demás modelos, y Moreano et al. (2026) un 99,03 % con un ensamble de cinco CNN. Los conjuntos de datos son pequeños o de laboratorio: 674 imágenes de fruto (Moreano et al., 2026), un subconjunto de PlantVillage (Ramana Reddy et al., 2025) o clases con 22 a 30 imágenes (Kochhar et al., 2026); solo dos usan imágenes propias de campo (Iqbal et al., 2026; Christakakis et al., 2024). La validación suele ser una partición única; dos estudios aplican validación cruzada (Iqbal et al., 2026; Kochhar et al., 2026), y ninguno se valida con un conjunto de campo independiente. El mismo enfoque rinde de forma muy distinta según el cultivo: de 44 a 95 % en Kochhar et al. (2026).

Tabla 7. *Técnicas de IA, conjuntos de datos y métricas de los estudios tecnológicos*

Estudio [ID]	Modelo o técnica	Conjunto de datos	Métrica (resultado)
Moreano et al. (2026) [T0002]	Ensamble VotingBS de cinco CNN (ResNet50, InceptionV3, EfficientNetB2, VGG16 y DenseNet121) en dos etapas	674 imágenes de fruto (351 de Kaggle y el resto de fuentes en línea verificadas); 3 clases	Exactitud 99,03 %; precisión 98,92 %; exhaustividad 98,89 % (validación hold-out 85/15)
Iqbal et al. (2026) [T0009]	RF, VGG16, CNN propia, YOLOv5, YOLOv8 y DETR	Conjunto propio de campo fotografiado con teléfono de 64 MP: trigo (4 clases) y guisante (3180 imágenes, 4 clases)	Exactitud: VGG16 98 %, DETR 96 %, CNN 92 %, RF 89 %, YOLOv8 87 %, YOLOv5 80 % (80/20 y validación cruzada)
Ramana Reddy et al. (2025) [T0010]	CNN propia (PyTorch); severidad con OpenCV; Grad-CAM	Subconjunto binario (sano / enfermo) de PlantVillage	Exactitud 92,06 %; precisión, exhaustividad y F1 ≈ 90 % (prueba hold-out)
Christakakis et al. (2024) [T0011]	YOLOv8 (variantes n a x; se eligió YOLOv8l)	659 imágenes de campo e invernadero (EDEN Library) con 8710 anotaciones	mAP50 70,2 % (conjunto de validación)
Kochhar et al. (2026) [T0013]	CNN y VGG-16 optimizado (10 modelos)	Imágenes de campo (Ludhiana) y públicas; 19 clases de enfermedad en 5 cultivos	Exactitud de 44,15 % (arroz) a 95,23 % (maíz), con validación cruzada estratificada repetida

Nota. Elaboración propia a partir de la hoja Articulos_finales de la matriz.

Ilustración 22 Redacción de los resultados sobre técnicas de IA, conjuntos de datos y métricas

4.4 Brechas y oportunidades para la aplicación (RQ5)

La Tabla 9 resume las brechas identificadas y cómo las abordará el proyecto en las siguientes actividades del itinerario.

Tabla 9. *Brechas, evidencia y oportunidades para la aplicación móvil de diagnóstico en tallos*

Brecha	Evidencia	Oportunidad para el proyecto
No hay sistemas de IA para el tallo del aguacate; la IA se ha centrado en hojas y frutos.	Moreano et al. (2026); Sajitha et al. (2024); Tabla 7	Primer sistema enfocado en el tallo (Act. 13 a 20).
No existen conjuntos de imágenes de tallos ni estudios de Ecuador.	Tabla 5; Majdalawieh et al. (2025)	Conjunto propio de campo con metadatos y varias tomas por planta (Act. 10 a 12).
Los síntomas se superponen y hay coinfecciones.	Linaldeddu et al. (2026); Hernández et al. (2023); Möller et al. (2025)	Clases por tipo de síntoma, validadas con la tutora (Act. 10).
La foto subestima el daño interno y no detecta infecciones latentes.	Rodríguez-Gálvez et al. (2025); Vecchio, Martino, et al. (2026); Valencia et al. (2022)	Advertencias en el resultado y recomendación de confirmar en laboratorio (Act. 17).
Pocas escalas visuales de severidad del tallo.	Guirado-Manzano et al. (2026); Valencia et al. (2022); Solís-García et al. (2021)	Escala de severidad adaptada para el etiquetado (Act. 12).
Los sistemas dependen del servidor y de Internet.	Ramana Reddy et al. (2025); Kochhar et al. (2026)	Modelo ligero ejecutado en el teléfono sin conexión (Act. 19 y 20).
No hay validación en campo independiente.	Tabla 7; Saini et al. (2026)	Prueba final con imágenes nuevas de tallos tomadas en campo (Act. 15 y 22).
La evaluación con usuarios es escasa y poco interpretable.	Christakakis et al. (2024); Lin et al. (2026); Martinelli et al. (2024)	Diseño centrado en el usuario, explicación del resultado y pruebas con agricultores (Act. 16, 17 y 21).

Nota. Elaboración propia. Las actividades corresponden al itinerario de prácticas.

Ilustración 23 Redacción de las brechas y oportunidades para la aplicación

10. 02 de octubre de 2026

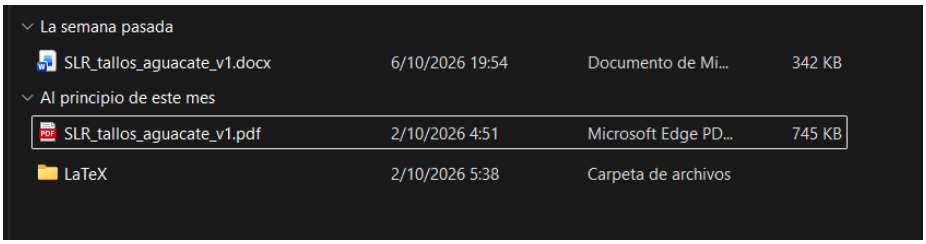


Ilustración 24 Borrador de la SLR en Word, PDF y LaTeX

11. 05 de octubre de 2026

1 Introducción

Este documento especifica los requisitos del prototipo de aplicación móvil TalloSano, que forma parte del proyecto Smart Agriculture. La aplicación toma o recibe una foto del tallo del aguacate, revisa que sea clara, la analiza con el modelo de inteligencia artificial definido en el SRS-2 dentro del propio teléfono y muestra un resultado orientativo. Funciona igual con o sin conexión a Internet.

1.1 Propósito

Especificar qué debe hacer el prototipo TalloSano y con qué condiciones, para guiar su desarrollo y sus pruebas funcionales.
Dirigido al autor, que desarrolla la aplicación, y a la tutora, que revisa y valida el documento.

1.2 Alcance

- Producto: TalloSano, versión 0.1 (prototipo Android).
- Incluye: cuenta local (registro, inicio y cierre de sesión), captura guiada o elección de una foto, revisión de la calidad de la foto, análisis en el teléfono, resultado orientativo con su confianza, historial guardado en el dispositivo, ayuda e indicador "En línea / Sin conexión".
- No incluye: otros cultivos u órganos (el selector de casos del prototipo es para versiones futuras), identificación del hongo, recomendación de tratamientos, servidor, respaldo en la nube, recuperación de contraseña por correo ni versión para iPhone.
- Los requisitos funcionales son los casos de uso, y los requisitos no funcionales se describen en el mismo documento de casos de uso.
- Es coherente con el SRS-1 (conjunto de datos) y el SRS-2 (modelo de IA), y con los casos de uso del documento Casos_de_uso_TalloSano_v0.1.

Ilustración 25 Redacción de la introducción del SRS de la aplicación TalloSano

1.3 Personal involucrado

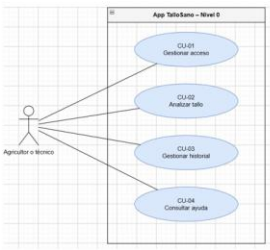
Nombre	Ariel Llumiquinga
Rol	Autor y desarrollador de la aplicación
Categoría profesional	Estudiante de prácticas preprofesionales, Ingeniería de Software
Responsabilidades	Especificar los requisitos, desarrollar la aplicación, integrar el modelo y ejecutar las pruebas funcionales.
Información de contacto	ajllumiquinga2@espe.edu.ec

Nombre	Ing. Doris Chicaiza
Rol	Tutora y revisora
Categoría profesional	Docente, Departamento de Ciencias de la Computación, ESPE
Responsabilidades	Revisar y validar este documento y el prototipo.
Información de contacto	—

Ilustración 26 Personal involucrado en el SRS de la aplicación

12. 06 de octubre de 2026

NIVEL 0



Caso de uso: CU-01	Gestionar acceso
Actor(es):	Agricultor o técnico (iniciador)
Propósito:	Permitir que cada usuario tenga su propia cuenta en el teléfono para entrar a la app y mantener separado su historial de análisis.
Descripción:	A partir de la pantalla de bienvenida, el usuario crea una cuenta local con su nombre, usuario y contraseña, o inicia sesión si ya la tiene; la

Ilustración 27 Diagrama de casos de uso de nivel 0 y caso de uso CU-01 Gestionar acceso

13. 07 de octubre de 2026

Cada requisito funcional corresponde a un caso de uso. Su descripción completa (precondiciones, secuencia normal, postcondiciones y excepciones) está en el documento Casos_de_uso_TalloSano_v0.1; cada título enlaza a ese documento.

No. de requisito	Nombre de requisito	Prioridad	Responsable
RF-01	Registrarse (CU 1.1)	Alta/Esencial	Autor
RF-02	Iniciar sesión (CU 1.2)	Alta/Esencial	Autor
RF-03	Cerrar sesión (CU 1.3)	Media/Deseado	Autor
RF-04	Tomar foto (CU 2.1)	Alta/Esencial	Autor
RF-05	Elegir imagen de la galería (CU 2.2)	Alta/Esencial	Autor
RF-06	Revisar foto (CU 2.3)	Alta/Esencial	Autor
RF-07	Ver resultado (CU 2.4)	Alta/Esencial	Autor

Descripción de requisitos del sofware

Ilustración 28 Requisitos funcionales del SRS de la aplicación TalloSano

Los requisitos no funcionales están descritos con su criterio de aceptación y su forma de verificación en la sección "Requisitos no funcionales" de Casos_de_uso_TalloSano_v0.1.

No. de requisito	Nombre de requisito	Tipo	Prioridad	Responsable
RNF-01	Tiempo de respuesta	Rendimiento	Alta/Esencial	Autor
RNF-02	Tamaño de la aplicación	Rendimiento	Media/Deseado	Autor
RNF-03	Contraseña cifrada	Seguridad	Alta/Esencial	Autor
RNF-04	Contraseña mínima	Seguridad	Media/Deseado	Autor
RNF-05	Datos solo en el teléfono	Seguridad	Alta/Esencial	Autor
RNF-06	Historial por usuario	Seguridad	Alta/Esencial	Autor
RNF-07	Permisos mínimos	Seguridad	Alta/Esencial	Autor
RNF-08	Estabilidad	Fiabilidad	Alta/Esencial	Autor
RNF-09	Manejo de errores	Fiabilidad	Media/Deseado	Autor
RNF-10	Funcionamiento con y sin Internet	Disponibilidad	Alta/Esencial	Autor
RNF-11	Indicador de conexión	Disponibilidad	Media/Deseado	Autor
		Usabilida	Alta/Esen	

Ilustración 29 Requisitos no funcionales del SRS de la aplicación TalloSano

1. 08 de octubre de 2026

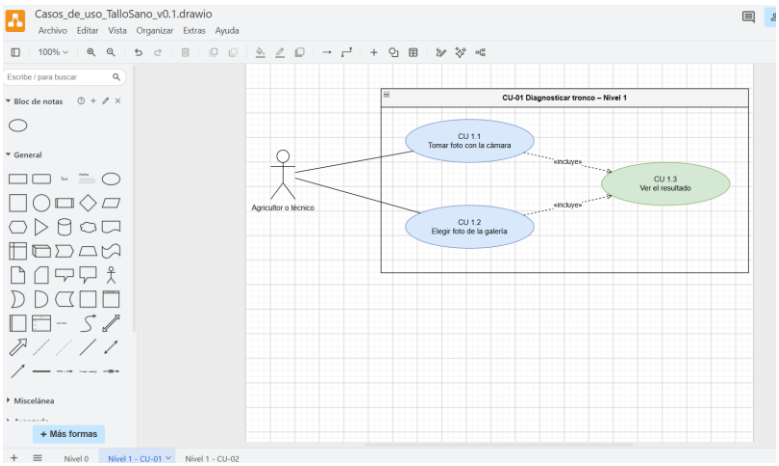


Ilustración 30 Diagrama de casos de uso de nivel 1: CU-01 Diagnosticar tronco

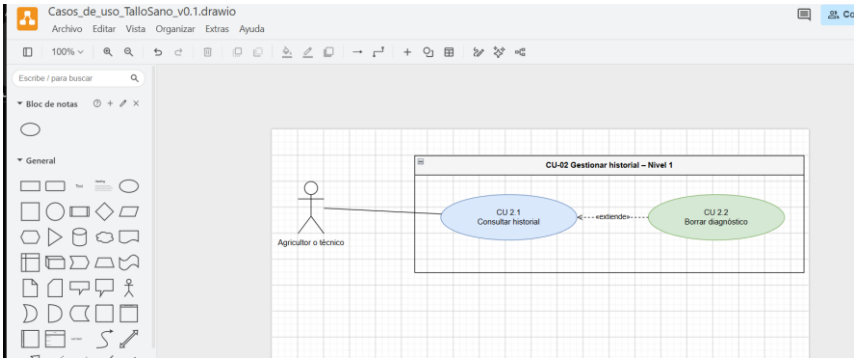


Ilustración 31 Diagrama de casos de uso de nivel 1: CU-02 Gestionar historial

CU 1.1	Registrarse (RF-01)

Descripción	Crear una cuenta local para usar la app en el teléfono.
Precondición	La app está instalada. El usuario no tiene una cuenta en este teléfono.
Secuencia normal	Acción (Actor / Proceso)
1	Usuario: Abre la app y selecciona “Crear cuenta”.
2	Sistema: Muestra el formulario de registro.
3	Usuario: Ingresa su nombre, un nombre de usuario y una

Ilustración 32 Especificación del caso de uso CU 1.1 Registrarse

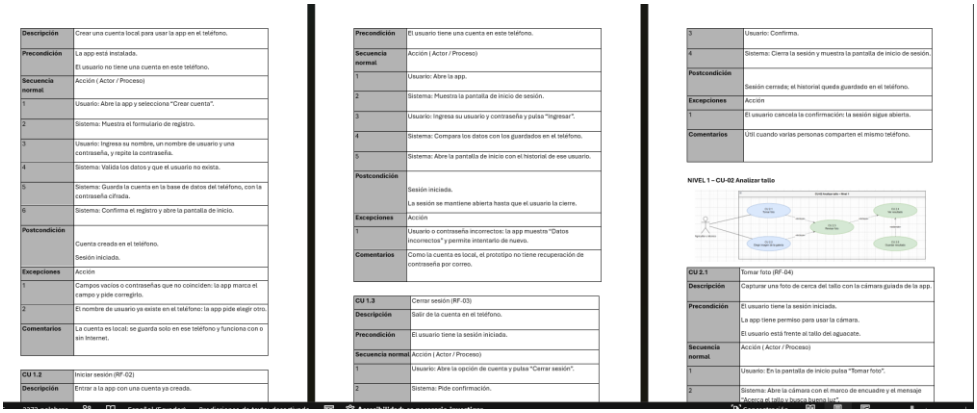
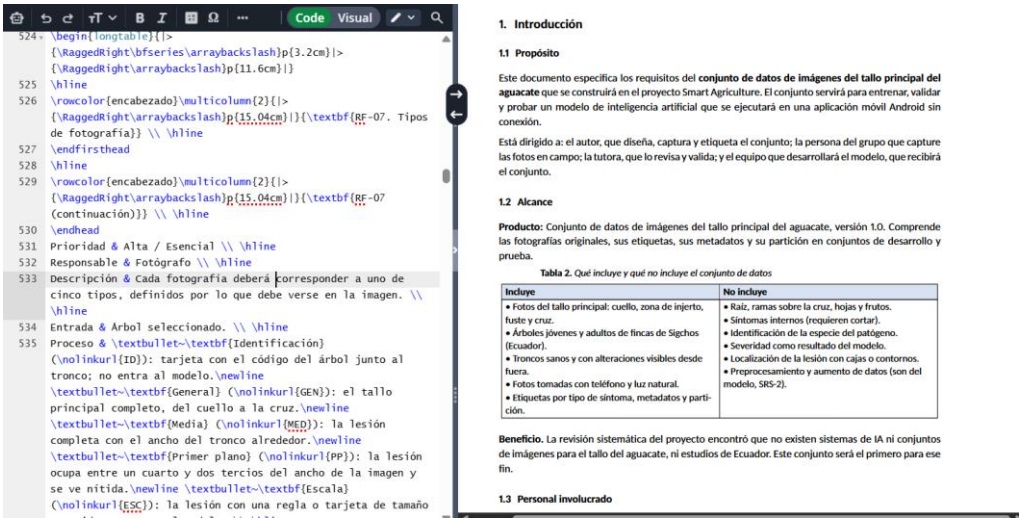


Ilustración 33 Especificación de los casos de uso de acceso y de CU-02 Analizar tallo

2. 12 de octubre de 2026



```
\begin{longtable}{|>
{\RaggedRight\bfseries\arraybackslash}p{3.2cm}|>
{\RaggedRight\arraybackslash}p{11.6cm}|}
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RF-07. Tipos
de fotografía}} \\ \hline
\endfirsthead
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RF-07
(continuación)}} \\ \hline
\endhead
Prioridad & Alta / Esencial \\ \hline
Responsable & Fotógrafo \\ \hline
Descripción & Cada fotografía deberá corresponder a uno de
cinco tipos, definidos por lo que debe verse en la imagen. \\
\hline
Entrada & Árbol seleccionado. \\ \hline
Proceso & \textbullet~\textbf{Identificación}
(\nolinkurl{ID}): tarjeta con el código del árbol junto al
tronco; no entra al modelo.\newline
\textbullet~\textbf{General} (\nolinkurl{GEN}): el tallo
principal completo, del cuello a la cruz.\newline
\textbullet~\textbf{Media} (\nolinkurl{MED}): la lesión
completa con el ancho del tronco alrededor.\newline
\textbullet~\textbf{Primer plano} (\nolinkurl{PP}): la lesión
ocupa entre un cuarto y dos tercios del ancho de la imagen y
se ve nítida.\newline \textbullet~\textbf{Escala}
(\nolinkurl{ESC}): la lesión con una regla o tarjeta de tamaño
```

1. Introducción

1.1 Propósito

Este documento especifica los requisitos del **conjunto de datos de imágenes del tallo principal del aguacate** que se construirá en el proyecto Smart Agriculture. El conjunto servirá para entrenar, validar y probar un modelo de inteligencia artificial que se ejecutará en una aplicación móvil Android sin conexión.

Está dirigido a: el autor, que diseña, captura y etiqueta el conjunto; la persona del grupo que capture las fotos en campo; la tutora, que lo revisa y valida; y el equipo que desarrollará el modelo, que recibirá el conjunto.

1.2 Alcance

Producto: Conjunto de datos de imágenes del tallo principal del aguacate, versión 1.0. Comprende las fotografías originales, sus etiquetas, sus metadatos y su partición en conjuntos de desarrollo y prueba.

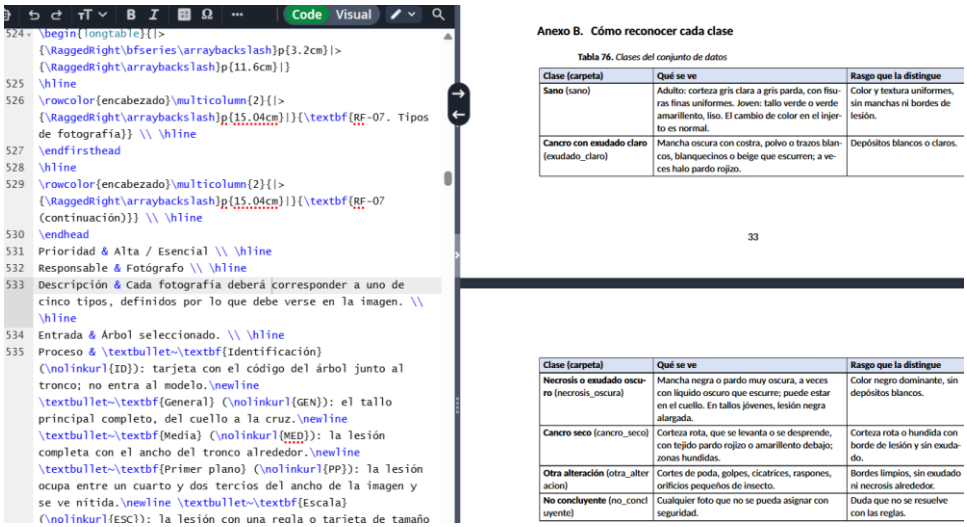
Tabla 2. *Qué incluye y qué no incluye el conjunto de datos*

Incluye	No incluye
• Fotos del tallo principal: cuello, zona de injerto, fuste y cruz. • Árboles jóvenes y adultos de fincas de Sigchos (Ecuador). • Troncos sanos y con alteraciones visibles desde fuera. • Fotos tomadas con teléfono y luz natural. • Etiquetas por tipo de síntoma, metadatos y partición.	• Raíz, ramas sobre la cruz, hojas y frutos. • Síntomas internos (requieren cortar). • Identificación de la especie del patógeno. • Severidad como resultado del modelo. • Localización de la lesión con cajas o contornos. • Preprocesamiento y aumento de datos (son del modelo, SRS-2).

Beneficio. La revisión sistemática del proyecto encontró que no existen sistemas de IA ni conjuntos de imágenes para el tallo del aguacate, ni estudios de Ecuador. Este conjunto será el primero para ese fin.

1.3 Personal involucrado

Ilustración 34 Redacción en LaTeX del SRS del conjunto de datos: introducción y tipos de fotografía



```
\begin{longtable}{|>
{\RaggedRight\bfseries\arraybackslash}p{3.2cm}|>
{\RaggedRight\arraybackslash}p{11.6cm}|}
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RF-07. Tipos
de fotografía}} \\ \hline
\endfirsthead
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RF-07
(continuación)}} \\ \hline
\endhead
Prioridad & Alta / Esencial \\ \hline
Responsable & Fotógrafo \\ \hline
Descripción & Cada fotografía deberá corresponder a uno de
cinco tipos, definidos por lo que debe verse en la imagen. \\
\hline
Entrada & Árbol seleccionado. \\ \hline
Proceso & \textbullet~\textbf{Identificación}
(\nolinkurl{ID}): tarjeta con el código del árbol junto al
tronco; no entra al modelo.\newline
\textbullet~\textbf{General} (\nolinkurl{GEN}): el tallo
principal completo, del cuello a la cruz.\newline
\textbullet~\textbf{Media} (\nolinkurl{MED}): la lesión
completa con el ancho del tronco alrededor.\newline
\textbullet~\textbf{Primer plano} (\nolinkurl{PP}): la lesión
ocupa entre un cuarto y dos tercios del ancho de la imagen y
se ve nítida.\newline \textbullet~\textbf{Escala}
(\nolinkurl{ESC}): la lesión con una regla o tarjeta de tamaño
```

Anexo B. Cómo reconocer cada clase

Tabla 76. *Clases del conjunto de datos*

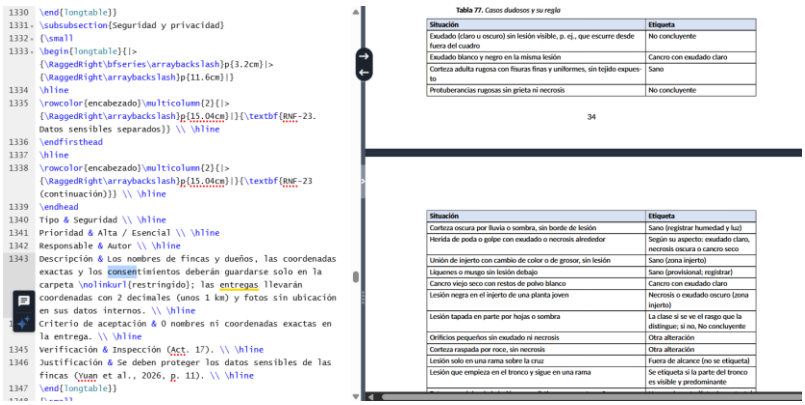
Clase (carpeta)	Qué se ve	Rasgo que la distingue
Sano (sano)	Adulto: corteza gris clara a gris parda, con fisuras finas uniformes. Joven: tallo verde o verde amarillento, liso. El cambio de color en el injerto es normal.	Color y textura uniformes, sin manchas ni bordes de lesión.
Cancro con exudado claro (exudado_claro)	Mancha oscura con costra, polvo o trazos blancos, blanquecinos o beige que escurren; a veces halo pardo rojizo.	Depósitos blancos o claros.

33

Clase (carpeta)	Qué se ve	Rasgo que la distingue
Necrosis o exudado oscuro (necrosis_oscura)	Mancha negra o pardo muy oscura, a veces con líquido oscuro que escurre; puede estar en el cuello. En tallos jóvenes, lesión negra alargada.	Color negro dominante, sin depósitos blancos.
Cancro seco (cancro_seco)	Corteza rota, que se levanta o se desprende, con tejido pardo rojizo o amarillento debajo; zonas hundidas.	Corteza rota o hundida con borde de lesión y sin exudado.
Otra alteración (otra_alteracion)	Cortes de poda, golpes, cicatrices, raspones, orificios pequeños de insecto.	Bordes limpios, sin exudado ni necrosis alrededor.
No concluyente (no_concluyente)	Cualquier foto que no se pueda asignar con seguridad.	Duda que no se resuelve con las reglas.

Ilustración 35 Clases del conjunto de datos en el Anexo B del SRS

3. 13 de octubre de 2026



```
\end{longtable}}
\subsubsection{Seguridad y privacidad}
{\small
\begin{longtable}{|>
{\RaggedRight\bfseries\arraybackslash}p{3.2cm}|>
{\RaggedRight\arraybackslash}p{11.6cm}|}
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RNF-23.
Datos sensibles separados}} \\ \hline
\endfirsthead
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RNF-23
(continuación)}} \\ \hline
\endhead
Tipo & Seguridad \\ \hline
Prioridad & Alta / Esencial \\ \hline
Responsable & Autor \\ \hline
Descripción & Los nombres de fincas y dueños, las coordenadas
exactas y los consentimientos deberán guardarse solo en la
carpeta \nolinkurl{restringido}; las entregas llevarán
coordenadas con 2 decimales (unos 1 km) y fotos sin ubicación
en sus datos internos. \\ \hline
Criterio de aceptación & 0 nombres ni coordenadas exactas en
la entrega. \\ \hline
Verificación & Inspección (Act. 17). \\ \hline
Justificación & Se deben proteger los datos sensibles de las
fincas (Yuan et al., 2026, p. 11). \\ \hline
\end{longtable}}
```

Tabla 77. *Casos dudosos y su regla*

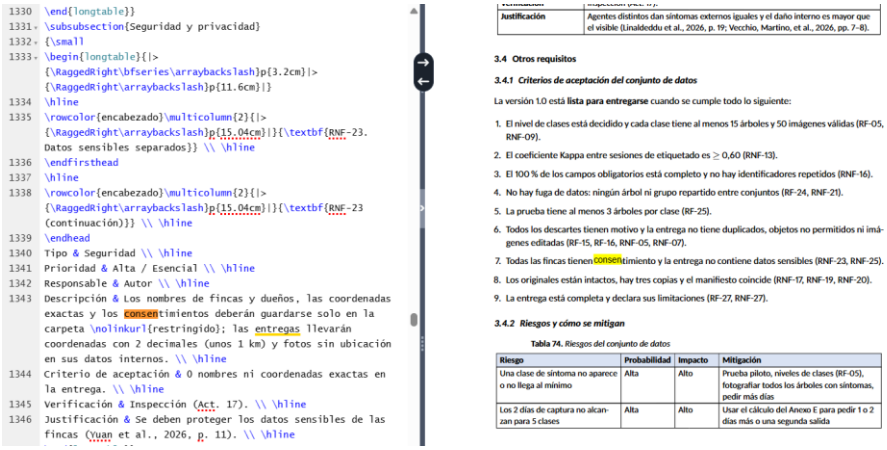
Situación	Etiqueta
Exudado (claro u oscuro) sin lesión visible, p. ej., que escurre desde fuera del cuadro	No concluyente
Exudado blanco y negro en la misma lesión	Cancro con exudado claro
Corteza adulta rugosa con fisuras finas y uniformes, sin tejido expuesto	Sano
Protuberancias rugosas sin grieta ni necrosis	No concluyente

34

Situación	Etiqueta
Corteza oscura por lluvia o sombra, sin borde de lesión	Sano (registrar humedad y luz)
Herida de poda o golpe con exudado o necrosis alrededor	Según su aspecto: exudado claro, necrosis oscura o cancro seco
Unión de injerto con cambio de color o de grosor, sin lesión	Sano (zona injerto)
Líquenes o musgo sin lesión debajo	Sano (provisional; registrar)
Cancro viejo seco con restos de polvo blanco	Cancro con exudado claro
Lesión negra en el injerto de una planta joven	Necrosis o exudado oscuro (zona injerto)
Lesión tapada en parte por hojas o sombra	La clase si se ve el rasgo que la distingue; si no, No concluyente
Orificios pequeños sin exudado ni necrosis	Otra alteración
Corteza raspada por roce, sin necrosis	Otra alteración
Lesión solo en una rama sobre la cruz	Fuera de alcance (no se etiqueta)
Lesión que empieza en el tronco y sigue en una rama	Se etiqueta si la parte del tronco es visible y predominante

Ilustración 36 Redacción en LaTeX del SRS del conjunto de datos: seguridad y casos dudosos

4. 14 de octubre de 2026



```
\end{longtable}}
\subsubsection{Seguridad y privacidad}
{\small
\begin{longtable}{|>
{\RaggedRight\bfseries\arraybackslash}p{3.2cm}|>
{\RaggedRight\arraybackslash}p{11.6cm}|}
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RNF-23.
Datos sensibles separados}} \\ \hline
\endfirsthead
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RNF-23
(continuación)}} \\ \hline
\endhead
Tipo & Seguridad \\ \hline
Prioridad & Alta / Esencial \\ \hline
Responsable & Autor \\ \hline
Descripción & Los nombres de fincas y dueños, las coordenadas
exactas y los consentimientos deberán guardarse solo en la
carpeta \nolinkurl{restringido}; las entregas llevarán
coordenadas con 2 decimales (unos 1 km) y fotos sin ubicación
en sus datos internos. \\ \hline
Criterio de aceptación & 0 nombres ni coordenadas exactas en
la entrega. \\ \hline
Verificación & Inspección (Act. 17). \\ \hline
Justificación & Se deben proteger los datos sensibles de las
fincas (Yuan et al., 2026, p. 11). \\ \hline
```

Justificación	Agentes distintos dan síntomas externos iguales y el daño interno es mayor que el visible (Linaldeddu et al., 2026, p. 19; Vecchio, Martino, et al., 2026, pp. 7–8).

3.4 Otros requisitos

3.4.1 Criterios de aceptación del conjunto de datos

La versión 1.0 está **lista para entregarse** cuando se cumple todo lo siguiente:

1. El nivel de clases está decidido y cada clase tiene al menos 15 árboles y 50 imágenes válidas (RF-05, RNF-09).
2. El coeficiente Kappa entre sesiones de etiquetado es ≥ 0,60 (RNF-13).
3. El 100 % de los campos obligatorios está completo y no hay identificadores repetidos (RNF-16).
4. No hay fuga de datos: ningún árbol ni grupo repartido entre conjuntos (RF-24, RNF-21).
5. La prueba tiene al menos 3 árboles por clase (RF-25).
6. Todos los descartes tienen motivo y la entrega no tiene duplicados, objetos no permitidos ni imágenes editadas (RF-15, RF-16, RNF-05, RNF-07).
7. Todas las fincas tienen consentimiento y la entrega no contiene datos sensibles (RNF-23, RNF-25).
8. Los originales están intactos, hay tres copias y el manifiesto coincide (RNF-17, RNF-19, RNF-20).
9. La entrega está completa y declara sus limitaciones (RF-27, RNF-27).

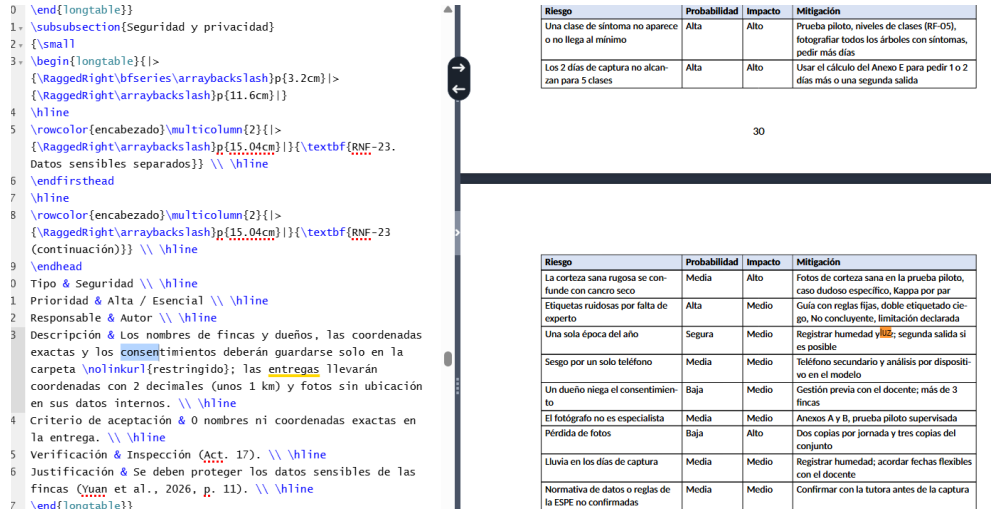
3.4.2 Riesgos y cómo se mitigan

Tabla 74. *Riesgos del conjunto de datos*

Riesgo	Probabilidad	Impacto	Mitigación
Una clase de síntoma no aparece o no llega al mínimo	Alta	Alto	Prueba piloto, niveles de clases (RF-05), fotografiar todos los árboles con síntomas, pedir más días
Los 2 días de captura no alcanzan para 5 clases	Alta	Alto	Usar el cálculo del Anexo E para pedir 1 o 2 días más o una segunda salida

Ilustración 37 Criterios de aceptación del conjunto de datos en el SRS

5. 15 de octubre de 2026



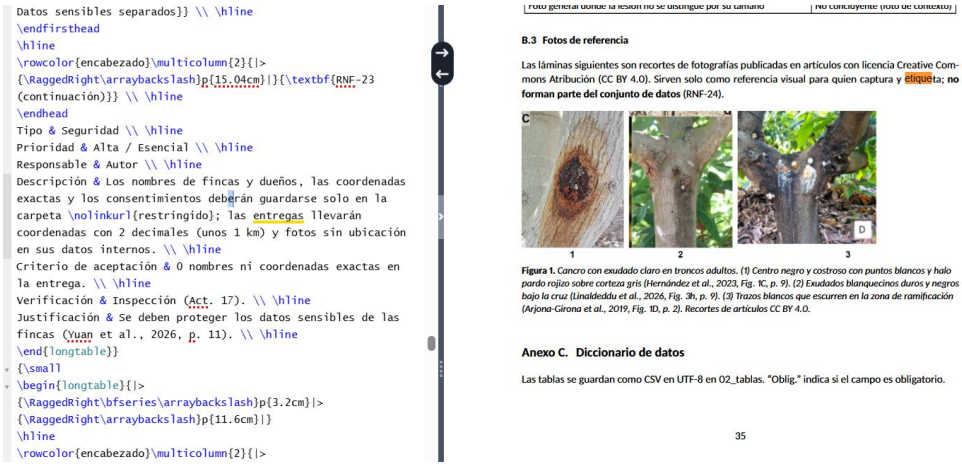
```
\end{longtable}}
\subsubsection{Seguridad y privacidad}
{\small
\begin{longtable}{|>
{\RaggedRight\bfseries\arraybackslash}p{3.2cm}|>
{\RaggedRight\arraybackslash}p{11.6cm}|}
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RNF-23.
Datos sensibles separados}} \\ \hline
\endfirsthead
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RNF-23
(continuación)}} \\ \hline
\endhead
Tipo & Seguridad \\ \hline
Prioridad & Alta / Esencial \\ \hline
Responsable & Autor \\ \hline
Descripción & Los nombres de fincas y dueños, las coordenadas
exactas y los consentimientos deberán guardarse solo en la
carpeta \nolinkurl{restringido}; las entregas llevarán
coordenadas con 2 decimales (unos 1 km) y fotos sin ubicación
en sus datos internos. \\ \hline
Criterio de aceptación & 0 nombres ni coordenadas exactas en
la entrega. \\ \hline
Verificación & Inspección (Act. 17). \\ \hline
Justificación & Se deben proteger los datos sensibles de las
fincas (Yuan et al., 2026, p. 11). \\ \hline
\end{longtable}}
```

Riesgo	Probabilidad	Impacto	Mitigación
Una clase de síntoma no aparece o no llega al mínimo	Alta	Alto	Prueba piloto, niveles de clases (RF-05), fotografiar todos los árboles con síntomas, pedir más días
Los 2 días de captura no alcanzan para 5 clases	Alta	Alto	Usar el cálculo del Anexo E para pedir 1 o 2 días más o una segunda salida

30

Riesgo	Probabilidad	Impacto	Mitigación
La corteza sana rugosa se confunde con cancro seco	Media	Alto	Fotos de corteza sana en la prueba piloto, caso dudoso específico, Kappa por par
Etiquetas ruidosas por falta de experto	Alta	Medio	Guía con reglas fijas, doble etiquetado ciego, No concluyente, limitación declarada
Una sola época del año	Segura	Medio	Registrar humedad y luz; segunda salida si es posible
Sesgo por un solo teléfono	Media	Medio	Teléfono secundario y análisis por dispositivo en el modelo
Un dueño niega el consentimiento	Baja	Medio	Gestión previa con el docente; más de 3 fincas
El fotógrafo no es especialista	Media	Medio	Anexos A y B, prueba piloto supervisada
Pérdida de fotos	Baja	Alto	Dos copias por jornada y tres copias del conjunto
Lluvia en los días de captura	Media	Medio	Registrar humedad; acordar fechas flexibles con el docente
Normativa de datos o reglas de la ESPE no confirmadas	Media	Medio	Confirmar con la tutora antes de la captura

Ilustración 38 Riesgos del conjunto de datos y su mitigación en el SRS



```
Datos sensibles separados}} \\ \hline
\endfirsthead
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
{\RaggedRight\arraybackslash}p{15.04cm}|}{\textbf{RNF-23
(continuación)}} \\ \hline
\endhead
Tipo & Seguridad \\ \hline
Prioridad & Alta / Esencial \\ \hline
Responsable & Autor \\ \hline
Descripción & Los nombres de fincas y dueños, las coordenadas
exactas y los consentimientos deberán guardarse solo en la
carpeta \nolinkurl{restringido}; las entregas llevarán
coordenadas con 2 decimales (unos 1 km) y fotos sin ubicación
en sus datos internos. \\ \hline
Criterio de aceptación & 0 nombres ni coordenadas exactas en
la entrega. \\ \hline
Verificación & Inspección (Act. 17). \\ \hline
Justificación & Se deben proteger los datos sensibles de las
fincas (Yuan et al., 2026, p. 11). \\ \hline
\end{longtable}}
{\small
\begin{longtable}{|>
{\RaggedRight\bfseries\arraybackslash}p{3.2cm}|>
{\RaggedRight\arraybackslash}p{11.6cm}|}
\hline
\rowcolor{encabezado}\multicolumn{2}{|>
```

Foto general donde la lesión no se distingue por su tamaño	No concluyente (foto de contexto)

B.3 Fotos de referencia

Las láminas siguientes son recortes de fotografías publicadas en artículos con licencia Creative Commons Atribución (CC BY 4.0). Sirven solo como referencia visual para quien captura y etiqueta; **no forman parte del conjunto de datos** (RNF-24).

Figura 1. *Cancro con exudado claro en troncos adultos. (1) Centro negro y costroso con puntos blancos y halo pardo rojizo sobre corteza gris (Hernández et al., 2023, Fig. 1C, p. 9). (2) Exudados blanquecinos duros y negros bajo la cruz (Linaldeddu et al., 2026, Fig. 3h, p. 9). (3) Trazos blancos que escurren en la zona de ramificación (Arjona-Girona et al., 2019, Fig. 1D, p. 2). Recortes de artículos CC BY 4.0.*

Anexo C. Diccionario de datos

Las tablas se guardan como CSV en UTF-8 en 02_tablas. "Oblig." indica si el campo es obligatorio.

35

Ilustración 39 Fotos de referencia de las clases y diccionario de datos del SRS

6. 16 de octubre de 2026

ID Requisito	Requisito resumido	Caso de uso Nivel 0	Caso de uso Nivel 1	Actor	Cobertura / Estado
RF-01	Crear una cuenta local con nombre, usuario y contraseña.	CU-01 Gestionar acceso	CU 1.1 Registrarse	Agricultor o técnico	**Cubierto**
RF-02	Entrar con usuario y contraseña validados en el teléfono; la sesión queda abierta hasta cerrarla.	CU-01 Gestionar acceso	CU 1.2 Iniciar sesión	Agricultor o técnico	**Cubierto**
RF-03	Salir de la cuenta con confirmación.	CU-01 Gestionar acceso	CU 1.3 Cerrar sesión	Agricultor o técnico	**Cubierto**
RF-04	Capturar la foto del tallo con la cámara guiada (marco y mensaje de ayuda).	CU-02 Analizar tallo	CU 2.1 Tomar foto	Agricultor o técnico	**Cubierto**
RF-05	Usar una foto del tallo guardada en el teléfono.	CU-02 Analizar tallo	CU 2.2 Elegir imagen de la galería	Agricultor o técnico	**Cubierto**
RF-06	Comprobar que la foto sea clara antes de analizarla y permitir repetirla.	CU-02 Analizar tallo	CU 2.3 Revisar foto	Agricultor o técnico / Sistema	**Cubierto**
RF-07	Analizar la foto con el modelo dentro del teléfono y mostrar el resultado orientativo con su confianza y avisos.	CU-02 Analizar tallo	CU 2.4 Ver resultado	Sistema / Agricultor o técnico	**Cubierto**
RF-08	Guardar el análisis en el historial del usuario al pulsar "Guardar resultado".	CU-02 Analizar tallo	CU 2.5 Guardar resultado	Agricultor o técnico	**Cubierto**
RF-09	Ver la lista de análisis guardados y el detalle de cada uno.	CU-03 Gestionar historial	CU 3.1 Consultar historial	Agricultor o técnico	**Cubierto**
RF-10	Eliminar un análisis del historial después de confirmar.	CU-03 Gestionar historial	CU 3.2 Borrar análisis	Agricultor o técnico	**Cubierto**
RF-11	Ver cómo tomar la foto, qué significa cada resultado y los límites de la aplicación.	CU-04 Consultar ayuda	No aplica	Agricultor o técnico	**Cubierto**

Matriz RF | Matriz RNF | +

Ilustración 40 Matriz de trazabilidad entre los requisitos funcionales y los casos de uso de TalloSano

3.4.3 *Trazabilidad con la revisión sistemática*

Tabla 75. *Brechas de la SLR atendidas por los requisitos*

Brecha de la SLR	Requisitos que la atienden
No hay IA para el tallo del aguacate	RF-01, RF-02, RF-27
No hay conjuntos de imágenes de tallos ni estudios de Ecuador	RF-07 a RF-14, RF-21, RF-22, RNF-01, RNF-03, RNF-04, RNF-09
Los síntomas se superponen y hay coinfecciones	RF-02 a RF-05, RF-17 a RF-19, RNF-13
La foto subestima el daño interno	RF-04, RNF-05, RNF-27
Pocas escalas visuales de severidad	RF-20, RF-23
Dependencia del servidor e Internet	RNF-01, RNF-02 (fotos de teléfonos reales para un modelo en el dispositivo)
Sin validación en campo independiente	RF-13, RF-14, RF-24 a RF-26, RNF-04, RNF-12, RNF-21, RNF-22
Poca evaluación con usuarios	RF-26, RNF-02 (fotos reales para probar la app)

Ilustración 41 Trazabilidad entre las brechas de la SLR y los requisitos del SRS del conjunto de datos

7. 19 de octubre de 2026

2.2 Zonas del tallo principal

Tabla 3. *Zonas del tallo principal*

Zona	Definición operativa	Lo que reportan las fuentes en esa zona	Respaldo
Z1 Cuello	Franja inferior del tronco en contacto con el suelo	Pudrición del cuello por *Phytophthora*; la necrosis de la corteza interna y del cámbium avanza hacia la base del tallo y agrieta la corteza	[Fuente] Linaldeddu et al. (2026, pp. 9–11)
Z2 Zona de injerto	Franja donde se unen el portainjerto (patrón) y la variedad	En plantas jóvenes, lesiones del tallo, decoloración de la madera y muerte descendente que suelen comenzar en el punto de injerto; en plantaciones nuevas, la necrosis baja por el tronco tierno hasta encima del injerto	[Fuente] Vecchio, Martino, et al. (2026, pp. 1, 3); Hernández et al. (2023, p. 8); Rodríguez-Gálvez et al. (2025, p. 2)
Z3 Fuste	Tramo del tronco entre la zona de injerto y la cruz	– Cancros con exudado. En el tallo principal, el hundimiento y el sector en V se ven menos que en las ramas por el abundante exudado oscuro; a veces hay exudado blanco en el centro. – Necrosis oscura de la corteza con exudado negruzco, sin hundimiento. – Corteza agrietada, oscura o ligeramente hundida; exudado azucarado que al secar forma un polvo blanco-amarillento. – Corteza friable con exudados de perseitol; protuberancias rugosas en la corteza del tronco.	[Fuente] Linaldeddu et al. (2026, p. 11); Hernández et al. (2023, pp. 2, 8); Valencia et al. (2022, pp. 2, 6)
Z4 Cruz (límite superior)	Punto donde nace la primera rama principal; las ramas por encima quedan fuera	Ninguna fuente de Grupos v2 define este límite	[Decisión de diseño]

Ilustración 42 Zonas del tallo principal definidas para el conjunto de datos (DS-01)

3.4 Lo que el conjunto de datos no permite

Tabla 7. *Límites del conjunto de datos*

No permite	Motivo	Respaldo
Identificar la especie del patógeno	Hay cancros causados por *Phytophthora* externamente idénticos a los de *Neofusicoccum parvum*; solo un corte del tronco permitió distinguirlos. El exudado también puede deberse a otras causas.	[Fuente] Linaldeddu et al. (2026, p. 19); Hernández et al. (2023, p. 8)
Medir el daño interno	La necrosis interna avanza antes y más lejos que la externa (lesión externa de 2,5–3,2 cm frente a decoloración interna de 12,0–12,6 cm).	[Fuente] Vecchio, Martino, et al. (2026, pp. 7–8); Rodríguez-Gálvez et al. (2025, p. 1)
Detectar infecciones latentes	Las Botryosphaeriaceae pueden vivir como endófitos sin daño inmediato.	[Fuente] Möller et al. (2025, p. 2)
Entregar la severidad como resultado del modelo	La severidad se registra como metadato.	[Decisión de diseño]
Preprocesar o aumentar las imágenes	Corresponde al modelo (SRS-2); el conjunto entrega las imágenes originales.	[Decisión de diseño]

Ilustración 43 Límites del conjunto de datos: lo que no permite identificar (DS-01)

Tabla 3. *Matriz de síntomas, zonas y fuentes*

N.º	Síntoma	Z1	Z2	Z3	Z4	Plantas jóvenes	Fuentes (pág.)	Contexto
S1	Cancro con exudado blanquecino a pardo que seca en polvo (perseitol)			●	●		A0018 (9, 11); A0015 (2, 8); A0038 (2); A0046 (11); A0022 (1, 6); A0016 (8)	Campo
S2	Exudado oscuro abundante ("sangrado") sobre el cancro	●		●			A0018 (9, 11)	Campo
S3	Necrosis oscura de la corteza con exudado negruzco, sin hundimiento			●		●	A0018 (10–11)	Campo y vivero
S4	Corteza oscura, agrietada, friable o ligeramente hundida			●			A0015 (2, 8); A0038 (2); A0046 (11); A0018 (9)	Campo
S5	Protuberancias rugosas en la corteza			●			A0038 (6)	Campo
S6	Pudrición del cuello; necrosis que baja a la base y agrieta la corteza	●				●	A0018 (9–10); A0041 (1)	Campo y vivero
S7	Lesión que nace en el injerto; decoloración en la unión del injerto		●			●	A0003 (1, 3, 6); A0046 (11); A0015 (8)	Vivero y campo
S8	Lesión necrótica oscura y alargada en tallo joven (a veces hundida, con picnidios)					●	A0018 (10, 15); A0003 (6–8); A0025 (2)	Vivero e invernadero
S9	Orificios de entrada de insecto barrenador en la corteza			●			A0045 (2)	Campo
S10	Necrosis interna (cuña o V, madera pardo-rojiza, haces rojizos)		●	●		●	A0018 (9); A0015 (2); A0016 (7); A0038 (3); A0046 (11); A0003 (7–8); A0025 (2)	Requiere corte

Ilustración 44 Matriz de síntomas del tronco, zonas y fuentes (DS-02)

Figura 1. *Cancros con exudado en el tronco de árboles adultos (síntomas S1 y S4)*



Nota. (1) Cancro del tronco: centro negro y costroso con puntos blancos y halo pardo-rojizo sobre corteza gris (Hernández et al., 2023, Fig. 1C, p. 9). (2) Cancro del tallo con exudados blanquecinos duros y negros, bajo la cruz (Linaldeddu et al., 2026, Fig. 3h, p. 9). (3) Lesiones externas con exudado; la foto muestra la zona de ramificación con trazos blancos que escurren y corteza ennegrecida (Arjona-Girona et al., 2019, Fig. 1D, p. 2). Recortes de artículos con licencia CC BY 4.0.

Ilustración 45 Fotos de referencia de cancros con exudado en el tronco (DS-02)

8. 20 de octubre de 2026

Distancias sin medir:

Foto	Distancia	Referencia con el cuerpo
General	2–3 m	Unos 3 pasos largos hacia atrás
Media	~1 m	El brazo estirado más medio brazo
De cerca	20–40 cm	Un antebrazo (del codo a la punta de los dedos)

Inclinada a 45° no es agacharse. Es dar **un paso corto al costado** alrededor del tronco, a la misma altura y a la misma distancia, y girar el teléfono para seguir apuntando a la lesión. De frente se ve bien el color; desde el costado se nota el relieve (hundimiento, costra levantada). Solo se agachan si la lesión está en la base del tronco, y entonces para todas las fotos de esa lesión.

```
VISTA DESDE ARRIBA

        ( tronco )
         \__L__/          L = lesión
          /   \
         /     \
 [teléfono]    [teléfono]
 de frente     inclinada (1 paso al costado)
```

Ilustración 46 Distancias y ángulos de captura de las fotografías del tronco

7. Planilla de finca (1 hoja por finca)

Finca: F__ · **Fecha:** / · **Hora inicio/fin:** ___ / ___ · **Clima:** sol / nublado / lluvia · **Teléfono:** _____ · **Consentimiento:** ☐

Código	Edad	Lesión	Parece	N.° lesiones	Zona y cara	Sano de	Luz	Mojado	Notas
F01-A001	A	S	B	1	Fu-N	—	Nu	N	goma blanca escurre
F01-A002	A	N	—	—	—	A001	Nu	N	líquenes
F01-A003	J	S	O	1	Cu-S	—	So	N	mancha negra en la base
F01-A004	J	N	—	—	—	A003	So	N	
F01-A005	A	S	H	1	Fu-E	—	Nu	N	corte de machete (sin sano)

Ilustración 47 Planilla de finca para el registro de campo

3. Diccionario de datos

En las tablas siguientes, "Oblig." indica si el campo es obligatorio (S) u opcional (N). El origen indica de dónde sale el dato: **EXIF** (metadatos que guarda el teléfono en la foto), **hoja de campo** (lo anota quien captura), **etiquetado** (lo asigna el etiquetador), **calculado** (se obtiene de otros campos) o **dueño** (lo informa el dueño de la finca).

3.1 Tabla fincas

Tabla 3. *Campos de la tabla fincas*

Campo	Descripción	Tipo y valores permitidos	Oblig.	Origen
id_finca	Código de la finca; no contiene su nombre	Texto "F" + 2 dígitos (F01, F02…)	S	Asignado
fecha_visita	Fecha de la visita	Fecha AAAA-MM-DD	S	Hoja de finca
parroquia	Ubicación general	Texto (p. ej., Sigchos)	S	Hoja de finca
altitud_m	Altitud aproximada	Entero, metros	N	Calculado (GPS)
clima_observado	Tiempo durante la visita	soleado / parcialmente nublado / nublado / lluvia	S	Hoja de finca
etapa_fenologica	Etapa del cultivo durante la visita	floración / cuajado / desarrollo del fruto / cosecha / sin dato	N	Dueño u observación
variedad	Variedad predominante	Texto (p. ej., Hass) o "sin dato"	N	Dueño
portainjerto	Portainjerto predominante	Texto o "sin dato"	N	Dueño
arboles_revisados	Árboles revisados en el recorrido de inspección	Entero ≥ 0	S	Hoja de finca (DS-06, sección 3)
arboles_con_sintomas	Árboles con síntomas en el tallo principal en el recorrido	Entero ≥ 0	S	Hoja de finca
consentimiento	Si el dueño dio su consentimiento	sí / no	S	DS-10

Ilustración 48 Plantilla de metadatos: campos de la tabla fincas

9. 21 de octubre de 2026

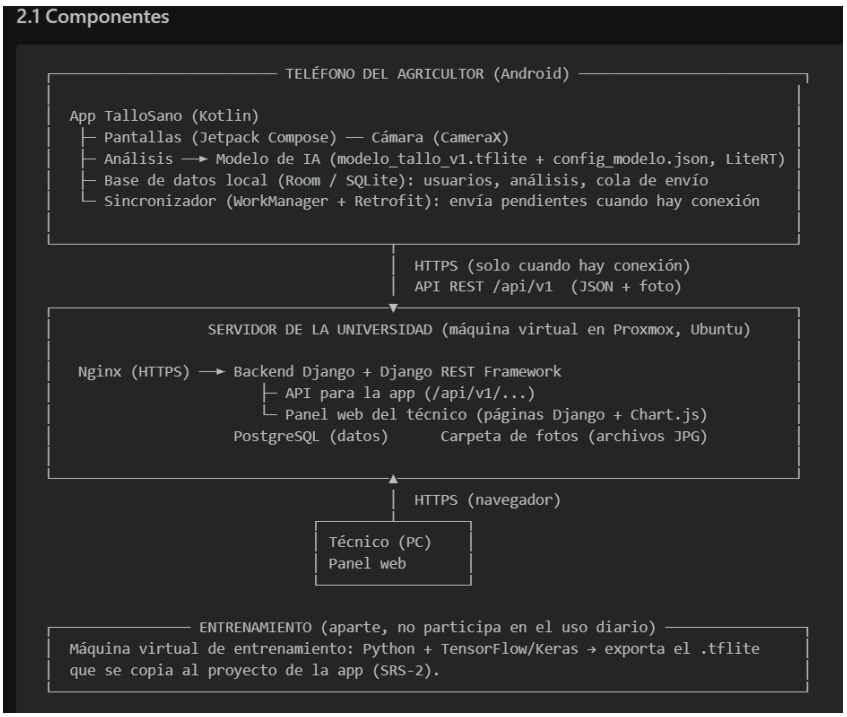
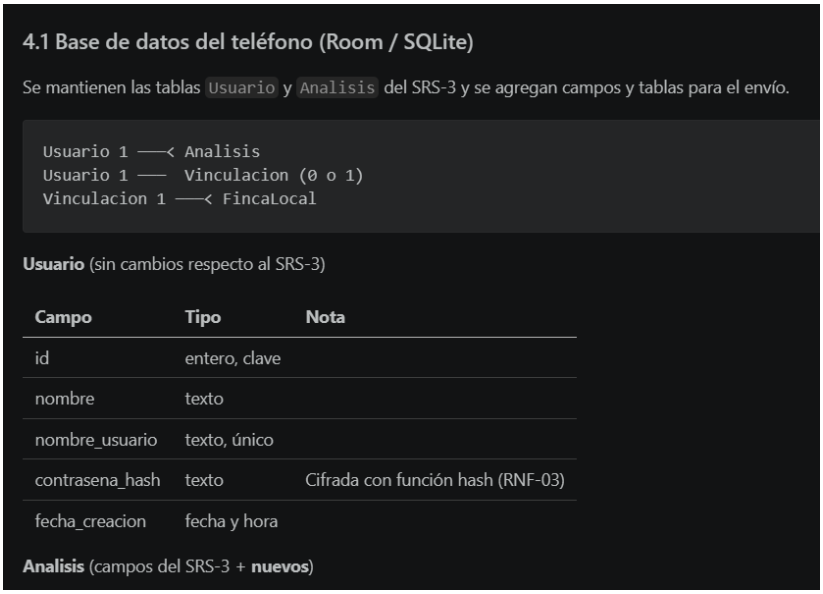


Ilustración 49 Arquitectura general del sistema TalloSano: componentes



4.1 Base de datos del teléfono (Room / SQLite)

Se mantienen las tablas `Usuario` y `Analisis` del SRS-3 y se agregan campos y tablas para el envío.

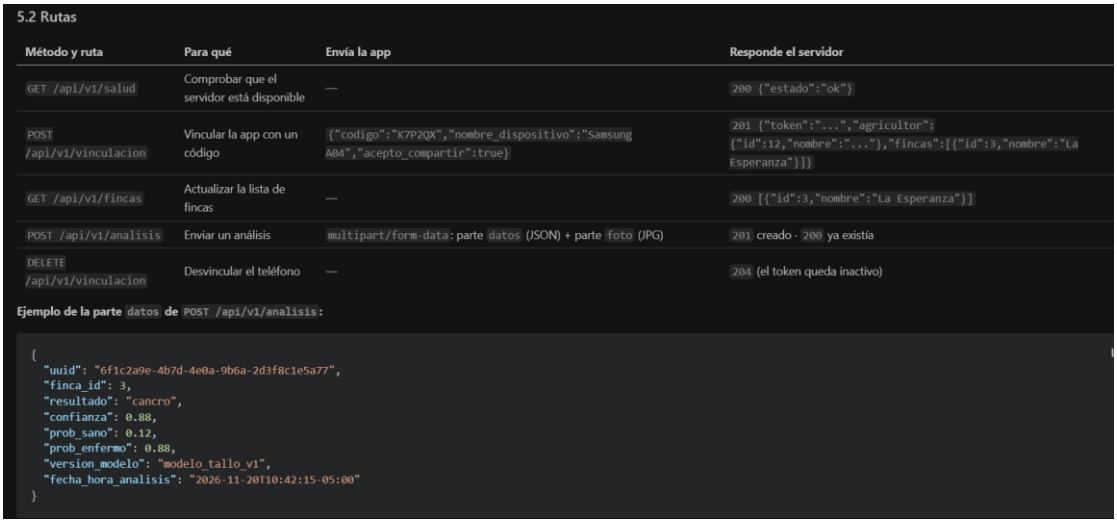
```
Usuario 1 ──< Analisis
Usuario 1 ──  Vinculacion (0 o 1)
Vinculacion 1 ──< FincaLocal
```

Usuario (sin cambios respecto al SRS-3)

Campo	Tipo	Nota
id	entero, clave	
nombre	texto	
nombre_usuario	texto, único	
contrasena_hash	texto	Cifrada con función hash (RNF-03)
fecha_creacion	fecha y hora	

Analisis (campos del SRS-3 + **nuevos**)

Ilustración 50 Modelo de datos de la base de datos del teléfono (Room / SQLite)



5.2 Rutas

Método y ruta	Para qué	Envía la app	Responde el servidor
`GET /api/v1/salud`	Comprobar que el servidor está disponible	—	`200 {"estado":"ok"}`
`POST /api/v1/vinculacion`	Vincular la app con un código	`{"codigo":"K7P2QX","nombre_dispositivo":"Samsung A04","acepto_compartir":true}`	`201 {"token":"...","agricultor":{"id":12,"nombre":"..."},"fincas":[{"id":3,"nombre":"La Esperanza"}]}`
`GET /api/v1/fincas`	Actualizar la lista de fincas	—	`200 [{"id":3,"nombre":"La Esperanza"}]`
`POST /api/v1/analisis`	Enviar un análisis	`multipart/form-data`: parte `datos` (JSON) + parte `foto` (JPG)	`201` creado · `200` ya existía
`DELETE /api/v1/vinculacion`	Desvincular el teléfono	—	`204` (el token queda inactivo)

Ejemplo de la parte `datos` de `POST /api/v1/analisis`:

```
{
  "uuid": "6f1c2a9e-4b7d-4e0a-9b6a-2d3f8c1e5a77",
  "finca_id": 3,
  "resultado": "cancro",
  "confianza": 0.88,
  "prob_sano": 0.12,
  "prob_enfermo": 0.88,
  "version_modelo": "modelo_tallo_v1",
  "fecha_hora_analisis": "2026-11-20T10:42:15-05:00"
}
```

Ilustración 51 Rutas de la API de sincronización entre la aplicación y el servidor

10. 22 de octubre de 2026

3.2.2 *Entrenamiento*

RF-07. Modelo base y aprendizaje por transferencia	
Prioridad	Alta / Esencial
Responsable	Autor (desarrollador del modelo)
Descripción	El modelo deberá partir de **MobileNetV3** preentrenado con ImageNet, reemplazando su capa final por una nueva capa de 2 salidas.
Entrada	Pesos preentrenados de MobileNetV3 (TensorFlow/Keras).
Proceso	• Cargar MobileNetV3 sin su capa final. • Añadir: agrupamiento global, abandono (dropout) de 0,2 y una capa de 2 salidas con activación softmax. • Usar la versión Large; usar Small si la Large no cumple RNF-07.
Salida	Modelo listo para entrenar.
Criterio de aceptación	Arquitectura documentada en la ficha del modelo (RF-24).

Ilustración 52 Selección de MobileNetV3 y aprendizaje por transferencia (SRS-2, RF-07)

RF-08. Experimentos de entrenamiento	
Prioridad	Alta / Esencial
Responsable	Autor (desarrollador del modelo)
Descripción	Deberán entrenarse y compararse al menos tres configuraciones.
Entrada	Datos preparados (RF-01 a RF-06) y modelo base (RF-07).
Proceso	• **E1:** MobileNetV3-Large con el modelo base congelado; solo se entrena la capa nueva. • **E2:** igual que E1 y, después, ajuste fino de los últimos bloques con una tasa de aprendizaje baja. • **E3:** MobileNetV3-Small con la mejor estrategia entre E1 y E2. • Configuración inicial en el Anexo B.
Salida	Resultados de E1, E2 y E3 en el registro.
Criterio de aceptación	Tres experimentos completos con sus métricas por pliegue.
Verificación	Revisión del registro de experimentos (Act. 18).
Justificación	Comparar configuraciones permite elegir el modelo con mejor equilibrio entre acierto y tamaño; las revisiones destacan la transferencia como forma de reducir el costo de cómputo (Majdalawieh et al., 2025, p. 5).

Ilustración 53 Experimentos de entrenamiento E1, E2 y E3 (SRS-2, RF-08)

config.yaml

C: > Users > andre > Downloads > metodologia > modelo_tallo > proyecto_modelo > configs > config.yaml

```yaml
# Defines runtime paths and training hyperparameters for the ML pipeline.

project_name: Plant_Disease_Early_Diagnosis_System          # Stable artifact identifier
data:
  raw_path: datasets/raw                                    # PlantVillage source images
  split_path: datasets/split                                # Prepared train/val/test images
  img_size: [224, 224]                                      # Input resolution [H, W]
  batch_size: 16                                            # Training batch size
  split_ratio:                                              # Dataset partition ratios
    train: 0.8                                              # Training set ratio
    val: 0.1                                                # Validation set ratio
    test: 0.1                                               # Test set ratio
  seed: 42                                                  # Reproducibility seed
  excluded_classes: []                                      # Classes omitted before splitting

model:
  base_model: MobileNetV3Large                              # Pre-trained backbone architecture
  learning_rate_stage1: 0.001                               # Initial learning rate
  learning_rate_stage2: 0.0001                              # Fine-tuning learning rate
  epochs_stage1: 15                                         # Head training duration
  epochs_stage2: 30                                         # Fine-tuning duration
  fine_tune_fraction: 0.3                                   # Fraction of backbone layers unfrozen in stage 2
  patience: 3                                               # Early stopping patience

defaults:
  model_path: outputs/model_v1/checkpoints/best_model.keras # Default inference model

```

Ilustración 54 Configuración de hiperparámetros iniciales del modelo (config.yaml)

11. 23 de octubre de 2026

config.yaml | net.py

C: > Users > andre > Downloads > metodologia > modelo_tallo > proyecto_modelo > src > modeling > net.py

```python

class PlantModel:
    def __init__(self, config: dict, num_classes: int):
        # Keep model shape and label count tied to the loaded runtime config.
        self.input_shape = (*config["data"]["img_size"], 3)
        self.num_classes = num_classes
        self.model_name = config["model"]["base_model"]

        # Apply lightweight image augmentation inside the model graph for training only.
        self.data_augmentation = keras.Sequential(
            [
                keras.layers.RandomFlip("horizontal_and_vertical"),
                keras.layers.RandomRotation(0.2),
                keras.layers.RandomZoom(0.2),
                keras.layers.RandomContrast(0.2),
            ]
        )

    def build(self) -> tuple[keras.Model, keras.Model]:
        # Resolve the configured Keras application backbone by name.
        if self.model_name not in ConfigLoader.SUPPORTED_BASE_MODELS:
            supported = ", ".join(sorted(ConfigLoader.SUPPORTED_BASE_MODELS))
            raise ValueError(f"Unsupported base_model '{self.model_name}'. Supported: {supported}")

        base_model_class = getattr(keras.applications, self.model_name)
        if not callable(base_model_class):
            raise TypeError(f"Configured base_model '{self.model_name}' is not callable")

        base_model_kwargs = {
            "input_shape": self.input_shape,
            "include_top": False,
            "weights": "imagenet",
        }
        if self.model_name in {"MobileNetV3Large", "MobileNetV3Small"}:
            # Keep the model artifact self-contained: Python, TFLite, and mobile
```

Ilustración 55 Definición del aumento de datos en el modelo (net.py)

C: > Users > andre > Downloads > metodologia > modelo_tallo > proyecto_modelo > src > modeling > net.py

```
8   class PlantModel:
25      def build(self) -> tuple[keras.Model, keras.Model]:
40          if self.model_name in {"MobileNetV3Large", "MobileNetV3Small"}:
41              # Keep the model artifact self-contained: Python, TFLite, and mobile
42              # inference all feed raw RGB pixels and rely on this layer to rescale.
43              base_model_kwargs["include_preprocessing"] = True
44
45          base_model = base_model_class(**base_model_kwargs)
46
47          # Stage 1 trains only the custom classifier head.
48          base_model.trainable = False
49
50          # Build the trainable head expected by the two-stage trainer.
51          inputs = keras.Input(shape=self.input_shape)
52          x = self.data_augmentation(inputs)
53          x = base_model(x, training=False)
54          x = keras.layers.GlobalAveragePooling2D()(x)
55          x = keras.layers.Dropout(0.2)(x)
56          outputs = keras.layers.Dense(self.num_classes, activation="softmax")(x)
57
58          model = keras.Model(inputs, outputs)
59          return model, base_model
60
```

Ilustración 56 Normalización de la entrada y capa de clasificación del modelo (net.py)

C: > Users > andre > Downloads > metodologia > modelo_tallo > proyecto_modelo > scripts > prepare_data.py > ...

```
3   import os
4   import random
5   import shutil
6   from pathlib import Path
7
8   from tqdm import tqdm
9
10  from src.core.config import ConfigLoader
11
12
13  class DataPreparer:
14      VALID_EXTENSIONS = {".jpg", ".jpeg", ".png", ".bmp"}
15
16      def __init__(self, config_path: str):
17          # Resolve paths once so cleanup and copy operations use the same contract.
18          config = ConfigLoader.load(config_path)
19          self.project_root = Path.cwd().resolve()
20
21          self.raw_path = self._resolve_project_path(config["data"]["raw_path"])
22          self.split_path = self._resolve_project_path(config["data"]["split_path"])
23          self.ratios = config["data"]["split_ratio"]
24          self.seed = config["data"]["seed"]
25          self.excluded = config["data"].get("excluded_classes", [])
26
27      def clean_target(self) -> None:
28          # Reset only a validated project-local split directory.
29          self._validate_clean_target()
30          if self.split_path.exists():
31              shutil.rmtree(self.split_path)
32          self.split_path.mkdir(parents=True)
```

Ilustración 57 Script de preparación de datos: configuración y limpieza (prepare_data.py)

```python
def split_data(self) -> None:
    # Keep file assignment reproducible across machines and reruns.
    rng = random.Random(self.seed)
    if not self.raw_path.exists():
        raise FileNotFoundError(f"Path not found: {self.raw_path}")

    # Exclude classes before sorting so label order stays deterministic.
    classes = [d.name for d in self.raw_path.iterdir() if d.is_dir()]
    classes = [c for c in classes if c not in self.excluded]
    classes.sort()

    print(f"Classes: {len(classes)}")

    for class_name in tqdm(classes, desc="Processing"):
        src_dir = self.raw_path / class_name
        images = [f for f in src_dir.iterdir() if f.suffix.lower() in self.VALID_EXTENSIONS]

        images.sort()
        rng.shuffle(images)
        splits = self._split_images(images)

        # Prefer symlinks to avoid duplicating datasets; copy on platforms that disallow them.
        for split_name, split_imgs in splits.items():
            dest_dir = self.split_path / split_name / class_name
            dest_dir.mkdir(parents=True, exist_ok=True)

            for img_path in split_imgs:
                dest_file = dest_dir / img_path.name
                try:
                    os.symlink(img_path.resolve(), dest_file)
                except OSError:
                    shutil.copy(img_path, dest_file)
```

Ilustración 58 Partición de las imágenes en entrenamiento, validación y prueba (split_data)

```python
def _split_images(self, images: list[Path]) -> dict[str, list[Path]]:
    n_images = len(images)
    split_names = ["train", "val", "test"]
    raw_counts = {name: n_images * float(self.ratios[name]) for name in split_names}
    counts = {name: int(raw_counts[name]) for name in split_names}

    remaining = n_images - sum(counts.values())
    by_fraction = sorted(
        split_names,
        key=lambda name: (raw_counts[name] - counts[name], self.ratios[name]),
        reverse=True,
    )
    for name in by_fraction[:remaining]:
        counts[name] += 1

    if n_images >= len(split_names):
        for name in split_names:
            if counts[name] == 0:
                donor = max(split_names, key=lambda candidate: counts[candidate])
                if counts[donor] > 1:
                    counts[donor] -= 1
                    counts[name] = 1

    train_end = counts["train"]
    val_end = train_end + counts["val"]
    return {
        "train": images[:train_end],
        "val": images[train_end:val_end],
        "test": images[val_end:],
    }
```

Ilustración 59 Cálculo de proporciones de la partición (_split_images)

C: > Users > andre > Downloads > metodologia > modelo_tallo > proyecto_modelo > scripts > prepare_data.py > ...

```python
class DataPreparer:

    def _resolve_project_path(self, value: str) -> Path:
        # Resolve config paths relative to the project root used for this run.
        path = Path(value).expanduser()
        if not path.is_absolute():
            path = self.project_root / path
        return path.resolve()

    def _validate_clean_target(self) -> None:
        # Guard destructive cleanup against project root and outside-project paths.
        target = self.split_path.resolve()

        if target == self.project_root:
            raise ValueError("Refusing to clean the project root")

        if not target.is_relative_to(self.project_root):
            raise ValueError(f"Refusing to clean a path outside the project: {target}")

        if target.anchor == str(target):
            raise ValueError(f"Refusing to clean a filesystem root: {target}")

        if target.exists() and not target.is_dir():
            raise ValueError(f"Split path exists but is not a directory: {target}")


if __name__ == "__main__":
    # Execute the full preparation workflow for direct script usage.
    preparer = DataPreparer("configs/config.yaml")
    preparer.clean_target()
    preparer.split_data()
```

Ilustración 60 Validaciones de rutas y ejecución del script de partición (prepare_data.py)

12. 26 de octubre de 2026

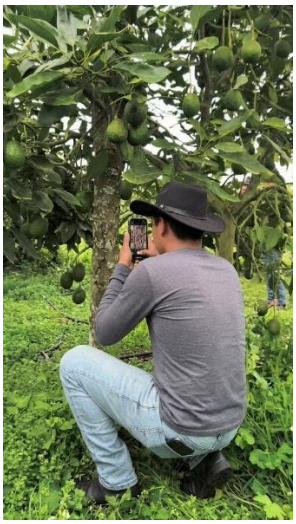


Ilustración 61 Captura de fotografías del tronco en campo

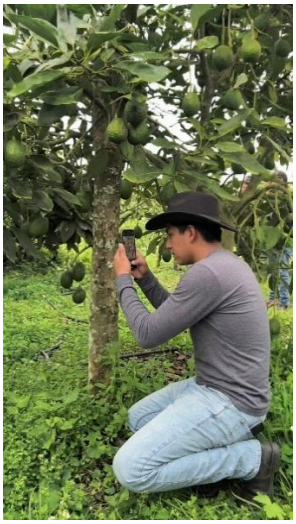


Ilustración 62 Captura de una fotografía cercana del tronco en campo



Ilustración 63 Fotografía general de un tronco sano

13. 27 de octubre de 2026



Ilustración 64 Fotografía general de un tronco con lesiones oscuras en la corteza

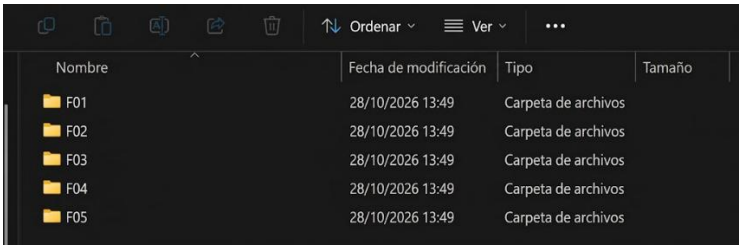


Ilustración 65 Organización de las imágenes por finca (F01–F05)

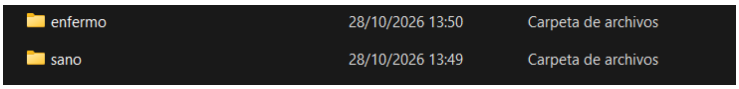


Ilustración 66 Organización de las imágenes en las carpetas sano y enfermo

14. 28 de octubre de 2026

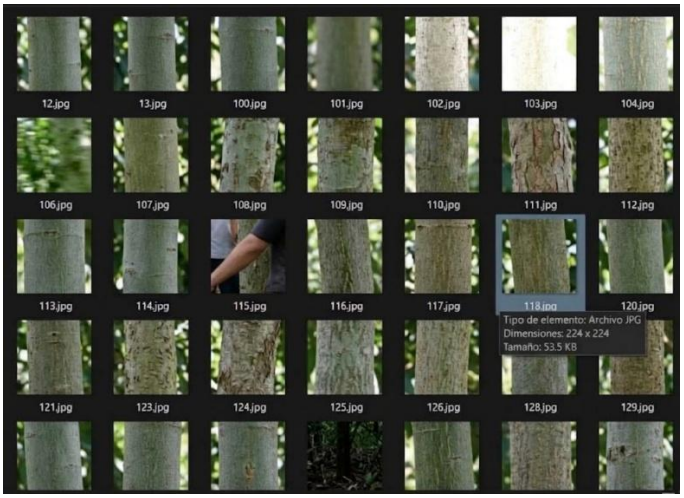


Ilustración 67 Imágenes de troncos clasificadas en la carpeta sano

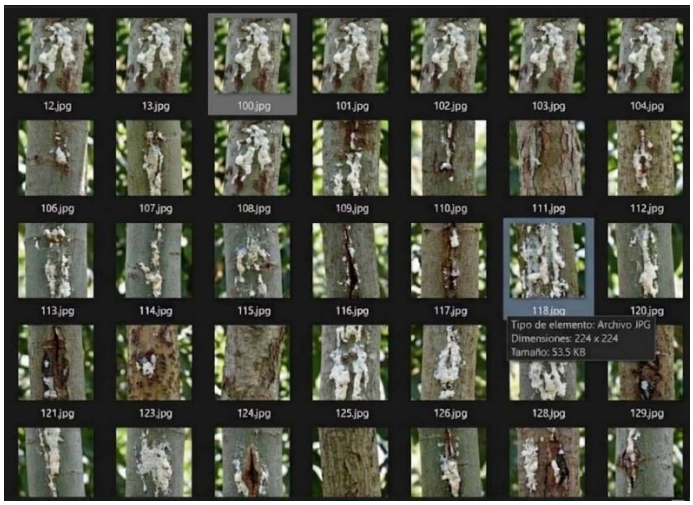


Ilustración 68 Imágenes de troncos clasificadas en la carpeta enfermo



Ilustración 69 Imágenes renombradas con el código de finca y de árbol

15. **29 de octubre de 2026**
16. **30 de octubre de 2026**
17. **4 de noviembre de 2026**
18. **5 de noviembre de 2026**
19. **6 de noviembre de 2026**
20. **9 de noviembre de 2026**
21. **10 de noviembre de 2026**
22. **11 de noviembre de 2026**